



پایان نامه دوره کارشناسی مهندسی برق

طراحی و شبیه سازی عامل تصمیم گیر هوشمند برای اعزام و استقرار آمبولانس در محیط های شهری پرتراکم

نیلوفر ملا

استاد راهنما:

دکتر مهدی دلربایی

شهریور ۱۴۰۵

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ

تقدیم به:

پدرم؛ که قامت استوارش پشتوانه‌ی گام‌هایم بود و دستان زحمت‌کشش، راهنمای مسیر فردا.
 مادرم؛ که دعاهای آرام‌بخشش، چراغ راه این مسیر پرت‌تهاب بود و عشق بی‌قید و شرطش، پناهگاه لحظه‌های
 خستگی.
 و خواهر نازنینم؛ که رفاقت و مهربانی زلالش، زیباترین انگیزه برای ادامه‌ی این راه بود.


تأییدیه هیات داوران

اعضای هیئت داوران، نسخه نهائی پایان نامه خانم: نیلوفر ملا

را با عنوان: طراحی و شبیه سازی عامل تصمیم گیر هوشمند برای اعزام و استقرار آمبولانس در محیط های شهری پرتراکم

از نظر شکل و محتوی بررسی نموده و پذیرش آن را برای تکمیل درجه کارشناسی تأیید می کنند.

اعضای هیئت داوران	نام و نام خانوادگی	رتبه علمی	امضاء
۱- استاد راهنما	دکتر مهدی دلربایی		
۲- استاد داور	دکتر امیرحسین نیکوفرد		



دانشگاه صنعتی خواجه نصیرالدین طوسی

اظهارنامه دانشجو

اینجانب نیلوفر ملا دانشجوی مقطع کارشناسی رشته مهندسی برق گواهی می‌نمایم که مطالب ارائه شده در این پایان‌نامه با عنوان:

طراحی و شبیه‌سازی عامل تصمیم‌گیر هوشمند برای اعزام و استقرار آمبولانس در محیط‌های شهری پرتراکم

با راهنمایی استاد محترم دکتر مهدی دلربایی توسط شخص اینجانب انجام شده است. صحت و اصالت مطالب نوشته شده در این پایان‌نامه تأیید می‌شود و در تدوین متن پروژه قالب مصوب دانشگاه را به طور کامل رعایت کرده‌ام.

امضاء دانشجو:

تاریخ: ۱۴۰۵/۰۶/۲۶

حق طبع، نشر و مالکیت نتایج

- ۱- حق چاپ و تکثیر این پایان نامه/رساله متعلق به نویسنده و استاد راهنمای آن است. هرگونه تصویربرداری از کل یا بخشی از پروژه تنها با موافقت نویسنده یا استاد راهنما یا کتابخانه دانشکده‌های مهندسی برق و کامپیوتر دانشگاه صنعتی خواجه نصیرالدین طوسی مجاز است.
- ۲- کلیه حقوق معنوی این اثر متعلق به دانشگاه صنعتی خواجه نصیرالدین طوسی است و بدون اجازه کتبی دانشگاه قابل واگذاری به شخص ثالث نیست.
- ۳- استفاده از اطلاعات و نتایج موجود پروژه بدون ذکر مرجع مجاز نیست.

تشکر و قدردانی

سپاس بی‌کران پروردگار یکتا را که به من موهبت اندیشیدن و آموختن عطا فرمود تا با توفیق و عنایت او، این مسیر پژوهشی را به سرانجام برسانم.

به ثمر نشستن این پایان‌نامه، وام‌دار الطاف و همراهی عزیزانی است که در این مسیر یاری گرم بوده‌اند. بر خود وظیفه می‌دانم مراتب سپاس و قدردانی عمیق خود را به استاد راهنمای گرانقدرم، جناب آقای دکتر مهدی دلربایی تقدیم نمایم. ایشان برای من بسیار فراتر از یک استاد راهنما بودند؛ حامی و معلمی دلسوز که با سعه‌ی صدر، شکیبایی بی‌نظیر و راهنمایی‌های عالمانه‌شان در تک‌تک لحظات این پژوهش در کنارم ایستادند. حمایت‌های بی‌دریغ و صبوری ایشان در برابر چالش‌های مسیر، بزرگ‌ترین پشتوانه و دلگرمی من برای عبور از موانع علمی بود و بدون همراهی پدران و دلسوزانه‌ی ایشان، این دستاورد هرگز محقق نمی‌شد.

همچنین از استاد محترم و داور گرامی، جناب آقای دکتر امیرحسین نیکوفرد، که با دقت نظر، زمان‌گذاری و نقدهای سازنده‌ی خود بر غنای علمی و کیفیت این رساله افزودند، صمیمانه سپاسگزاری می‌کنم.

در نهایت، خالصانه‌ترین مراتب قدردانی خود را نثار خانواده‌ی عزیزم می‌نمایم. پدر و مادر مهربانم که با دعای خیر و از خودگذشتگی‌هایشان، همواره استوارترین تکیه‌گاه من بوده‌اند و خواهر نازنینم که با همدلی و حضور گرمش، تلخی خستگی‌های این مسیر را به شیرینی تبدیل کرد. این موفقیت، ثمره‌ی فداکاری‌های بی‌دریغ آنان است.

چکیده

مدیریت مدیریت بهینه ناوگان اورژانس پیش‌بیمارستانی در کلان‌شهرهای پرتراکم به دلیل نوسانات ترافیکی و توزیع تصادفی حوادث، یک چالش پیچیده است. رویکردهای سنتی و واکنشی، به دلیل فقدان دیدگاه پیش‌بینانه، منجر به بروز خلأهای پوششی و سرگردانی ناوگان می‌شوند. به منظور غلبه بر این چالش، پژوهش حاضر یک سیستم پشتیبان تصمیم‌گیری را طراحی نموده و عملکرد آن را بر روی گراف ساده‌شده ترافیکی کلان‌شهر تهران شبیه‌سازی کرده است. در این معماری، اعزام بر اساس کوتاه‌ترین زمان سفر دینامیک انجام می‌شود، در حالی که بازاستقرار پیشگیرانه توسط عامل هوشمند مبتنی بر یادگیری تقویتی عمیق و الگوریتم بهینه‌سازی نزدیک‌ترین سیاست هدایت می‌گردد. این مدل شبیه‌سازی با لحاظ نمودن محدودیت‌های واقع‌گرایانه‌ای نظیر استهلاک، خرابی ناوگان و ترافیک پویا، بر اساس میانگین‌گیری آماری از ۳۰ اجرای متوالی ارزیابی شده است. نتایج استخراج‌شده در سه سناریوی عملیاتی، نشان‌دهنده برتری چشمگیر و معنادار عامل هیبریدی است؛ به طوری که در روز کاری استاندارد، نرخ موفقیت رسیدن در زمان طلایی با بهبودی بالغ بر ۱۱ درصد، به مرز ۸۶٪ ارتقا یافت. در ارزیابی متقاطع (روز تعطیل)، مدل با اتخاذ استراتژی خویشتن‌داری، زمان سرگردانی ناوگان را نزدیک به ۷۴ درصد کاهش داد. همچنین در تست استرس و شرایط بحرانی (۷۰۰ تقاضا)، شبکه عصبی با درک اشباع سیستم و اجرای منطق تریاژ مکانی، تاب‌آوری ناوگان را در سخت‌ترین تقاطع ترافیک و بحران، با ۲۶ درصد بهبود نسبی در مقایسه با خط مبنا افزایش داد.

کلیدواژه‌ها: مدیریت ناوگان اورژانس، بازاستقرار پیشگیرانه، سیستم تصمیم‌گیر هیبریدی، یادگیری تقویتی عمیق، الگوریتم بهینه‌سازی خط‌مشی در مجاورت، تریاژ مکانی، شبیه‌سازی رویداد گسسته.

فهرست مطالب

عنوان	صفحه
تأییدیه هیات داوران.....	ب
فهرست شکل‌ها.....	ک
فهرست جدول‌ها.....	ل
فصل ۱- مقدمه.....	۱
۱-۱- بیان مسئله.....	۲
۱-۲- ضرورت و اهمیت تحقیق.....	۳
۱-۳- اهداف تحقیق.....	۴
۱-۳-۱- هدف اصلی.....	۴
۱-۳-۲- اهداف فرعی.....	۴
۱-۴- سوالات تحقیق.....	۵
۱-۵- ساختار پایان نامه.....	۶
فصل ۲- مرور ادبیات و پیشینه تحقیق.....	۷
۲-۱- مقدمه.....	۷
۲-۲- مفاهیم پایه‌ای و تفکیک عملیاتی در مدیریت ناوگان اورژانس.....	۸
۲-۲-۱- زمان پاسخ‌گویی و مفهوم زمان طلایی.....	۸
۲-۲-۲- تفکیک بنیادین: اعزام در برابر استقرار مجدد.....	۸
۲-۳- رویکردهای قطعی و ایستا.....	۹
۲-۴- رویکردهای احتمالی و برنامه‌ریزی پویای تقریبی.....	۱۱
۲-۵- هوش مصنوعی و یادگیری تقویتی عمیق در اورژانس.....	۱۳
۲-۶- تبیین خلأ تحقیقاتی و معرفی رویکرد هیبریدی.....	۱۵
فصل ۳- مدل‌سازی ریاضی و روش‌شناسی تحقیق.....	۱۷
۳-۱- مقدمه.....	۱۷

- ۲-۳- چارچوب کلی سیستم پیشنهادی..... ۱۷
- ۳-۳- مدل سازی محیط شهری..... ۱۹
- ۱-۳-۳- شبکه ارتباطی و گراف شهر..... ۱۹
- ۲-۳-۳- وزن دهی یال ها و زمان سفر پایه..... ۲۰
- ۳-۳-۳- ترافیک پویا و زمان سفر لحظه ای..... ۲۱
- ۴-۳-۳- تولید مکانی-زمانی حوادث..... ۲۱
- ۵-۳-۳- شدت حادثه و مهلت پاسخ..... ۲۲
- ۶-۳-۳- مدل ناوگان و وضعیت آمبولانس ها..... ۲۲
- ۷-۳-۳- خدمت رسانی، خرابی، بازگشت شبانه..... ۲۳
- ۸-۳-۳- منابع عدم قطعیت در محیط شبیه سازی..... ۲۴
- ۴-۳- منطق عملیاتی سیستم..... ۲۵
- ۱-۴-۳- تشکیل صف حوادث..... ۲۵
- ۲-۴-۳- سیاست اعزام حریصانه..... ۲۵
- ۳-۴-۳- محاسبه زمان پاسخ..... ۲۶
- ۴-۴-۳- سیاست بازاستقراری قانون محور در روش های پایه..... ۲۶
- ۵-۴-۳- چرایی معماری هیبریدی..... ۲۶
- ۵-۳- فرمول بندی مسئله به صورت فرآیند تصمیم گیری مارکوف..... ۲۷
- ۱-۵-۳- فضای حالت..... ۲۷
- ۲-۵-۳- فضای عمل..... ۲۸
- ۳-۵-۳- تابع انتقال..... ۲۸
- ۴-۵-۳- تابع پاداش..... ۲۹
- ۵-۵-۳- ضریب تنزیل و هدف یادگیری..... ۳۰
- ۶-۳- PPO و فرایند آموزش..... ۳۰
- ۱-۶-۳- مبانی PPO..... ۳۰

۳۰	۳-۶-۲- تابع هدف PPO.....
۳۱	۳-۶-۳- تنظیمات آموزش.....
۳۱	۳-۷-۷- تعریف روش‌ها و حالات تقاضا.....
۳۱	۳-۷-۱- روش اول: خط مبنا بدون ترافیک.....
۳۱	۳-۷-۲- روش دوم: ترافیک پویا و خرابی.....
۳۲	۳-۷-۳- روش سوم: استقرار مجدد مبتنی بر یادگیری تقویتی.....
۳۲	۳-۷-۴- تقاضای ناهمگن زمانی و کالبراسیون حالات شبیه‌سازی.....
۳۳	۳-۷-۵- پروتکل ارزیابی آماری و اعتبارسنجی نتایج (اجرای ۳۰ روزه).....
۳۵	فصل ۴- نتایج شبیه‌سازی و تحلیل عملکرد.....
۳۵	۴-۱- مقدمه.....
۳۷	۴-۲- معرفی شاخص‌های کلیدی عملکرد.....
۳۷	۴-۲-۱- شاخص‌های کیفیت خدمات بالینی.....
۳۸	۴-۲-۲- شاخص‌های پوشش مکانی-زمانی.....
۳۸	۴-۲-۳- شاخص‌های کارایی عملیاتی و استهلاك.....
۳۹	۴-۲-۴- شاخص‌های توزیع بار کاری و خستگی تکنسین‌ها.....
۳۹	۴-۳- تأثیر ترافیک پویا بر عملکرد اورژانس (ضرورت استفاده از هوش مصنوعی).....
۴۰	۴-۳-۱- ارزیابی عملکرد در شرایط آرمانی (خط مبنای ایستا).....
۴۰	۴-۳-۲- افت عملکرد در محیط واقعی (ترافیک پویا و استهلاك).....
۴۱	۴-۳-۳- تحلیل مقایسه‌ای و آسیب‌شناسی سیستم واکنشی.....
۴۲	۴-۴- ارزیابی عملکرد عامل هوشمند در شرایط تقاضای استاندارد (روز کاری).....
۴۳	۴-۴-۱- بهبود زمان پاسخ‌گویی و نرخ موفقیت.....
۴۶	۴-۴-۲- تحلیل پوشش استراتژیک مکانی.....
۴۷	۴-۴-۳- تحلیل کارایی عملیاتی، توزیع بار کاری و کاهش استهلاك.....
۴۸	۴-۴-۴- جمع‌بندی دستاوردهای عامل هوشمند در شرایط استاندارد.....

۴-۵-ارزیابی تطبیق پذیری مدل در الگوهای متغیر (سناریوی روز تعطیل).....	۴۸
۴-۵-۱-تحلیل شاخص های کلان و عملکرد در پیک های ترافیکی شبانه.....	۴۹
۴-۵-۲-کارایی عملیاتی و کنترل پدیده هرج و مرج ناوگان.....	۵۱
۴-۶-تحلیل حساسیت و تست تاب آوری سیستم (شرایط بحران و تقاضای بالا).....	۵۳
۴-۶-۱-تحلیل فروپاشی سیستم و محدودیت های فیزیکی شبکه.....	۵۳
۴-۶-۲-تحلیل تاب آوری در ساعات اوج بحران.....	۵۴
۴-۶-۳-کارایی عملیاتی و جلوگیری از سرگردانی مطلق ناوگان.....	۵۶
۴-۷-شناسایی گلوگاه های عملیاتی و تحلیل آسیب پذیری.....	۵۷
۴-۷-۱-تحلیل توزیع زمانی آسیب پذیری.....	۵۸
۴-۷-۲-تحلیل عمیق مکانی: تقاطع پوشش دهی و نرخ شکست.....	۶۰
۴-۸-تحلیل پاداش تجمعی شبکه عصبی در سناریوهای سه گانه.....	۶۲
فصل ۵- نتیجه گیری و پیشنهادات.....	۶۶
۵-۱-دستاوردها و نتایج اصلی پژوهش.....	۶۷
۵-۲-پیشنهادهای کاربردی و مدیریتی.....	۶۹
۵-۳-نوآوری های پژوهش.....	۷۱
۵-۴-محدودیت های پژوهش و فرضیات ساده ساز.....	۷۳
۵-۵-پیشنهادهای تحقیقات آتی.....	۷۵
مراجع.....	۷۸

فهرست شکل‌ها

صفحه	عنوان
شکل ۳-۱: گراف ساده‌شده شهر تهران..... ۲۰	
شکل ۴-۱: مقایسه توزیع زمان‌های پاسخ‌گویی؛ (الف): شرایط آرمانی بدون ترافیک، (ب): محیط واقع‌گرایانه با ترافیک پویا..... ۴۱	
شکل ۴-۲: مقایسه محله‌های فاقد پوشش در طول ۲۴ ساعت؛ (الف): شرایط آرمانی، (ب): تأثیر ترافیک پویا بر ایجاد خلأهای پوششی..... ۴۱	
شکل ۴-۳: مقایسه توزیع زمان‌های پاسخ‌گویی در شرایط ترافیک پویا؛ (الف): خط مبنای واکنشی (بدون هوش مصنوعی)، (ب): سیستم مدیریت‌شده توسط عامل هوشمند (RL)..... ۴۳	
شکل ۴-۴: مقایسه عملکرد عامل هوشمند و خط مبنای پویا به تفکیک ترافیک روان (روز) و پیک ترافیک (شبانه) در روز کاری استاندارد..... ۴۴	
شکل ۴-۵: مقایسه تعداد محله‌های فاقد پوشش در طول ۲۴ ساعت؛ (الف): خط مبنای واکنشی (بدون هوش مصنوعی)، (ب): سیستم مدیریت‌شده توسط عامل هوشمند (RL)..... ۴۶	
شکل ۴-۶: مقایسه عملکرد عامل هوشمند و خط مبنای پویا به تفکیک ترافیک روان (روز) و پیک ترافیک (شبانه) در روز تعطیل..... ۵۰	
شکل ۴-۷: مقایسه تاب‌آوری خط مبنای پویا و عامل هوشمند در شرایط بحران به تفکیک ترافیک روان و ترافیک اوج..... ۵۴	
شکل ۴-۸: روند تغییرات مناطق بی‌دفاع در شرایط بحران (مدل RL). پرش‌های نمودار به سمت مرز ۵۵ محله، نشان‌دهنده اشباع کامل ناوگان است..... ۵۶	
شکل ۴-۹: توزیع ساعتی مأموریت‌های ناموفق (تأخیردار)؛ (الف) روز کاری، (ب) روز تعطیل، (ج) بحران..... ۵۸	
شکل ۴-۱۰: مقایسه مناطق دارای بیشترین آسیب‌پذیری تئوریک (بالا - زمان عدم پوشش) در تقاطع با مناطق دارای بیشترین شکست عملیاتی (پایین - تعداد مأموریت تأخیردار)..... ۶۰	
شکل ۴-۱۱: روند میانگین پاداش تجمعی عامل هوشمند PPO در طول یک شبانه‌روز (حاصل ۳۰ بار اجرا)؛ (الف) روز کاری، (ب) روز تعطیل، (ج) بحران..... ۶۲	
شکل ۴-۱۲: اثبات کمینه‌سازی هزینه‌ها؛ مقایسه پاداش تجمعی عامل هوشمند در برابر خط مبنا..... ۶۴	

فهرست جدول‌ها

عنوان	صفحه
جدول ۱-۴: عملکرد سیستم مکاشفه‌ای در شرایط آرمانی (بدون ترافیک - روز کاری استاندارد).....	۴۰
جدول ۲-۴: عملکرد سیستم مکاشفه‌ای در محیط واقع‌گرایانه (با ترافیک پویا و استهلاک - روز کاری استاندارد) (حاصل ۳۰ بار اجرای مستقل).....	۴۰
جدول ۳-۴: عملکرد عامل هوشمند (RL) در محیط واقع‌گرایانه در روز کاری استاندارد (حاصل ۳۰ بار اجرای مستقل).....	۴۳
جدول ۴-۴: مقایسه آماری نرخ موفقیت در شرایط مختلف ترافیکی (حاصل ۳۰ بار اجرای مستقل).....	۴۵
جدول ۵-۴: مقایسه شاخص‌های عملیاتی و بار کاری در روز کاری استاندارد (حاصل ۳۰ بار اجرای مستقل).....	۴۷
جدول ۶-۴: مقایسه عملکرد کلی سیستم خط مبنای پویا و عامل هوشمند در سناریو روز تعطیل (حاصل ۳۰ بار اجرای مستقل).....	۴۹
جدول ۷-۴: مقایسه آماری نرخ موفقیت در شرایط مختلف ترافیکی روز تعطیل (حاصل ۳۰ بار اجرای مستقل).....	۵۰
جدول ۸-۴: مقایسه شاخص‌های عملیاتی و بار کاری در ارزیابی متقاطع روز تعطیل (حاصل ۳۰ بار اجرای مستقل).....	۵۲
جدول ۹-۴: مقایسه عملکرد کلی خط مبنای پویا و عامل هوشمند در شرایط تست استرس (حاصل ۳۰ بار اجرای مستقل).....	۵۳
جدول ۱۰-۴: مقایسه آماری نرخ موفقیت در شرایط بحران تقاضا (حاصل ۳۰ بار اجرای مستقل).....	۵۵
جدول ۱۱-۴: مقایسه شاخص‌های عملیاتی و استهلاک در شرایط تست استرس (حاصل ۳۰ بار اجرای مستقل).....	۵۷

فصل ۱- مقدمه

سیستم‌های اورژانس پیش‌بیمارستانی^۱ خط مقدم نظام سلامت در مواجهه با حوادث و سوانح محسوب می‌شوند. در شرایط بحرانی نظیر ایست قلبی، سکته مغزی یا تصادفات شدید ترافیکی، حفظ حیات بیمار وابستگی مستقیمی به زمان پاسخ‌گویی^۲ دارد؛ تا جایی که از چند دقیقه‌ی ابتدایی پس از وقوع حادثه به عنوان زمان طلایی یاد می‌شود [۱]. با گسترش روزافزون کلان‌شهرها، تراکم جمعیت و پیچیدگی شبکه‌های ارتباطی، مدیریت ناوگان اورژانس از یک مسئله‌ی ساده‌ی لجستیکی، به یک چالش بهینه‌سازی پویا و تصادفی^۳ تبدیل شده است [۲].

در محیط‌های شهری پرتراکم نظیر کلان‌شهر تهران، ترافیک دارای نوسانات شدید زمانی و مکانی است و توزیع حوادث نیز از الگوهای غیرقطعی پیروی می‌کند. در چنین بستر متلاطمی، تکیه بر الگوریتم‌های سنتی تخصیص منابع، منجر به کاهش بهره‌وری ناوگان و از دست رفتن زمان‌های حیاتی می‌گردد. از این رو، ادغام تکنیک‌های نوین هوش مصنوعی، به‌ویژه یادگیری تقویتی عمیق^۴ [۳]، با سیستم‌های اطلاعات جغرافیایی، بستری را فراهم آورده است تا سیستم‌های مدیریت بحران از فاز انفعال خارج شده و به سمت تصمیم‌گیری‌های پیش‌بینانه و استراتژیک حرکت کنند.

^۱ EMS: Emergency Medical Services

^۲ Response Time

^۳ Stochastic Optimization

^۴ Deep Reinforcement Learning

۱-۱- بیان مسئله

رایج‌ترین سیاست عملیاتی در سیستم‌های اعزام آمبولانس، رویکرد نزدیک‌ترین در دسترس^۱ است [۴]. در این رویکرد، سیستم به صورت کاملاً واکنشی^۲ عمل می‌کند؛ بدین معنا که تنها پس از وقوع حادثه و تماس با مرکز، نزدیک‌ترین آمبولانس آزاد به محل اعزام می‌گردد. البته باید توجه داشت که در شبکه‌های پیچیده شهری، مفهوم نزدیک‌ترین لزوماً معادل کوتاه‌ترین فاصله مکانی نیست؛ بلکه در یک سیستم کارآمد، تخصیص باید بر اساس کوتاه‌ترین زمان سفر دینامیک^۳، با در نظر گرفتن ترافیک لحظه‌ای انجام شود. چرا که گاهی یک آمبولانس با فاصله مکانی بیشتر، به دلیل قرارگیری در مسیرهای روان‌تر، سریع‌تر از آمبولانس مجاور به بالین بیمار می‌رسد.

با این وجود، حتی اگر اعزام بر اساس زمان سفر بهینه نیز انجام شود، ضعف بنیادین رویکرد واکنشی زمانی آشکار می‌شود که اعزام یک آمبولانس، منجر به ایجاد خلأ پوششی در منطقه‌ی استقرار اولیه می‌گردد. اگرچه برخی سیستم‌های پیشرفته‌تر با استفاده از رویکردهای مکاشفه‌ای^۴ و قوانین استقرار در محل تلاش می‌کنند با جابه‌جایی سایر آمبولانس‌ها این خلأ را پر کنند، اما به دلیل فقدان نگاه پیش‌بینانه^۵ و عدم درک دینامیک پیچیده‌ی ترافیک، این جابه‌جایی‌ها در ساعات پیک ناکارآمد بوده و منجر به پدیده‌ی مخرب سرگردانی ناوگان^۶ می‌شوند [۵]. در این حالت، آمبولانس‌ها بدون آنکه مأموریتی انجام دهند، دائماً در گراف پرترافیک شهر جابه‌جا شده و استهلاک بالایی را به سیستم تحمیل می‌کنند.

علاوه بر این، در زمان وقوع شوک‌های تقاضا (بحران)، سیستم‌های مبتنی بر قوانین صلب دچار فروپاشی منطقی شده و توانایی اولویت‌بندی مکانی (تریاز فضایی) را از دست می‌دهند. در نتیجه، مسئله‌ی اصلی این پژوهش، فقدان یک عامل تصمیم‌گیر هوشمند و آینده‌نگر است که قادر باشد پویایی‌های ترافیک، استهلاک

^۱ Myopic/Greedy Dispatch

^۲ Reactive

^۳ Dynamic Travel Time

^۴ Heuristics

^۵ Proactive

^۶ Fleet Thrashing

ناوگان و ارزش استراتژیک محله‌های مختلف را در لحظه تحلیل کرده و ناوگان محدود اورژانس را به صورت بهینه توزیع نماید.

۱-۲- ضرورت و اهمیت تحقیق

اهمیت توسعه‌ی یک سیستم هوشمند اعزام و استقرار در کلان‌شهرها، ریشه در دو بُعد انسانی و اقتصادی دارد. از منظر انسانی، هر دقیقه تأخیر در رسیدن به بالین بیمار بدحال، احتمال مرگ‌ومیر و یا بروز ضایعات عصبی جبران‌ناپذیر را به صورت تصاعدی افزایش می‌دهد [۱]. بنابراین، ارتقای الگوریتم‌های مسیریابی و استقرار، مستقیماً با شاخص نجات جان انسان‌ها در ارتباط است.

از منظر اقتصاد سلامت، تجهیز و نگهداری ناوگان آمبولانس هزینه‌های گزافی به همراه دارد. رویکردهای سنتی برای جبران افت عملکرد در ساعات پیک ترافیک، همواره پیشنهاد خرید آمبولانس بیشتر یا احداث پایگاه‌های جدید را مطرح می‌کنند که در بسیاری از مواقع فاقد توجیه اقتصادی است. استفاده از هوش مصنوعی، ظرفیت پنهان ناوگان موجود را آزاد کرده و بهره‌وری را به سقف ریاضی خود می‌رساند. توسعه‌ی شبکه‌های عصبی نظیر بهینه‌سازی نزدیک‌ترین سیاست^۱ [۶] که قادر به درک پاداش‌های بلندمدت و ارزیابی ریسک در محیط‌های غیرقطعی هستند، این امکان را فراهم می‌سازد تا تصمیماتی فراتر از توان تحلیل انسانی، مانند فدا کردن آگاهانه‌ی یک گره کم‌خطر برای حفظ شریان‌های مرکزی، اتخاذ شود که ضرورت انجام این تحقیق را به روشنی اثبات می‌نماید.

^۱ PPO: Proximal Policy Optimization

۱-۳- اهداف تحقیق

۱-۳-۱- هدف اصلی

هدف اصلی پروژه، طراحی، شبیه‌سازی و ارزیابی یک سیستم تصمیم‌گیر هوشمند هیبریدی^۱ برای مدیریت پویای ناوگان آمبولانس در محیط‌های شهری پرتراکم (با مطالعه موردی کلان‌شهر تهران) است؛ به گونه‌ای که فرآیند اعزام^۲ بر مبنای الگوریتم‌های قطعی و تخصیص سریع‌ترین زمان سفر دینامیک انجام پذیرد و فرآیند استقرار مجدد و پیشگیرانه^۳ توسط یک عامل هوشمند مبتنی بر یادگیری تقویتی عمیق هدایت شود، تا در نهایت نرخ پاسخ‌گویی به‌موقع بیشینه و استهلاک ناوگان کمینه گردد.

۱-۳-۲- اهداف فرعی

اهداف فرعی این پژوهش به این صورت است:

- تفکیک منطق عملیاتی سیستم به دو لایه‌ی اعزام واکنشی و قطعی و استقرار پیش‌بینانه و هوشمند جهت حفظ پایداری و قابلیت اطمینان در تصمیمات اورژانس.
- مدل‌سازی محیط تصادفی و پویای کلان‌شهر، شامل گراف ترافیکی متغیر (بر اساس ساعات شبانه‌روز) و توزیع غیریکنواخت حوادث با در نظر گرفتن شدت بالینی آن‌ها.
- توسعه و پیاده‌سازی یک الگوریتم خط مبنای پیشرفته مبتنی بر سیاست استقرار در محل جهت ایجاد یک معیار ارزیابی عادلانه برای سنجش عملکرد هوش مصنوعی.
- کاهش استهلاک و سرگردانی ناوگان از طریق پیاده‌سازی استراتژی‌های خویشنداری توسط شبکه عصبی.

^۱ Hybrid Intelligent Decision Making System

^۲ Dispatch

^۳ Proactive Relocation

- ارزیابی قدرت تعمیم‌پذیری مدل آموزش‌دیده در برابر تغییر رژیم ترافیکی (نظیر تغییر توزیع تقاضا در روزهای تعطیل).
- سنجش تاب‌آوری سیستم در شرایط بحران و اشباع تقاضا از طریق پیاده‌سازی مفهوم تریاژ مکانی و اولویت‌بندی گره‌های شهری.
- اعتبارسنجی قطعی و اثبات معناداری آماری برتری عامل هوشمند، از طریق میانگین‌گیری‌های متوالی ۳۰ روزه و ارزیابی زوجی در برابر سیستم خط مبنا.

۱-۴- سوالات تحقیق

سوالات این پژوهش به شرح زیر است:

- چگونه استفاده از الگوریتم‌های یادگیری تقویتی (به‌ویژه الگوریتم بهینه‌سازی خط‌مشی در مجاورت) می‌تواند زمان پاسخ‌گویی و نرخ موفقیت مأموریت‌های اورژانس را در مقایسه با روش‌های استقرار سنتی بهبود بخشد؟
- عامل هوشمند چگونه می‌تواند بدون افت چشمگیر شاخص‌های پوشش، از پدیده سرگردانی ناوگان (استهلاک ناشی از جابه‌جایی‌های پیوسته) در محیط‌های پویا جلوگیری نماید؟
- آیا مدل آموزش‌دیده در شرایط توزیع متداول روز کاری، قابلیت تعمیم‌پذیری و حفظ کارایی در محیط‌های پیش‌بینی‌نشده (نظیر روز تعطیل و تقاضای بحرانی) را داراست؟
- رفتار و منطق تصمیم‌گیری شبکه عصبی در مواجهه با شرایط اشباع ناوگان (کمبود مطلق منابع) چگونه تفسیر می‌شود؟

۱-۵- ساختار پایان نامه

رساله حاضر در پنج فصل ساختاریافته است. در فصل اول، کلیات تحقیق، بیان مسئله و اهداف پژوهش تشریح گردید. فصل دوم به بررسی پیشینه ادبیات تحقیق و مرور انتقادی مطالعات پیشین در حوزه مکان‌یابی و تخصیص ناوگان امدادی با رویکردهای تحقیق در عملیات و یادگیری ماشین می‌پردازد. در فصل سوم، روش‌شناسی پژوهش، ابزارهای شبیه‌سازی، مدل‌سازی گراف شهری، معماری تابع پاداش و ریاضیات حاکم بر الگوریتم PPO به تفصیل بیان می‌گردد. فصل چهارم به اجرای شبیه‌سازی‌ها، تحلیل نتایج، ارزیابی مقایسه‌ای هوش مصنوعی با خط مبنا (بر اساس داده‌های تجمیعی از ۳۰ اجرای مستقل) و تست‌های تاب‌آوری اختصاص دارد. در نهایت، فصل پنجم ضمن نتیجه‌گیری از دستاوردهای تحقیق، پیشنهادات کاربردی برای مدیران شهری و مسیرهای توسعه برای محققان آتی را ارائه می‌نماید.

فصل ۲- مرور ادبیات و پیشینه تحقیق

۲-۱- مقدمه

سیستم‌های مدیریت اورژانس پیش‌بیمارستانی در دهه‌های اخیر تحولات چشمگیری را پشت سر گذاشته‌اند. با افزایش روزافزون جمعیت کلان‌شهرها و پیچیده‌تر شدن شبکه‌های ترافیکی، رویکردهای سنتی مدیریت ناوگان که عمدتاً بر پایه ریاضیات قطعی و مدل‌های ایستا بنا شده بودند، به تدریج جای خود را به سیستم‌های پویا و هوشمند داده‌اند [۲]. مرور ادبیات در این حوزه نشان می‌دهد که مسیر تکامل الگوریتم‌های تخصیص منابع امدادی، یک روند تدریجی از مدل‌های مکان‌یابی ثابت، به سمت مدل‌های تصادفی (نظیر برنامه‌ریزی پویای تقریبی) و در نهایت به سمت رویکردهای نوین مبتنی بر یادگیری ماشین و هوش مصنوعی بوده است [۷].

هدف از این فصل، بررسی، دسته‌بندی و تحلیل انتقادی مطالعات پیشین در زمینه اعزام و استقرار آمبولانس‌هاست. در این راستا، ابتدا در بخش ۲-۲، مفاهیم بنیادین و شاخص‌های کلیدی در مدیریت اورژانس تبیین می‌گردد و تفاوت ماهوی فرآیندهای عملیاتی روشن می‌شود. سپس، سیر تطور الگوریتم‌ها در سه مقطع مدل‌های قطعی و ریاضی، مدل‌های احتمالی و پویای تقریبی و مدل‌های مبتنی بر یادگیری تقویتی عمیق مورد واکاوی قرار خواهد گرفت. در نهایت، با جمع‌بندی نقاط قوت و ضعف پژوهش‌های موجود، خلأ تحقیقاتی فعلی در متون علمی برجسته شده و ضرورت عبور از مدل‌های تک‌بعدی به سمت طراحی یک معماری هیبریدی^۱، به عنوان ایده و نوآوری محوری این رساله، به اثبات خواهد رسید.

^۱ Hybrid Architecture

۲-۲- مفاهیم پایه‌ای و تفکیک عملیاتی در مدیریت ناوگان اورژانس

پیش از ورود به تحلیل مدل‌های ریاضی و الگوریتم‌های هوش مصنوعی، ضروری است تا مفاهیم بنیادین و شاخص‌های کلیدی که شالوده‌ی ارزیابی سیستم‌های اورژانس را تشکیل می‌دهند، تعریف گردند. درک دقیق این مفاهیم، مرزهای عملیاتی این پژوهش را به روشنی مشخص می‌سازد.

۱-۲-۲- زمان پاسخ‌گویی و مفهوم زمان طلایی

ارزیابی کارایی هر سیستم امدادی، در گرو سنجش دقیق شاخصی به نام زمان پاسخ‌گویی است. زمان پاسخ‌گویی به فاصله زمانی میان دریافت تماس اضطراری در مرکز پیام^۱ تا لحظه رسیدن نیروهای امدادی به بالین بیمار اطلاق می‌گردد. در ادبیات پزشکی اورژانس، مفهومی حیاتی تحت عنوان زمان طلایی وجود دارد که تأکید می‌کند مداخلات درمانی نجات‌بخش (نظیر احیای قلبی-ریوی یا کنترل خونریزی‌های شدید) باید در کوتاه‌ترین زمان ممکن پس از وقوع حادثه (معمولاً کمتر از ۸ الی ۱۰ دقیقه برای حوادث فوق‌اورژانسی) آغاز شوند [۸]. تحقیقات نشان می‌دهد که هر دقیقه تأخیر در این بازه، احتمال زنده ماندن بیمار را به صورت تصاعدی و نمایی کاهش می‌دهد [۱]. از این رو، هدف غایی تمامی رویکردهای بهینه‌سازی ناوگان، بیشینه‌سازی درصد مأموریت‌هایی است که با موفقیت در محدوده زمان طلایی انجام می‌پذیرند.

۲-۲-۲- تفکیک بنیادین: اعزام در برابر استقرار مجدد

یکی از مهم‌ترین چالش‌های مفهومی در توسعه‌ی الگوریتم‌های اورژانس، خلط مبحث میان دو فرآیند عملیاتی کاملاً متمایز اعزام و استقرار مجدد است [۷]. درک تفاوت ماهوی این دو عملیات، سنگ‌بنای طراحی سیستم‌های نوین و هیبریدی به شمار می‌رود.

اعزام، یک واکنش در لحظه و قطعی به حادثه‌ای است که هم‌اکنون رخ داده است. هنگامی که یک بیمار درخواست کمک می‌کند، سیستم باید تصمیم بگیرد که کدام آمبولانس در دسترس را به محل حادثه روانه کند. از منظر تحقیق در عملیات، این فرآیند یک مسئله‌ی مسیریابی قطعی^۲ است که منطق حاکم بر آن،

^۱ Dispatch Center

^۲ Deterministic Routing

انتخاب سریع‌ترین و نزدیک‌ترین وسیله‌ی نقلیه بر اساس وضعیت فعلی شبکه معابر است [۴]. در این فرآیند، فرصتی برای آزمون و خطا وجود ندارد و قابلیت اطمینان و سرعت محاسبات در بالاترین سطح اهمیت قرار دارند.

برخلاف اعزام که ماهیتی واکنشی دارد، استقرار مجدد یک اقدام کاملاً پیشگیرانه و آینده‌نگرانه است. این فرآیند به مدیریت ناوگان آزاد و در حال انتظار اختصاص دارد. هنگامی که یک آمبولانس به مأموریت اعزام می‌شود، منطقه تحت پوشش اولیه آن دچار یک خلأ دفاعی و پوششی می‌گردد. هدف از بازاستقرار، جابه‌جا کردن استراتژیک سایر آمبولانس‌های آزاد به سمت مناطق پرخطر و بی‌دفاع است تا سیستم برای حوادث نامعلوم آینده آماده بماند [۲]. از منظر مدل‌سازی ریاضی، این فرآیند یک مسئله‌ی بهینه‌سازی تصادفی و پویا است که نیازمند درک احتمالات وقوع حادثه، ارزیابی الگوهای ترافیکی آینده و لحاظ نمودن هزینه‌ی جابه‌جایی و استهلاک ناوگان است [۹].

تمایز قائل شدن میان این دو فرآیند، یعنی قطعیت و سادگی در لایه‌ی اعزام، در برابر تصادفی بودن و پیچیدگی استراتژیک در لایه‌ی استقرار مجدد، همان نقطه‌ای است که مسیر رویکردهای کلاسیک را از مدل‌های هوشمند مدرن جدا می‌سازد. در بخش‌های آتی این فصل مشاهده خواهد شد که چگونه مطالعات پیشین در تلاش برای حل یکپارچه و همزمان این دو مسئله‌ی ناهمگون، دچار پیچیدگی‌های عظیم محاسباتی و خطاهای استراتژیک شده‌اند.

۲-۳- رویکردهای قطعی و ایستا^۱

نخستین تلاش‌های سیستماتیک برای بهینه‌سازی و مدیریت ناوگان اورژانس، ریشه در علم تحقیق در عملیات^۲ و مدل‌های ریاضی قطعی دارد [۲]. رویکردهای سنتی در این حوزه عمدتاً بر پروتکل‌های از پیش تعیین‌شده تمرکز داشته‌اند [۱۰] و هدف اصلی آن‌ها یافتن بهترین چیدمان فیزیکی برای پایگاه‌های امدادی بوده است.

^۱ Deterministic & Static Approaches

^۲ Operations Research

سنگ‌بنای این رویکردها، استفاده از مدل‌های برنامه‌ریزی عدد صحیح^۱ برای مدل‌سازی شبکه‌ی اورژانس است. در این راستا، مدل‌های کلاسیکی نظیر مسئله مکان‌یابی پوشش حداکثری^۲ توسعه یافتند [۱۱]. در مدل مسئله مکان‌یابی پوشش حداکثری و توسعه‌های پس از آن، هدف این است که با در اختیار داشتن تعداد محدودی آمبولانس، بیشترین میزان از تقاضای شهری در یک شعاع زمانی مشخص (زمان استاندارد پاسخ‌گویی) تحت پوشش قرار گیرد.

محققان برای اجرای سیاست‌های استقرار مجدد با استفاده از این رویکردها، معمولاً دو مسیر را طی کرده‌اند. رویکرد نخست، حل کردن این برنامه‌های عدد صحیح در یک فاز آماده‌سازی پیش از عملیات^۳ است تا به یک جدول جستجو دست یابند [۱۲]. این جداول به عنوان یک دستورالعمل ثابت به اپراتورها می‌گویند که به ازای در دسترس بودن هر تعداد آمبولانس در لحظه، ناوگان باید در کدام پایگاه‌ها مستقر شود. رویکرد دوم، تلاش برای حل کردن این مدل‌های برنامه‌ریزی عدد صحیح به صورت در لحظه و با وقوع هر رویداد جدید در سیستم است [۴].

با وجود قدرت ریاضی این مدل‌ها در فاز طراحی استراتژیک شبکه، کاربرد آن‌ها به عنوان سیستم تصمیم‌گیر عملیاتی با محدودیت‌های بنیادینی روبه‌رو است که عبور از آن‌ها نیازمند رویکردهای نوین است. یکی از این محدودیت‌ها، فقدان انعطاف‌پذیری در برابر پویایی محیط است. مطالعات سنتی معمولاً بر روی داده‌های شبیه‌سازی ساده اعتبارسنجی شده‌اند و در مواجهه با تغییرات دینامیک دنیای واقعی، بیش از حد ثابت و صلب هستند [۱۰]. این روش‌ها ترافیک شهر، سرعت حرکت و نرخ وقوع حوادث را ثابت فرض می‌کنند، که این امر در کلان‌شهرهای پرتراکم با رژیم‌های ترافیکی متغیر (اوج صبحگاهی و عصرگاهی)، فرضی کاملاً غیرواقع‌بینانه است.

^۱ Integer Programming

^۲ MCLP: Maximal Covering Location Problem

^۳ Preparatory Phase

^۴ Lookup Table

پیچیدگی محاسباتی در لحظه، محدودیتی دیگر است. تلاش برای حل مدل‌های بزرگ برنامه‌ریزی عدد صحیح به صورت در لحظه^۱، از نظر محاسباتی بسیار سنگین و فشرده است [۹]. در یک کلان‌شهر با صدها گره ترافیکی، حل این مدل‌ها عملاً باعث ایجاد تأخیر در تصمیم‌گیری‌های حیاتی می‌شود.

از محدودیت‌های دیگر می‌توان به شکنندگی جداول جستجو اشاره کرد. استفاده از جداول جستجوی از پیش محاسبه‌شده اگرچه مشکل‌گندی محاسبات را حل می‌کند [۱۲]، اما به شدت آسیب‌پذیر است. این جداول قادر به درک شرایط لحظه‌ای ترافیک، مسدود شدن معابر یا وقوع شوک‌های تقاضا نیستند و سیستم را در زمان وقوع بحران‌ها و تصادفات همزمان، دچار اختلال و تصمیمات اشتباه می‌کنند.

در نتیجه، ناتوانی مدل‌های ایستا در پاسخگویی به ذات تصادفی حوادث و ترافیک، محققان را به سمت توسعه‌ی مدل‌های پویا و احتمالی سوق داد که در بخش بعدی مورد بررسی قرار می‌گیرد.

۲-۴- رویکردهای احتمالی و برنامه‌ریزی پویای تقریبی^۲

برای غلبه بر محدودیت‌ها و ضعف‌های مدل‌های قطعی، محققان به سمت مدل‌سازی تصادفی و سیستم‌های پویا حرکت کردند. در این دیدگاه، محیط عملیاتی اورژانس به عنوان یک فرآیند تصمیم‌گیری مارکوف^۳ فرمول‌بندی می‌شود تا بتواند عدم قطعیت در زمان، مکان و شدت بروز حوادث را به درستی درک کند [۱۳]. با این حال، به دلیل حجم عظیم متغیرهای حالت، نظیر موقعیت تمامی آمبولانس‌ها، وضعیت آزاد یا درگیر بودن آن‌ها و زمان‌های سفر، حل دقیق مدل‌های فرآیند تصمیم‌گیری مارکوف در شبکه‌های واقعی و برای ناوگان‌های بزرگ، به دلیل بروز پدیده نفرین ابعاد^۴ از نظر محاسباتی عملاً غیرممکن است [۱۴].

برای دور زدن این محدودیت محاسباتی، استفاده از تکنیک برنامه‌ریزی پویای تقریبی^۵ در دستور کار پژوهشگران قرار گرفت [۱۴]. در مطالعات پیشگامی نظیر پژوهش مکسول و همکاران، از برنامه‌ریزی پویای

^۱ Real-time

^۲ Stochastic Models & ADP

^۳ Markov Decision Process – MDP

^۴ Curse of Dimensionality

^۵ ADP: Approximate Dynamic Programming

تقریبی برای توسعه‌ی سیاست‌های بازاستقرار آمبولانس استفاده شد [۵]. دستاورد و نقطه قوت بسیار مهم در این دسته از پژوهش‌ها، درک درست آن‌ها از تفکیک عملیاتی بود؛ به گونه‌ای که محققان به درستی لایه‌ی اعزام را از استقرار جدا کردند. در این سیستم‌ها، فرآیند اعزام همچنان بر اساس منطق قطعی، ارسال نزدیک‌ترین آمبولانس در دسترس (از نظر زمانی)، صورت می‌گرفت و مدل برنامه‌ریزی پویای تقریبی صرفاً برای تخمین تابع ارزش^۱ و تصمیم‌گیری استراتژیک در خصوص استقرار مجدد ناوگان آزاد به کار گرفته شد. این محققان همچنین با بهره‌گیری از مفهوم وضعیت پس از تصمیم^۲، توانستند نیاز به محاسبه‌ی امید ریاضی در هر گام را حذف کرده و سرعت تصمیم‌گیری را افزایش دهند [۱۵].

علی‌رغم این گام‌های رو به جلو و تفکیک هوشمندانه‌ی لایه‌های عملیاتی، استفاده از معماری برنامه‌ریزی پویای تقریبی در گراف‌های بزرگ و واقعی شهری با محدودیت‌ها و بن‌بست‌های جدی روبه‌رو است که مسیر را برای ورود شبکه‌های عصبی عمیق هموار کرد.

دشواری در طراحی توابع پایه و نفرین ابعاد، یکی از این محدودیت‌هاست. معماری برنامه‌ریزی پویای تقریبی به شدت وابسته به طراحی دستی توابع پایه^۳ است [۱۴]. با بزرگ شدن گراف شهری و افزایش تعداد پایگاه‌ها و آمبولانس‌ها، استخراج این ویژگی‌های دستی به شدت پیچیده شده و سیستم مجدداً در دام نفرین ابعاد گرفتار می‌شود.

یکی دیگر از این بن‌بست‌ها، پیچیدگی و شکست در تنظیم پارامترها^۴ است. تنظیم ضرایب و پارامترهای برنامه‌ریزی پویای تقریبی در محیط‌های پرنوسان بسیار دشوار است [۱۵]. تحقیقات نشان داده‌اند که روش‌های مرسوم تنظیم پارامتر مانند رگرسیون یا برنامه‌ریزی خطی، اغلب در یافتن سیاست بهینه ناکام می‌مانند و حتی اگر معماری برنامه‌ریزی پویای تقریبی قابلیت رسیدن به یک سیاست بهینه را داشته باشد، این الگوریتم‌ها

^۱ Value Function

^۲ Post-decision state

^۳ Basis Functions

^۴ Tuning

ممکن است در تله‌ی سیاست‌های زیربهمینه^۱ گرفتار شوند [۱۵]. استفاده از روش‌های جستجوی مستقیم^۲ برای رفع این مشکل نیز بار محاسباتی عظیمی را به فاز آموزش سیستم تحمیل می‌کند [۱۵].

ناتوانی در سناریوهای بحرانی و مرز اشباع، محدودیتی دیگر است. توابع خطی و تقریب‌های به کار رفته در برنامه‌ریزی پویای تقریبی، ظرفیت لازم برای کشف الگوهای پنهان و غیرخطی ترافیک کلان‌شهرها را ندارند. در سناریوهای بحرانی، نظیر ساعات اوج تقاضا با صدها حادثه همزمان، تنظیم دستی پارامترهای برنامه‌ریزی پویای تقریبی برای پیاده‌سازی مفاهیم پیچیده‌ای نظیر تریاژ مکانی و فدا کردن آگاهانه‌ی برخی گره‌ها جهت حفظ پایداری سیستم، عملاً ناممکن و فاقد کارایی عملیاتی است.

۲-۵- هوش مصنوعی و یادگیری تقویتی عمیق در اورژانس

با ظهور شبکه‌های عصبی عمیق^۳ و اثبات کارایی آن‌ها در حل مسائل پیچیده‌ی دارای فضای حالت پیوسته و بزرگ، مسیر تحقیقات مدیریت ناوگان به سمت استفاده از یادگیری تقویتی عمیق تغییر جهت داد. این رویکردهای نوین با هدف غلبه بر محدودیت‌های روش‌های ریاضی و برنامه‌ریزی پویای تقریبی، تلاش کردند تا الگوهای پنهان و غیرخطی تقاضا و ترافیک شهری را بدون نیاز به طراحی دستی توابع پایه استخراج نمایند. در این راستا، استفاده از الگوریتم‌های مبتنی بر ارزش، نظیر شبکه کیو عمیق^۴ [۱۶] و توسعه‌ی آن‌ها به شبکه‌های چندعاملی^۵ [۱۷]، به لبه‌ی تکنولوژی در این حوزه تبدیل شد.

به عنوان نمونه‌ای بارز از این جریان تحقیقاتی، می‌توان به پژوهش لیو و همکاران اشاره کرد که مسئله‌ی اعزام آمبولانس را در قالب یک چارچوب یادگیری تقویتی چندعاملی فرمول‌بندی نمودند [۱۰]. در این مطالعه، کل نقشه‌ی شهر با استفاده از مستطیل‌هایی به شبکه‌های گرید^۶ تقسیم‌بندی شد. محققان با استفاده از شبکه

¹ Sub-optimal

² Direct Search

³ Deep Neural Networks

⁴ DQN: Deep Q-Network

⁵ Multi-Agent RL

⁶ Grids

Q چندعاملی همراه با تکرار تجربه^۱، تلاش کردند تا عامل‌های هوشمند با یکدیگر همکاری کرده و زمان انتظار کلی بیماران را کاهش دهند [۱۰].

اگرچه استفاده از شبکه‌های عصبی در این مقالات جهش بزرگی در درک پویایی‌های محیطی محسوب می‌شود، اما واکاوی دقیق معماری و مفروضات این سیستم‌ها، نقاط ضعف بنیادین و خطاهای استراتژیکی را آشکار می‌سازد که کارایی آن‌ها را در پیاده‌سازی‌های واقعی به شدت زیر سؤال می‌برد.

بزرگترین نقد وارد بر مطالعات اخیر در حوزه یادگیری تقویتی عمیق، تلاش غیرضروری آن‌ها برای واگذاری تمامی تصمیمات به شبکه عصبی است. به عنوان مثال، در پژوهش لیو و همکاران، هدف الگوریتم هوش مصنوعی صراحتاً تصمیم‌گیری برای اینکه کدام آمبولانس، کدام بیمار را سوار کند^۲ تعریف شده است [۱۰]. همان‌طور که پیش‌تر در بخش مفاهیم پایه اشاره شد، اعزام آمبولانس به بیمار یک مسئله‌ی قطعی مسیریابی است که الگوریتم‌های کلاسیک آن را با قابلیت اطمینان ۱۰۰٪ و در کسری از ثانیه حل می‌کنند [۱۸]. سپردن این وظیفه‌ی قطعی به یک عامل یادگیری تقویتی که ذاتاً تمایل به آزمون و خطا و اکتشاف دارد، نه تنها بار پردازشی سیستم را به شدت افزایش می‌دهد، بلکه می‌تواند منجر به خطاهای فاجعه‌بار تخصیص گردد (نظیر اعزام یک آمبولانس دورتر به جای آمبولانس مجاور به دلیل نوسانات شبکه عصبی).

اکثر مقالات این حوزه، برای تسهیل فرآیند آموزش شبکه‌های عصبی خود، پیچیدگی‌های دنیای واقعی را نادیده گرفته‌اند. این مطالعات نقشه را به شبکه‌های گرید مستطیلی ساده تقسیم می‌کنند و اکشن عامل‌ها را صرفاً رفتن به یک گرید خاص تعریف می‌نمایند [۱۰]. این رویکرد، ساختار واقعی و پیچیده‌ی توپولوژی شهری، شامل بزرگراه‌ها، تقاطع‌های غیرهمسطح، خیابان‌های یک‌طرفه و گره‌های بن‌بست را به طور کامل از بین می‌برد. افزون بر این، فرض ثابت بودن سرعت حرکت در طول شبانه‌روز، ناتوانی این مدل‌ها را در درک نوسانات ترافیکی و شوک‌های دینامیک کلان‌شهرها به همراه دارد.

¹ MAQR: Multi-Agent Q-Network with Experience Replay

² Which ambulance to pick up which patient

طراحی تابع پاداش^۱، قلب تپنده‌ی الگوریتم‌های یادگیری تقویتی است. در بسیاری از این مطالعات، پاداش‌ها صرفاً بر اساس عواملی نظیر تعداد درخواست‌های هر گرید، زمان انتظار بیماران و هزینه زمانی سفر محاسبه می‌شوند. فقدان یک جریمه‌ی ساختاری برای جابه‌جایی‌های بی‌مورد باعث می‌شود که شبکه‌ی عصبی در جستجوی پاداش‌های احتمالی آینده، دائماً آمبولانس‌های آزاد را بین مناطق مختلف جابه‌جا کند. این جابه‌جایی‌های هیجانی و پیوسته که در اصطلاح به آن سرگردانی ناوگان می‌گویند [۵]، در دنیای واقعی منجر به افزایش شدید استهلاک خودروها، خستگی مفرط پرسنل عملیاتی و افزایش احتمال تصادفات در حین بازاستقرار می‌گردد.

۲-۶- تبیین خلأ تحقیقاتی و معرفی رویکرد هیبریدی^۲

مرور تحلیلی و انتقادی ادبیات تحقیق در بخش‌های پیشین، یک تقابل روش‌شناختی آشکار را در حوزه مدیریت اورژانس نمایان می‌سازد. از یک سو، مدل‌های کلاسیک تحقیق در عملیات و برنامه‌ریزی پویای تقریبی [۱۴، ۱۵]، علی‌رغم درک درست از منطق اعزام، در مواجهه با محیط‌های پویای کلان‌شهرها برای عملیات استقرار مجدد به شدت کُند و شکننده بوده و در دام پیچیدگی محاسباتی گرفتار می‌شوند. از سوی دیگر، مطالعات نوین مبتنی بر یادگیری تقویتی عمیق نیز با اتخاذ رویکردهای افراطی سرتاسری و تلاش برای واگذاری تمامی تصمیمات از جمله تخصیص قطعی بیمار به آمبولانس، به شبکه‌های عصبی [۱۰]، دچار خطاهای منطقی، افزایش بار پردازشی و ایجاد پدیده‌ی مخرب سرگردانی ناوگان شده‌اند.

با توجه به این بن‌بست علمی، خلأ یک معماری هیبریدی در متون پژوهشی به شدت احساس می‌شود؛ معماری نوآورانه‌ای که به جای اصرار بر استفاده‌ی مطلق از یک روش خاص، بهترین و پایدارترین ویژگی‌های هر دو پارادایم را با یکدیگر ترکیب نماید. بر این اساس، ساختار چنین رویکرد هیبریدی‌ای باید دارای دو لایه‌ی عملیاتی کاملاً مجزا و تخصصی باشد.

^۱ Reward Function

^۲ Research Gap & Hybrid Approach

لایه‌ی اعزام قطعی^۱ که فرآیند حیاتی و حساس پاسخ‌گویی به حوادث رخ داده را از دوش عامل هوش مصنوعی برداشته و آن را به الگوریتم‌های قطعی مسیریابی واگذار می‌کند. با تکیه بر منطق کمترین زمان سفر در لحظه^۲، تخصیص آمبولانس به بیمار بدون هیچ‌گونه آزمون و خطا، با قابلیت اطمینان ۱۰۰٪ و در کسری از ثانیه انجام می‌پذیرد تا ریسک خطاهای بالینی به صفر برسد.

لایه‌ی استقرار هوشمند و پیشگیرانه^۳ که مدیریت استراتژیک ناوگان آزاد را بر عهده گرفته و منحصراً توسط الگوریتم‌های لبه‌ی تکنولوژی یادگیری تقویتی مبتنی بر سیاست، نظیر PPO [۶] هدایت می‌شود. این عامل هوشمند به گونه‌ای آموزش می‌بیند که با درک عمیق از توپولوژی واقعی گراف شهر و نوسانات ترافیک پویا، خلأهای پوششی را پیش‌بینی نماید. افزون بر این، با طراحی هوشمندانه‌ی تابع پاداش، هزینه‌ی فیزیکی جابه‌جایی‌ها لحاظ شده و با اعمال استراتژی خویشتن‌داری، از بروز پدیده‌ی استهلاک‌آور سرگردانی ناوگان به طور کامل جلوگیری می‌گردد.

با در نظر گرفتن محدودیت‌های بنیادین مدل‌های پیشین و نیاز مبرم سیستم‌های بهداشت و درمان به یک سیستم پشتیبان تصمیم واقع‌گرایانه و قابل‌اجرا، رساله‌ی حاضر دقیقاً برای پر کردن همین شکاف علمی تدوین شده است. طراحی، توسعه و شبیه‌سازی این عامل تصمیم‌گیر هیبریدی بر روی گراف ترافیکی کلان‌شهر تهران، نه تنها محدودیت‌های الگوریتم‌های پیشین را برطرف می‌سازد، بلکه گامی نوین در جهت پیوند قابلیت اطمینان ریاضیات با هوشمندی شبکه‌های عصبی عمیق به شمار می‌رود.

¹ Deterministic Dispatch Layer

² Shortest Dynamic Travel Time

³ Intelligent Relocation Layer

فصل ۳- مدل سازی ریاضی و روش شناسی تحقیق

۳-۱- مقدمه

محیط های شهری پرتراکم، سیستم های پیچیده و غیرقطعی هستند که مدیریت منابع حیاتی در آنها با چالش های متعددی از جمله نوسانات ترافیکی، توزیع تصادفی تقاضا و استهلاك تجهیزات مواجه است. هدف از این فصل، ارائه یک چارچوب جامع و فرمول بندی دقیق ریاضی برای مدل سازی عملیات اورژانس پیش بیمارستانی در چنین محیطی است [۱۹]. به این منظور، ضمن در نظر گرفتن کلان شهر تهران به عنوان مقیاس و مبنای شبیه سازی، پویایی های سیستم به صورت یک فرآیند تصمیم گیری مارکوف فرمول بندی شده است [۱۳]. در ادامه، اجزای مختلف مدل اعم از ساختار گراف شهری، مدل ترافیک پویا، نرخ های متغیر تقاضا، منطق عملیاتی اعزام، و در نهایت معماری الگوریتم های یادگیری تقویتی عمیق مورد استفاده در این پژوهش [۳] به تفصیل تشریح می گردند.

۳-۲- چارچوب کلی سیستم پیشنهادی

سیستم پیشنهادی در این پژوهش یک معماری هیبریدی برای مدیریت ناوگان آمبولانس ها ارائه می دهد. منظور از معماری هیبریدی آن است که تمام تصمیمات عملیاتی سیستم به یک عامل یادگیری تقویتی واگذار نمی شود، بلکه هر نوع تصمیم با توجه به ماهیت و حساسیت زمانی آن، به سازوکار مناسب سپرده می شود [۷].

در عملیات اورژانس، تصمیم اعزام ماهیتی فوری دارد. هنگامی که حادثه ای رخ می دهد، سیستم باید در کوتاه ترین زمان ممکن یک آمبولانس مناسب را انتخاب کند. تأخیر در چنین تصمیمی می تواند مستقیماً باعث افزایش زمان پاسخ شود. به همین دلیل، در این پژوهش اعزام آمبولانس به صورت واکنشی و با استفاده

از یک سیاست حریصانه انجام می‌شود [۴]. این سیاست، نزدیک‌ترین آمبولانس آزاد را بر اساس زمان سفر لحظه‌ای در شبکه انتخاب می‌کند [۲۰].

در مقابل، تصمیم استقرار مجدد ماهیتی پیشگیرانه دارد. این تصمیم به یک حادثه مشخص پاسخ نمی‌دهد، بلکه تلاش می‌کند آرایش آمبولانس‌ها را به گونه‌ای تنظیم کند که در آینده پوشش مناسبی در سطح شهر برقرار باشد [۹]. از آنجا که تصمیم استقرار مجدد به وضعیت کلی سیستم، ترافیک، نسبت آمبولانس‌های آزاد و الگوی پوشش وابسته است، می‌توان آن را به عنوان یک مسئله تصمیم‌گیری متوالی و بلندمدت در نظر گرفت [۵]. در این بخش، عامل یادگیری تقویتی با مشاهده وضعیت محیط، مقصد مناسب برای جابه‌جایی آمبولانس را انتخاب می‌کند.

بر این اساس، سیستم از دو لایه اصلی تشکیل می‌شود.

لایه واکنشی اعزام که در زمان وقوع حادثه فعال می‌شود. وظیفه آن تشکیل صف حوادث، اولویت‌بندی حوادث و اختصاص آمبولانس آزاد به حادثه‌ای است که در صدر صف قرار دارد. معیار انتخاب آمبولانس، کمینه کردن زمان سفر از محل فعلی آمبولانس تا محل حادثه است [۱۸].

لایه پیشگیرانه استقرار مجدد که در فاصله میان مأموریت‌ها یا در زمان‌هایی که آمبولانس آزاد وجود دارد، فعالیت می‌کند. عامل یادگیری تقویتی تلاش می‌کند با استفاده از اطلاعات مربوط به زمان، ترافیک، ظرفیت آزاد ناوگان و پوشش گره‌های شهری، آمبولانس‌ها را به نقاطی منتقل کند که احتمال ایجاد خلأ پوششی در آن‌ها بیشتر است [۶].

این تفکیک باعث می‌شود که عامل یادگیری تقویتی مستقیماً با تصمیم اضطراری و حساس اعزام تداخل نداشته باشد. به بیان دیگر، لایه اعزام وظیفه پاسخ سریع به تقاضای موجود را بر عهده دارد، در حالی که عامل یادگیری تقویتی با نگاه آینده‌نگر، برای بهبود آمادگی شبکه در برابر تقاضاهای بعدی تصمیم‌گیری می‌کند.

۳-۳- مدل سازی محیط شهری

۳-۳-۱- شبکه ارتباطی و گراف شهر

برای نمایش ساختار فضایی شهر، محیط شهری به صورت یک گراف جهت دار و وزن دار تعریف می شود

[۲۱]:


$$G = (V, E) \quad (۱-۳)$$

در این رابطه، V مجموعه گره ها و E مجموعه یال های شبکه است. گره ها نماینده ناحیه های مختلف شهر و پایگاه های اورژانس هستند. یال ها نیز مسیرهای ارتباطی میان این نقاط را نمایش می دهند. در واقع گره ها به دو گروه اصلی تقسیم می شوند:

$$V = V_S \cup V_D \quad (۲-۳)$$

در این رابطه، V_S مجموعه گره های مربوط به پایگاه های ثابت اورژانس (۲۹ عدد) و V_D مجموعه گره های تقاضا (۵۶ عدد) است. گره های تقاضا می توانند نماینده مناطق مسکونی، تجاری، تقاطع ها، محله ها یا سایر نقاطی باشند که احتمال وقوع حادثه در آن ها وجود دارد [۲۱].

مجموعه یال ها، E ، نشان دهنده مسیرهای مواصلاتی، بزرگراه ها و خیابان های متصل کننده گره ها است. در این شبکه، ارتباطات بین گره ها بر اساس توپولوژی مسیرهای واقعی و محدودیت های فواصل طراحی شده است.



شکل ۳-۱: گراف ساده‌شده شهر تهران

۳-۳-۲- وزن‌دهی یال‌ها و زمان سفر پایه

به هر یال $e_{ij} \in E$ یک زمان سفر پایه (t_{ij}^{base}) اختصاص داده شده است. این مقدار، نشان‌دهنده مدت زمان عبور یک آمبولانس با سرعت ثابت و استاندارد ۷۰ کیلومتر بر ساعت در شرایط خلأ ترافیکی است. این عدد یکی از فرضیات پژوهش من است.

علاوه بر زمان پایه، به هر مسیر یک ضریب احتقان پایه (c_{ij}^{base}) اختصاص یافته است که نشان‌دهنده استعداد آن مسیر برای درگیر شدن در گره‌های ترافیکی است. بر اساس مشاهدات، اخبار خبرگزاری‌ها و داده‌های نسبی از وضعیت ترافیک کلان‌شهر تهران، این ضرایب به صورت زیر دسته‌بندی و روی یال‌های گراف اعمال شده‌اند [۲۲]:

- بزرگراه‌های اصلی: $c^{base} = 1.0$ (بیشترین استعداد قفل شدن در ساعات پیک به دلیل حجم بالای تردد خودروها).

- محدوده مرکزی شهر: $c^{base} = 0.85$ (محدوده‌های دارای طرح ترافیک، مراکز تجاری و تراکم بالای فعالیت).

- بزرگراه های رابط و کمربندی ها: $c^{base} = 0.6$
- خیابان های فرعی و محلی: $c^{base} = 0.3$ (مسیرهایی که کمتر تحت تأثیر ترافیک عبوری قرار می گیرند).

۳-۳-۳- ترافیک پویا و زمان سفر لحظه ای

ترافیک در شهرهای بزرگ یک پدیده کاملاً وابسته به زمان است [۲۲]. در این پژوهش، زمان شبیه سازی ۲۴ ساعت (۱۴۴۰ دقیقه) است و برای اعمال الگوهای ترافیکی، یک ضریب فزاینده زمانی با نماد $M(h)$ تعریف شده است که h تا ۲۴ ساعت روز را نشان می دهد.

بار ترافیکی مؤثر بر روی هر یال در لحظه t به صورت زیر محاسبه می گردد:

$$C_{ij}(t) = c^{base}_{ij} \times M(h) \quad (3-3)$$

با توجه به شدت ترافیک مؤثر $C_{ij}(t)$ ، زمان سفر واقعی آمبولانس در مسیر e_{ij} در لحظه t ($T_{ij}(t)$)، به صورت یک تابع چندضابطه ای مدل سازی شده است تا تأثیر ترافیک های سنگین به شکل تصاعدی و غیرخطی بر کندی ناوگان اعمال شود [۲۲]:

$$T_{ij}(t) = f(x) = \begin{cases} t_{ij}^{base} (1 + C_{ij}(t)). & C_{ij}(t) < 0.4 \text{ (ترافیک سبک)} \\ t_{ij}^{base} (2 + C_{ij}(t)). & 0.4 \leq C_{ij}(t) < 0.6 \text{ (ترافیک معمولی)} \\ t_{ij}^{base} (3 + C_{ij}(t)). & C_{ij}(t) \geq 0.6 \text{ (ترافیک سنگین)} \end{cases} \quad (4-3)$$

در هر لحظه، زمان سفر مسیرها بر اساس وزن های جاری گراف محاسبه می شود. سپس برای انتخاب مسیر یا نزدیک ترین آمبولانس، کوتاه ترین مسیر موجود در شبکه زمان متغیر مورد استفاده قرار می گیرد [۱۸].

۳-۳-۴- تولید مکانی-زمانی حوادث

فرآیند ایجاد تماس ها با مرکز اورژانس بر اساس فرآیند تصادفی پواسون^۱ شبیه سازی شده است [۲۳]. در این مدل، نرخ متوسط وقوع حوادث کل شهر ($\lambda_{city}(t)$) بر اساس ساعت روز متغیر است (که در بخش ۳-۷ به تفصیل بیان می شود).

¹ Poisson Process

برای مدل‌سازی توزیع نامتقارن مکانی، به هر گره تقاضا $i \in V_D$ یک وزن مکانی w_i اختصاص داده شده است. با بهره‌گیری از دانش شهری و تطابق با الگوی حوادث کلان‌شهر، گره‌های مشخصی شامل $(n_{12}, n_{13}, n_{19}, n_{24}, n_{25}, n_{26}, n_{31}, n_{43}, n_{45})$ به عنوان گره‌های پرخطر^۱ تعیین شده‌اند که نمایانگر میادین اصلی، تقاطع‌های پرخطر و مراکز تجمع انسانی هستند [۲۴]. وزن این گره‌ها با ضریب ۱٫۸ در نظر گرفته شده (w_i) $(= 1.8)$ در حالی که برای سایر گره‌ها $w_i = 1.0$ است.

نرخ امید ریاضی وقوع حادثه در گره i در هر دقیقه (t) به صورت زیر محاسبه می‌شود:

$$\lambda_i(t) = \lambda_{city}(t) \frac{w_i}{\sum_{j \in V_D} w_j} \quad (5-3)$$

سپس تعداد حوادث ایجاد شده در گره i از توزیع $Poisson(\lambda_i(t))$ استخراج می‌شود.

۳-۳-۵- شدت حادثه و مهلت پاسخ

پس از تولید هر حادثه، میزان وخامت آن به صورت تصادفی مشخص می‌شود. حوادث به دو دسته تقسیم می‌گردند [۲۵].

حوادث شدید^۲ که به مداخلات حیاتی (مانند احیای قلبی ریوی یا تروما) نیاز دارند و مهلت پاسخ برای آن‌ها (t_{dead}) ، ۸ دقیقه در نظر گرفته شده است [۱].

حوادث خفیف^۳ با فوریت کمتر که مهلت پاسخ برای آن‌ها (t_{dead}) ، ۱۲ دقیقه است [۲۵].

لازم به ذکر است که احتمال وقوع حوادث شدید در شرایط عادی ۰/۳۵ و در روزهای تعطیل (به دلیل ماهیت تصادفات جاده‌ای پرخطرتر) برابر ۰/۵۵ لحاظ شده است.

۳-۳-۶- مدل ناوگان و وضعیت آمبولانس‌ها

ناوگان اورژانس شامل مجموعه‌ای از آمبولانس‌ها $A = \{a_1, a_2, \dots, a_k\}$ (در این پژوهش ۳۹ دستگاه آمبولانس در سطح گراف) است. هر آمبولانس a_k در هر لحظه در یکی از چهار وضعیت زیر قرار دارد [۲۶]:

^۱ Hotspots

^۲ Severe

^۳ Mild

- آزاد^۱: مستقر در پایگاه یا یک گره و آماده دریافت مأموریت.
 - درگیر^۲: در حال عزیمت به صحنه یا در حال ارائه خدمات درمانی در محل.
 - استقرار مجدد^۳: در حال حرکت از یک گره به گره دیگر با هدف بهبود پوشش شهر.
 - خارج از سرویس^۴: مواجهه با استهلاک یا خرابی و عدم امکان خدمت رسانی.
- این وضعیت ها در طول شبیه سازی به صورت پویا تغییر می کنند و بخشی از پویایی تابع انتقال محیط را تشکیل می دهند.

۳-۳-۷- خدمت رسانی، خرابی، بازگشت شبانه

زمان خدمت رسانی: پس از رسیدن آمبولانس به گره حادثه، زمان ارائه خدمات بالینی متغیر بوده و از توزیع یکنواخت S بین ۲۵ تا ۴۰ دقیقه پیروی می کند [۲۷]. استفاده از این توزیع باعث می شود مدت خدمت در همه مأموریت ها ثابت نباشد و تفاوت طبیعی میان عملیات مختلف در محیط ایجاد شود.

استهلاک و خرابی: آمبولانس های آزاد در هر دقیقه با احتمال $P_{breakdown} = 0.0005$ دچار نقص فنی یا نیازمند تعویض شیفِت تکنسین می شوند و برای مدت ۳۰ تا ۴۰ دقیقه از مدار خدمت خارج می شوند [۲۷]. این سازوکار باعث می شود ظرفیت مؤثر ناوگان در طول روز ثابت نباشد و سیستم مجبور شود تصمیمات اعزام و استقرار مجدد را در شرایطی اتخاذ کند که بخشی از منابع ممکن است موقتاً در دسترس نباشند.

بازگشت شبانه: در پایان هر روز (دقیقه ۰۰:۰۰)، تمامی آمبولانس هایی که در گره های غیر از پایگاه اصلی خود متوقف هستند، به صورت سیستمی دستور بازگشت به ایستگاه مادر را دریافت می کنند تا آماده سازی و تجدید قوا صورت پذیرد. این فرآیند موجب می شود وضعیت مکانی ناوگان در ابتدای هر روز از یک آرایش مشخص و قابل کنترل آغاز شود.

¹ Free

² Busy

³ Relocating

⁴ Out of Service

۳-۳-۸- منابع عدم قطعیت در محیط شبیه‌سازی

محیط طراحی شده در این پژوهش، یک محیط قطعی نیست؛ بلکه چند منبع مستقل و وابسته از عدم قطعیت را هم‌زمان در خود جای می‌دهد [۷]. نخستین منبع، ورود تصادفی حوادث است که با فرآیند پواسون مدل می‌شود. در نتیجه، زمان و تعداد حوادث در هر دقیقه از پیش به‌طور کامل مشخص نیست.

منبع دوم، مکان وقوع حوادث است. اگرچه گره‌های پرخطر نرخ بالاتری دارند، وقوع حادثه در آن‌ها قطعی نیست و تعداد حوادث هر گره نیز از توزیع پواسون استخراج می‌شود.

منبع سوم، شدت حادثه است که به‌صورت تصادفی تعیین شده و مهلت پاسخ متفاوتی برای هر کلاس ایجاد می‌کند.

منبع چهارم، زمان خدمت‌رسانی است که از توزیع یکنواخت نمونه‌برداری می‌شود. بنابراین مدت درگیری آمبولانس پس از رسیدن به محل حادثه ثابت نیست. منبع پنجم نیز خرابی احتمالی آمبولانس‌هاست که ظرفیت واقعی ناوگان را در هر لحظه تغییر می‌دهد [۲۸].

در کنار این موارد، زمان سفر نیز به‌دلیل تغییرات ترافیکی وابسته به زمان است. بنابراین، عدم قطعیت محیط تنها ناشی از یک متغیر تصادفی نیست، بلکه حاصل برهم‌کنش چند فرایند است [۲۸].

عدم قطعیت = ورود تصادفی حادثه + مکان وقوع حادثه + شدت حادثه + زمان خدمت‌رسانی + خرابی احتمالی آمبولانس‌ها + تغییرات ترافیکی.

این ویژگی سبب می‌شود که یک تصمیم استقرار مجدد در یک وضعیت مشخص، الزاماً در همه اجراهای شبیه‌سازی نتیجه یکسانی ایجاد نکند. به همین دلیل، عامل یادگیری تقویتی باید به‌جای یادگیری یک پاسخ ثابت، سیاستی را بیاموزد که در برابر طیفی از وضعیت‌های احتمالی عملکرد مناسبی داشته باشد.

۳-۴- منطق عملیاتی سیستم

۳-۴-۱- تشکیل صف حوادث

هر حادثه پس از تولید، در صورتی که آمبولانس آزاد برای اعزام فوری وجود نداشته باشد، وارد صف انتظار می شود. صف حوادث یک ساختار ایستا نیست و در هر گام زمانی با ورود حوادث جدید، رسیدگی به حوادث قبلی و تغییر وضعیت آمبولانس ها به روزرسانی می شود.

برای اولویت دهی، ابتدا شدت حادثه و سپس زمان انتظار در نظر گرفته می شود. به این ترتیب، حادثه شدید نسبت به حادثه خفیف در اولویت بالاتری قرار دارد و در میان حوادث هم سطح، حادثه ای که زودتر وارد صف شده است، زودتر بررسی می شود [۲۹].

این ترتیب، یک سازوکار ساده اما مهم برای پیاده سازی اولویت پزشکی در سیستم است؛ زیرا در شرایط کمبود منابع، پاسخ گویی به همه حوادث به صورت هم زمان امکان پذیر نیست و سیستم باید منابع محدود خود را ابتدا به حوادثی اختصاص دهد که تأخیر در آن ها پیامد شدیدتری دارد [۲۹].

۳-۴-۲- سیاست اعزام حریصانه

هنگامی که یک حادثه در صدر صف قرار می گیرد، مجموعه آمبولانس های آزاد بررسی می شود. برای هر آمبولانس آزاد، زمان سفر از موقعیت فعلی آن تا محل حادثه محاسبه می گردد. آمبولانسی انتخاب می شود که کمترین زمان سفر را داشته باشد (مبتنی بر منطق الگوریتم های Dijkstra / A* search) [۱۸]:

$$a^* = \arg \min_{a \in A_{free}} T_{path} \in (a_{loc}, i_{loc}) \quad (۳-۶)$$

در این رابطه، A_{free} مجموعه آمبولانس های آزاد، a_{loc} موقعیت آمبولانس، i_{loc} موقعیت حادثه است. تابع

T_{path} زمان کوتاه ترین مسیر در گراف جاری را نشان می دهد.

از آنجا که وزن یال ها تابع زمان هستند، مسیر بهینه ممکن است در ساعات مختلف روز تغییر کند. پس وزن مسیرها در زمان وقوع حادثه به روزرسانی شده و کوتاه ترین مسیر پویا بین محل استقرار آمبولانس ها و محل حادثه استخراج می گردد [۲۰]. بنابراین، نزدیک ترین آمبولانس صرفاً آمبولانسی نیست که از نظر فاصله

هندسی نزدیک‌تر باشد؛ بلکه آمبولانسی است که کمترین زمان سفر مورد انتظار را در شرایط ترافیکی فعلی داشته باشد.

در صورت یافتن مسیر، آمبولانس a^* به وضعیت درگیر درآمده و به محل گسیل می‌شود.

۳-۴-۳- محاسبه زمان پاسخ

زمان پاسخ‌گویی برای هر حادثه از لحظه ثبت تماس تا زمان رسیدن فیزیکی آمبولانس به گره تقاضا محاسبه می‌گردد. اگر $t_{created}$ زمان تولید حادثه و $t_{arrival}$ زمان رسیدن آمبولانس باشد:

$$t_{resp} = t_{arrival} - t_{created} \quad (۷-۳)$$

در صورتی که $t_{resp} \leq t_{dead}$ باشد، مأموریت به عنوان پاسخ موفق و به موقع^۱ ثبت می‌گردد [۲۵].

۳-۴-۴- سیاست بازاستقراری قانون‌محور در روش‌های پایه

در سناریوهای پایه (مبتنی بر منطق سنتی بدون هوش مصنوعی)، تصمیمات استقرار مجدد بر اساس یک قانون مکاشفه‌ای انجام می‌شود. در این قانون، سیستم بررسی می‌کند که آیا محله‌ای وجود دارد که از پوشش ۸ دقیقه‌ای تمامی آمبولانس‌های آزاد خارج شده باشد^۲. در این صورت، نزدیک‌ترین آمبولانس آزاد را به شرطی که به آن سمت هدایت می‌کند که با رفتن آن آمبولانس، محله فعلی‌اش دچار خلأ پوششی نگردد^۳ [۳۰]. این مکانیزم برای مقایسه با استقرارهای پیشگیرانه شبکه عصبی تعبیه شده است.

۳-۴-۵- چرایی معماری هیبریدی

جداکردن اعزام و استقرار مجدد، یک تصمیم صرفاً پیاده‌سازی نیست، بلکه از ماهیت متفاوت این دو مسئله ناشی می‌شود [۷]. اعزام، تصمیمی فوری، محلی و پاسخ‌محور است؛ زیرا یک حادثه مشخص رخ داده و سیستم باید در کوتاه‌ترین زمان، یک آمبولانس را به آن اختصاص دهد. در مقابل، استقرار مجدد تصمیمی آینده‌نگر است که باید اثر آن بر پوشش مناطق، دسترسی آتی و آمادگی شبکه را در نظر بگیرد.

^۱ On-Time

^۲ Logically Uncovered

^۳ Safe Relocation

اگر هر دو تصمیم به صورت همزمان به عامل یادگیری تقویتی واگذار شوند، فضای عمل و پیچیدگی یادگیری افزایش پیدا می کند. علاوه بر آن، عامل ممکن است برای بهبود یک شاخص بلندمدت، در تصمیم اعزام فوری رفتاری اتخاذ کند که با الزامات زمان حساس اورژانس سازگار نباشد [۱۰]. معماری هیبریدی این مشکل را کاهش می دهد: اعزام با یک سیاست سریع و قابل تفسیر انجام می شود و یادگیری تقویتی تنها در بخش استقرار مجدد، جایی که تصمیم گیری متوالی و بلندمدت اهمیت بیشتری دارد، به کار گرفته می شود.

۳-۵- فرمول بندی مسئله به صورت فرآیند تصمیم گیری مارکوف

برای حل هوشمندانه مسئله تخصیص و استقرار ناوگان، پویایی های مسئله به شکل یک فرآیند تصمیم گیری مارکوف شامل یک ۵ تایی $M=(S,A,P,R,\gamma)$ فرمول بندی شده است [۱۳].

۳-۵-۱- فضای حالت

در تئوری، فضای حالت کامل سیستم اورژانس شامل متغیرهای بسیار متعددی از جمله موقعیت دقیق جغرافیایی تک تک آمبولانس ها، وضعیت فعلی آن ها، فهرست کامل حوادث فعال، صف انتظار و اولویت بیماران است. با این حال، استفاده مستقیم از فضای حالت کامل در آموزش شبکه های عصبی یادگیری تقویتی، منجر به بروز پدیده نفرین ابعاد گردیده و فرآیند همگرایی الگوریتم را به شدت کند یا غیرممکن می سازد [۱۴]. علاوه بر این، با توجه به اتخاذ معماری هیبریدی در این پژوهش که در آن لایه واکنشی (اعزام) توسط الگوریتم مکاشفه ای صورت می پذیرد، عامل هوشمند منحصراً نیازمند درک تصویر کلان از وضعیت پوشش شهر برای اتخاذ تصمیمات پیشگیرانه است.

به همین منظور، از تکنیک انتزاع فضای حالت^۱ و مهندسی ویژگی استفاده شده است [۳۱]. بردار حالت $s_t \in S$ مشاهدات فشرده سازی شده عامل را از شهر نشان می دهد. این بردار با ابعاد $|V| + 3$ تعریف شده و برای تضمین پایداری در یادگیری شبکه عصبی، تمامی عناصر آن در بازه $[0, 1]$ نرمال سازی شده اند:

$$s_t = [\tau_t, M_t, \rho_t, c_{1,t}, c_{2,t}, \dots, c_{3,t}]^T \quad (۳-۸)$$

^۱ State Abstraction

اجزای این بردار عبارتند از:

τ_t : زمان نرمال‌شده‌ی روز (از ۰ تا ۱) که به عامل کمک می‌کند الگوهای زمانی و پیک‌های تقاضا را

$$\tau_t = \frac{t - t_{start}}{T_{total}} \text{ پیش‌بینی کند.}$$

M_t : ضریب ترافیک لحظه‌ای شهر برای درک وضعیت تراکم معابر.

p_t : نسبت ناوگان آزاد؛ نشان‌دهنده درصد آمبولانس‌هایی است که در لحظه t هیچ مأموریتی ندارند و

نشان‌دهنده توان عملیاتی باقی‌مانده سیستم است.

$c_{i,t}$: وضعیت پوشش گره i (مقدار ۱ نشان‌دهنده آن است که گره تحت پوشش زیر ۸ دقیقه‌ی یکی از

آمبولانس‌های آزاد یا در حال استقرار است و ۰ در غیر این صورت).

۳-۵-۲- فضای عمل

فضای عمل عامل هوشمند به صورت گسسته $A = \{1, 2, \dots, |V| + 1\}$ تعریف شده است. عامل در هر

گام زمانی یک گره هدف را برای استقرار آمبولانس انتخاب می‌کند.

عمل $a_t \leq |V|$ به معنای دستور استقرار نزدیک‌ترین آمبولانس آزاد، بر اساس زمان کوتاه‌ترین مسیر در

گراف جاری، به گره a_t است و عمل $a_t = |V| + 1$ به معنای هیچ‌کاری نکن بوده و آرایش ناوگان را حفظ

می‌کند [۳۲].

این عمل تنها در بازه زمانی روز، یعنی زمانی که $6 \leq \text{hour} < 24$ است، فعال می‌شود. خارج از این بازه،

عمل عامل به صورت ضمنی بی‌اثر است. همچنین در صورتی که هیچ آمبولانس آزادی وجود نداشته باشد یا

آمبولانس از قبل در گره هدف قرار گرفته باشد، عمل اجراشده تغییری در محیط ایجاد نمی‌کند.

۳-۵-۳- تابع انتقال

با توجه به ماهیت متغیر محیط (ترافیک پویا)، تصادفی بودن توزیع پواسون برای حوادث و احتمالات

خرابی تجهیزات، تابع انتقال محیط $P(s_{t+1} | s_t, a_t)$ یک تابع کاملاً تصادفی است که محاسبه قطعی آن غیرممکن

بوده و نیازمند استفاده از روش‌های یادگیری بدون مدل می‌باشد [۳].

۳-۵-۴- تابع پاداش

برای تریاژ بیماران و هدایت عامل، وزن حادثه شدید $w_{severe} = 10.0$ و حادثه خفیف $w_{mild} = 1.0$ در نظر گرفته شد.

طراحی این تابع بر اساس منطق شکل دهی پاداش^۱ انجام شده است تا عامل، همزمان به اهداف متضاد سیستم دست یابد [۳۳]. پاداش در هر گام (r_t) از مجموع توابع زیر حاصل می شود:

- پاداش رسیدن به بالین بیمار / مجروح:

$$R_{arrival} = \begin{cases} +100w & \text{if } t_{resp} \leq t_{dead} \\ -100w - 50w \frac{(t_{resp} - t_{dead})}{t_{dead}} & \text{if } t_{resp} > t_{dead} \end{cases} \quad (۹-۳)$$

- جریمه زمان انتظار حوادث در صف:

$$R_{waiting} = -2.0 \sum_{i \in \text{Waiting}} w_i \quad (۱۰-۳)$$

- جریمه از دست رفتن پوشش استراتژیک:

$$R_{coverage} = -10.0 \times \sum_{j=1}^{|V_D|} (1 - c_{j,t}) \quad (۱۱-۳)$$

- هزینه عملیاتی جابه جایی و استهلاک:

$$R_{relocate} = -0.15 \times N(\text{Relocation Action}) \quad (۱۲-۳)$$

- جریمه رها کردن حادثه بی پاسخ تا پایان روز:

$$R_{unserved} = -500.0 \sum_{i \in \text{unserved}} w_i \quad (۱۳-۳)$$

در نتیجه:

$$r_t = R_{arrival} + R_{waiting} + R_{coverage} + R_{relocate} + R_{unserved} \quad (۱۴-۳)$$

^۱ Reward Shaping

۳-۵-۵- ضریب تنزیل و هدف یادگیری

هدف مدل در این MDP، یافتن یک سیاست بهینه π^* است که امید ریاضی مجموع پاداش‌های تنزیل‌شده را بیشینه نماید [۱۳]:

$$\max_{\pi} E_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t r_t \right] \quad (۱۵-۳)$$

در این پژوهش، از ضریب تنزیل استاندارد $\gamma = 0.99$ استفاده شده است تا هم پاداش‌های آنی و هم پاداش‌های آتی لحاظ شوند [۳].

۳-۶-۳ PPO و فرایند آموزش

۳-۶-۳-۱ مبانی PPO

الگوریتم PPO یکی از پیشرفته‌ترین الگوریتم‌های خانواده Actor-Critic در یادگیری تقویتی عمیق است [۶]. این الگوریتم با محدود کردن گام‌های به‌روزرسانی سیاست، پایداری در یادگیری را به شدت افزایش داده و از نوسانات مخرب در شبکه عصبی جلوگیری می‌کند. PPO برای فضاهای حالت با ابعاد بالا، نمونه‌برداری کارآمدتری نسبت به الگوریتم‌های سنتی دارد.

۳-۶-۳-۲ تابع هدف PPO

این الگوریتم برای حفظ سیاست جدید در مجاورت سیاست قبلی، از تابع هدف برش‌یافته^۱ به شکل زیر استفاده می‌کند [۶]:

$$L^{\text{CLIP}}(\theta) = \hat{E}_t [\min(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t)] \quad (۱۶-۳)$$

که در آن $r_t(\theta)$ نسبت احتمال انتخاب عمل در سیاست جدید به سیاست قدیم، $\hat{A}_t$ تابع مزیت و ϵ پارامتر برش است.

^۱ Clipped Surrogate Objective

۳-۶-۳- تنظیمات آموزش

معماری مدل سازی شده توسط یک شبکه عصبی پرسپترون چندلایه آموزش داده شده است. تنظیمات^۱ اعمال شده شامل نرخ یادگیری^۲ برابر با ۰,۰۰۰۳، اندازه دسته^۳ برابر با ۶۴ و طول افق جمع آوری داده^۴ برابر با ۲۰۴۸ می باشد [۳۴]. فرآیند آموزش برای دستیابی به همگرایی مطلوب، طی ۱,۵۰۰,۰۰۰ گام تعامل با محیط انجام پذیرفته است.

۳-۷- تعریف روش ها و حالات تقاضا

به منظور ارزیابی جامع سیستم، عملکرد آن در سه روش و سه حالت مختلف تقاضا شبیه سازی و مورد مقایسه قرار گرفته است.

۳-۷-۱- روش اول: خط مبنا بدون ترافیک

این روش نمایانگر ساده ترین شکل از محیط شهری است. در این حالت، گراف شهر کاملاً ایستا در نظر گرفته شده و زمان های سفر صرفاً بر اساس فاصله و بدون اعمال ضرایب ترافیکی یا خرابی آمبولانس ها محاسبه می شوند. این سناریو به عنوان معیاری برای مقایسه افت عملکرد در شرایط واقعی تدوین شده است.

۳-۷-۲- روش دوم: ترافیک پویا و خرابی

در این روش، تمامی پیچیدگی های دنیای واقعی اعم از ترافیک های متغیر وابسته به زمان، خرابی تصادفی آمبولانس ها و استقرار مجدد بر اساس قوانین و منطق سنتی مکاشفه ای در سیستم اعمال شده است [۳۰].

¹ Hyperparameters

² Learning Rate

³ Batch Size

⁴ n_steps

۳-۷-۳- روش سوم: استقرار مجدد مبتنی بر یادگیری تقویتی

در این روش، اعزام ناوگان همچنان به صورت واکنشی و حریصانه (حفظ ایمنی بیمار) صورت می‌گیرد، اما مسئولیت پیش‌بینی و مدیریت استقرار مجدد آمبولانس‌ها به صورت یکپارچه به عامل هوشمند آموزش‌دیده (شبکه عصبی PPO) سپرده شده است.

۳-۷-۴- تقاضای ناهمگن زمانی و کالیبراسیون حالات شبیه‌سازی

تولید تقاضا در سیستم‌های اورژانس پیش‌بیمارستانی، فرآیندی کاملاً تصادفی و وابسته به زمان است. به منظور مدل‌سازی واقع‌گرایانه این پدیده، از فرآیند پواسون ناهمگن^۱ استفاده شده است [۲۳]. در این فرآیند، پارامتر نرخ وقوع حوادث ($\lambda(t)$) ثابت نبوده و به صورت تابعی از زمان شبانه‌روز کالیبره می‌شود تا الگوهای رفتاری و ترافیکی کلان‌شهرها را تقلید نماید. به جای در نظر گرفتن یک نرخ ثابت، پروفایل تقاضا در سه حالت مختلف و با هدف ارزیابی تاب‌آوری عامل هوشمند در سطوح مختلف ضریب اشغال ناوگان^۲ کالیبره و طراحی شده است:

حالت اول، روز کاری استاندارد است. این حالت نمایانگر الگوی استاندارد کلان‌شهرها در روزهای کاری است که دارای یک توزیع دوقله‌ای می‌باشد [۳۵]. در این الگو، اوج اول تقاضا همگام با سفرهای صبحگاهی (ساعات ۶ الی ۹) و اوج دوم در ساعات پیک عصرگاهی (ساعات ۱۶ الی ۲۰) تنظیم شده است. پارامتر $\lambda(t)$ در این حالت طوری کالیبره شده است که مجموع حوادث روزانه حدود ۴۰۰ مأموریت باشد. این حجم از تقاضا، ناوگان را در شرایط عملیاتی متوسط و نرمال قرار می‌دهد.

حالت دوم، روز تعطیل است. هدف از طراحی این حالت، ارزیابی قدرت تطبیق‌پذیری^۳ عامل هوشمند در برابر تغییر ناگهانی رژیم تقاضا است. در روزهای تعطیل، الگوی سفرهای کاری حذف شده و اوج ترافیک و تقاضا به ساعات عصر و شب (ساعات ۱۸ الی ۲۲) منتقل می‌گردد. همچنین با توجه به ماهیت سفرهای تفریحی و سرعت بالاتر خودروها در معابر خلوت‌تر روز، احتمال وقوع حوادث شدید، مانند تصادفات جاده‌ای

^۱ NHPP: Non-Homogeneous Poisson Process

^۲ Fleet Utilization Rate - ρ

^۳ Adaptability

پرخاطر، از ۳۵٪ به ۵۵٪ افزایش یافته است ($\Delta P_{\text{severe}} = +20\%$). مجموع تقاضا در این الگو برای حدود ۳۰۰ حادثه کالبره شده است.

حالت سوم، شرایط بحرانی و تست استرس است. در مهندسی سیستم‌ها، ارزیابی آستانه فروپاشی سیستم از طریق تست استرس انجام می‌پذیرد. به منظور شبیه سازی شرایط بحرانی (نظیر وقوع حوادث زنجیره‌ای، شرایط جوی نامساعد یا بحران‌های شهری)، تابع نرخ وقوع حوادث $\lambda(t)$ به صورت مقیاس یافته تنظیم گردید تا مجموع تقاضای روزانه به حدود ۷۰۰ حادثه برسد.

در این سناریوی تقاضای بالا، با در نظر گرفتن میانگین زمان درگیری هر آمبولانس برای مأموریت‌ها، شامل زمان پاسخ، میانگین ۳۲٫۵ دقیقه خدمت رسانی بالینی در صحنه و زمان بازگشت، کل بار کاری تحمیل شده به سیستم به بیش از ۴۲،۰۰۰ دقیقه-مأموریت در شبانه روز می‌رسد. از سوی دیگر، با کسر زمان‌های اتلاف رفته از ظرفیت اسمی ناوگان (شامل ۳۹ دستگاه آمبولانس)، نظیر خرابی‌های تصادفی تجهیزات، زمان‌های ازدست رفته در گره‌های ترافیکی و به ویژه زمان‌هایی که آمبولانس‌ها صرف جابه جایی و استقرار مجدد برای حفظ پوشش شهر می‌کنند و عملاً در آن دقایق حیاتی از مدار ناوگان آزاد خارج می‌شوند، ضریب اشغال مؤثر سیستم به شدت افزایش یافته و به محدوده بحرانی ۰٫۸۵ الی ۰٫۹۰ می‌رسد [۳۶].

بر اساس مبانی تئوری صف^۱، زمانی که نرخ ورود تقاضا تا این حد به ظرفیت سرویس دهی سیستم نزدیک می‌شود ($p = 0.85-0.9$)، سیستم وارد فاز ناپایداری شده و طول صف حوادث منتظر، به صورت نمایی رشد می‌کند. در این نقطه، الگوریتم‌ها و سیستم‌های مکاشفه‌ای دچار فروپاشی منطقی و پدیده سرگردانی ناوگان می‌شوند [۵]. از این رو، این سناریو به عنوان آستانه فروپاشی سیستم، بستری ایده آل برای ارزیابی تاب‌آوری، اولویت بندی و سنجش قدرت تریاژ مکانی در عامل یادگیری تقویتی فراهم می‌آورد.

۳-۷-۵- پروتکل ارزیابی آماری و اعتبارسنجی نتایج (اجرای ۳۰ روزه)

به منظور اجتناب از خطای تصادفی ناشی از اجرای منفرد شبیه سازی و حصول اطمینان از پایداری عملکرد سیستم، پروتکل ارزیابی و تست مدل در این پژوهش بر مبنای اجرای مستقل و متوالی ۳۰ روزه

¹ Queuing Theory

(معادل یک ماه عملیاتی برای هر سناریو) طراحی شده است. با توجه به تعدد منابع عدم قطعیت در مدل (شامل زمان و مکان وقوع حوادث، ترافیک پویا و خرابی ناوگان)، هر یک از تقابل‌های میان سیستم خط مبنا و عامل هوشمند در حالات سه‌گانه تقاضا، با ۳۰ دانه تصادفی^۱ مختلف اجرا می‌گردد. نتایج ارائه‌شده در فصل آتی، بر مبنای میانگین این ۳۰ اجرا به همراه محاسبه انحراف معیار و آزمون‌های معناداری آماری^۲ استخراج و گزارش خواهند شد تا برتری استراتژیک و تاب‌آوری عامل یادگیری تقویتی با قطعیت ریاضی و آماری به اثبات برسد.

^۱ Random Seeds

^۲ P-value

فصل ۴- نتایج شبیه‌سازی و تحلیل عملکرد

۴-۱- مقدمه

پس از تشریح چارچوب مسئله و فرمول‌بندی ریاضی فرآیند تخصیص و استقرار ناوگان اورژانس در فصل پیشین، این فصل به ارزیابی جامع و تحلیل نتایج حاصل از اجرای شبیه‌سازی‌ها اختصاص دارد. هدف اصلی در این فصل، سنجش کارایی و اثربخشی عامل تصمیم‌گیر هوشمند (مبتنی بر یادگیری تقویتی) در مقایسه با روش‌های سنتی حاکم بر مدیریت ناوگان آمبولانس در محیط‌های شهری پرتراکم است. در این راستا، عملکرد سیستم از زوایای مختلفی نظیر بهینه‌سازی زمان پاسخ‌گویی، حفظ پوشش استراتژیک شهر، و توزیع منطقی بار کاری میان تکنسین‌ها مورد واکاوی قرار می‌گیرد.

برای تضمین اعتبار علمی و امکان ارزیابی عادلانه^۱ بین معماری پیشنهادی و روش‌های موجود، تمامی آزمایش‌ها تحت شرایط محیطی کاملاً یکسان اجرا شده‌اند [۳۷]. افق زمانی شبیه‌سازی برای هر یک از آزمایش‌ها برابر با ۲۴ ساعت کامل (۱۴۴۰ دقیقه) در نظر گرفته شده است تا تأثیر چرخه‌های کامل ترافیکی (پیک‌های صبحگاهی، عصرگاهی و ساعات خلوت شبانه) در عملکرد مدل‌ها لحاظ گردد. همچنین، به منظور تضمین اعتبار آماری و حفظ تکرارپذیری نتایج، از یک رویکرد ارزیابی ترکیبی استفاده شده است. برای استخراج و مقایسه شاخص‌های کلان عملیاتی (نظیر جداول نرخ موفقیت و میانگین تأخیرها)، شبیه‌سازی‌ها ۳۰ بار متوالی با هسته‌های تصادفی^۲ متمایز اجرا گردیده‌اند؛ به گونه‌ای که در هر تکرار، هر دو سیستم با مجموعه‌ای کاملاً یکسان و همگام از حوادث (تولید شده توسط فرآیند پواسون) و خرابی‌های ناوگان مواجه می‌شوند تا تفاوت در خروجی‌ها، منحصراً ناشی از کیفیت استراتژی‌های تصمیم‌گیری باشد [۳۷]. از سوی

^۱ Fair Comparison

^۲ Random Seeds (1 to 30)

دیگر، برای ترسیم نمودارهای سری زمانی و تحلیل رفتارهای لحظه‌ای سیستم در طول ۲۴ ساعت (نظیر نمودار نوسانات محله‌های بی‌دفاع یا توزیع هیستوگرام زمان پاسخ)، خروجی‌های یک اجرای نماینده مورد استناد قرار گرفته است. دلیل این تفکیک روش‌شناختی آن است که میانگین‌گیری ریاضی از نمودارهای سری زمانی در طول یک ماه، نوسانات طبیعی و شوک‌های مقطعی ترافیک را مسطح کرده و مانع از درک رفتار فیزیکی و آشوبناک سیستم در یک روز واقعی عملیاتی می‌گردد.

در این ارزیابی، عملکرد عامل هوشمند، که از الگوریتم PPO برای استقرار مجدد پیشگیرانه و از جستجوی گراف برای اعزام واکنشی بهره می‌برد، در برابر یک سیستم خط مبنای پویا^۱ مقایسه می‌گردد. سیستم خط مبنا فاقد هوش مصنوعی بوده و علاوه بر اعزام حریصانه (نزدیک‌ترین آمبولانس در دسترس)، استقرار مجدد ناوگان در آن صرفاً بر اساس مجموعه‌ای از قوانین مکاشفه‌ای و واکنش به خلاهای پوششی پس از وقوع آن‌ها صورت می‌پذیرد [۳۰].

ساختار آزمایش‌ها در این فصل به گونه‌ای طراحی شده است که تاب‌آوری و هوشمندی سیستم پیشنهادی در مواجهه با الگوهای مختلف ترافیک و تقاضا به چالش کشیده شود. بر این اساس، شبیه‌سازی‌ها و تحلیل نتایج در قالب سه سناریوی اصلی ارائه می‌گردند. سناریوی اول مربوط به روز کاری استاندارد است با تقاضای متوسط و اوج ترافیک در ساعات شروع و پایان کار شهری (به عنوان سناریوی محوری پژوهش). سناریوی دوم مرتبط با روز تعطیل است به منظور بررسی توان تطبیق‌پذیری عامل در برابر انتقال ساعات پیک ترافیک به زمان‌های شبانه و افزایش شدت تصادفات. در آخر سناریوی سوم در مورد شرایط بحران و تقاضای بالا است برای ارزیابی آستانه فروپاشی سیستم و سنجش قدرت تریاژ هوشمند عامل در شرایط کمبود شدید منابع امدادی.

در ادامه این فصل، ابتدا به تعریف دقیق شاخص‌های کلیدی عملکرد^۲ پرداخته شده و سپس نتایج عددی و گرافیکی هر یک از سناریوها با رویکردی تحلیلی مورد بحث قرار خواهد گرفت.

^۱ Dynamic Baseline

^۲ KPIs: Key Performance Indicators

۴-۲- معرفی شاخص‌های کلیدی عملکرد

به منظور ارزیابی جامع و علمی عملکرد مدل‌های پیاده‌سازی شده در این پژوهش، از مجموعه‌ای از شاخص‌های کلیدی عملکرد استفاده شده است [۳۸]. این شاخص‌ها به گونه‌ای انتخاب و فرمول‌بندی شده‌اند که ابعاد مختلف مدیریت اورژانس پیش‌بیمارستانی اعم از کیفیت خدمات بالینی، کارایی استراتژیک، هزینه‌های عملیاتی و عدالت در توزیع منابع را به صورت کمی اندازه‌گیری کنند. مقادیر این شاخص‌ها از فایل‌های لاگ شبیه‌ساز استخراج شده و مبنای مقایسه میان روش خط مبنا و عامل یادگیری تقویتی قرار می‌گیرند. شاخص‌های مورد استفاده در چهار دسته اصلی طبقه‌بندی شده‌اند.

۴-۲-۱- شاخص‌های کیفیت خدمات بالینی^۱

این دسته از شاخص‌ها مستقیماً با نجات جان بیماران و رعایت استانداردهای زمانی در ارتباط هستند [۳۸].

اولین شاخص، نرخ پاسخ‌گویی به موقع^۲ است. این شاخص حیاتی‌ترین معیار ارزیابی در سیستم‌های اورژانس پیش‌بیمارستانی محسوب می‌شود و بیانگر درصد مأموریت‌هایی است که آمبولانس پیش از پایان زمان طلایی به بالین بیمار رسیده است. با توجه به استانداردهای تریاژ در این مدل، مهلت استاندارد برای حوادث شدید برابر با ۸ دقیقه و برای حوادث خفیف برابر با ۱۲ دقیقه تعریف شده است [۱].

شاخص بعدی، مأموریت‌های ناموفق / با تأخیر^۳ است. تعداد کل حوادثی که زمان رسیدن به آن‌ها از مهلت مقرر فراتر رفته است و بیمار در معرض ریسک‌های جدی سلامتی قرار گرفته است.

شاخص سوم، میانگین زمان پاسخ^۴ است. این معیار نشان‌دهنده متوسط زمان سپری شده (به دقیقه) از لحظه ثبت حادثه تا لحظه رسیدن آمبولانس به گره تقاضا است.

^۱ Clinical Service Quality Metrics

^۲ On-Time Rate

^۳ Failed/Late Missions

^۴ Average Response Time

آخرین شاخص کیفیت خدمات بالینی، میانگین زمان خدمت‌رسانی^۱، متوسط زمانی است که تکنسین‌های اورژانس در صحنه حادثه درگیر تثبیت وضعیت بیمار بوده‌اند.

۴-۲-۲- شاخص‌های پوشش مکانی-زمانی^۲

هدف از استقرار پیشگیرانه، به حداقل رساندن مناطق آسیب‌پذیر در سطح شبکه شهری است. برای سنجش این هدف، شاخص‌های زیر به صورت لحظه‌به‌لحظه ارزیابی شده‌اند.

یکی از این شاخص‌ها، میانگین تعداد محله‌های بی‌دفاع^۳ است. این شاخص نشان می‌دهد که در هر دقیقه از اجرای شبیه‌سازی ۲۴ ساعته، به طور متوسط چه تعداد از گره‌های تقاضا خارج از چتر پوششی ۸ دقیقه‌ای ناوگان آزاد قرار داشته‌اند. کاهش این عدد نشان‌دهنده توزیع استراتژیک‌تر ناوگان در سطح شهر است. شاخص دیگر، میانگین مدت‌زمان بی‌دفاع ماندن^۴ است. علاوه بر تعداد محله‌های بی‌دفاع، تداوم این آسیب‌پذیری نیز حائز اهمیت است. این شاخص بیانگر متوسط زمان ممتدی (به دقیقه) است که یک گره شهری منتظر ورود یک آمبولانس به شعاع پوششی خود بوده است.

۴-۲-۳- شاخص‌های کارایی عملیاتی و استهلاک^۵

حرکت دادن مداوم آمبولانس‌ها اگرچه ممکن است پوشش را بهبود بخشد، اما هزینه‌های پنهانی برای سیستم به همراه دارد که با شاخص میانگین مجموع زمان جابه‌جایی ناوگان^۶ سنجیده می‌شود.

این شاخص متوسط دقایقی را نشان می‌دهد که کل ناوگان ۳۹ عددی در طول شبانه‌روز (حاصل از میانگین ۳۰ اجرای مستقل) صرف جابه‌جایی‌های بدون بیمار (پیشگیرانه) کرده است. مقادیر غیرمنطقی و بیش از حد این شاخص نشان‌دهنده پدیده سرگردانی ناوگان، هدررفت سوخت و ایجاد ترافیک کاذب است [۵]. یک الگوریتم هوشمند و بهینه باید بتواند با کمترین جابه‌جایی فیزیکی، بالاترین پوشش شهری را تضمین کند.

¹ Average Service Time

² Spatio-Temporal Coverage Metrics

³ Avg Uncovered Nodes

⁴ Avg Uncovered Duration

⁵ Operational Efficiency

⁶ Total Relocation Time

۴-۲-۴- شاخص‌های توزیع بار کاری و خستگی تکنسین‌ها^۱

حفظ عدالت در توزیع مأموریت‌ها میان پایگاه‌ها و تکنسین‌ها، یکی از الزامات اساسی در مدیریت منابع انسانی اورژانس برای جلوگیری از خطاهای ناشی از خستگی است [۳۹].

یکی از این شاخص‌ها انحراف معیار بار کاری^۲ است. این شاخص، انحراف معیار تعداد مأموریت‌های انجام‌شده توسط تک‌تک آمبولانس‌ها را محاسبه می‌کند. کاهش این متغیر در خروجی‌ها بدین معناست که سیستم اعزام توانسته است فشار کاری را به صورت متوازن بین تمامی کدهای عملیاتی تقسیم کند. شاخص دیگر، حداکثر بار کاری یک آمبولانس^۳ است. این معیار نشان‌دهنده بیشترین تعداد مأموریتی است که در طول یک شیفت کاری به یک آمبولانس خاص محول شده است. پایش این شاخص از تمرکز فشار طاقت‌فرسا بر روی یک ایستگاه یا تیم مشخص جلوگیری می‌کند.

۴-۳- تأثیر ترافیک پویا بر عملکرد اورژانس (ضرورت استفاده از هوش

مصنوعی)

یکی از اهداف کلیدی در این پژوهش، ارزیابی تأثیر متغیرهای دنیای واقعی (نظیر ترافیک پویا و استهلاک ناوگان) بر کارایی روش‌های خط‌مبنا در تخصیص آمبولانس است. در این رویکرد، سیستم به صورت کاملاً واکنشی عمل می‌کند؛ بدین معنا که تنها پس از وقوع حادثه و اعزام نزدیک‌ترین آمبولانس، در صورتی که خلأ پوششی در شبکه ایجاد شود، اقدام به استقرار مجدد سایر آمبولانس‌ها می‌نماید و فاقد مکانیزم پیش‌بینانه برای مدیریت استراتژیک ناوگان پیش از بروز بحران است. به منظور درک بهتر این محدودیت و اثبات ضرورت توسعه یک عامل هوشمند یادگیرنده، عملکرد سیستم در دو سناریوی متمایز (حالت آرمانی و حالت واقع‌گرایانه) شبیه‌سازی و ارزیابی شده است.

^۱ Workload Distribution^۲ Workload Std Dev^۳ Max Workload

۴-۳-۱- ارزیابی عملکرد در شرایط آرمانی (خط مبنای ایستا)

در گام نخست، یک سناریوی آرمانی شبیه‌سازی گردید که در آن فرض بر عدم وجود ترافیک و حرکت آمبولانس‌ها با سرعت ثابت و ایده‌آل است. همچنین در این حالت، احتمال خرابی تجهیزات صفر در نظر گرفته شده است. این سناریو به عنوان حد بالای عملکرد^۱ سیستم در نظر گرفته می‌شود.

جدول ۴-۱: عملکرد سیستم مکاشفه‌ای در شرایط آرمانی (بدون ترافیک - روز کاری استاندارد)

شاخص	تعداد کل مأموریت‌ها	مأموریت‌های موفق (به موقع)	مأموریت‌های ناموفق (تأخیر)	نرخ پاسخ‌گویی به موقع	میانگین زمان پاسخ (دقیقه)	میانگین زمان خدمت‌رسانی (دقیقه)
مقدار	۴۰۱	۳۹۸	۳	۹۹/۲۵٪	۲/۲۷	۳۲/۵۷

همان‌گونه که در جدول ۴-۱ مشاهده می‌شود، در غیاب چالش‌های ترافیکی، رویکرد اعزام حریصانه عملکردی خیره‌کننده با نرخ موفقیت ۹۹/۲۵ درصد و میانگین زمان پاسخ ۲/۲۷ دقیقه ثبت نموده است که نشان‌دهنده توزیع مناسب اولیه پایگاه‌ها در سطح گراف شهر است.

۴-۳-۲- افت عملکرد در محیط واقعی (ترافیک پویا و استهلاک)

محیط‌های کلان‌شهری به ندرت شرایط آرمانی را تجربه می‌کنند. در گام دوم، خط مبنای پویا با اعمال ضرایب ترافیکی متغیر در طول ۲۴ ساعت و احتمال خرابی ناوگان اجرا گردید. نتایج این شبیه‌سازی پس از ۳۰ بار اجرای مستقل، در جدول ۴-۲ ارائه شده است.

جدول ۴-۲: عملکرد سیستم مکاشفه‌ای در محیط واقع‌گرایانه (با ترافیک پویا و استهلاک - روز کاری استاندارد) (حاصل ۳۰ بار اجرای مستقل)


شاخص	تعداد کل مأموریت‌ها	مأموریت‌های موفق (به موقع)	مأموریت‌های ناموفق (تأخیر)	نرخ پاسخ‌گویی به موقع	میانگین زمان پاسخ (دقیقه)	میانگین زمان خدمت‌رسانی (دقیقه)
مقدار	۴۰۱	۳۰۳	۹۸	۷۵/۷٪	۷/۵	۳۲/۵۶

نتایج حاکی از افت ملموس و حدوداً ۲۴ درصدی در نرخ پاسخ‌گویی به موقع (سقوط به ۷۵/۷٪) و افزایش چشمگیر میانگین زمان پاسخ (از ۲/۲۷ به ۷/۸ دقیقه) است. این تنزل عملکرد، ناکارآمدی رویکرد واکنشی صرف را در مواجهه با پیچیدگی‌های ترافیکی آشکار می‌سازد.

^۱ Upper Bound

۳-۳-۴- تحلیل مقایسه‌ای و آسیب‌شناسی سیستم واکنشی


به منظور واکاوی دقیق‌تر دلایل این افت عملکرد، توزیع زمان‌های پاسخ و وضعیت پوشش شهری در دو حالت آرمانی و واقع‌گرایانه (برای یک روز نماینده) مورد قیاس قرار گرفته‌اند.



شکل ۴-۱: مقایسه توزیع زمان‌های پاسخ‌گویی؛ (الف): شرایط آرمانی بدون ترافیک، (ب): محیط واقع‌گرایانه با ترافیک پویا.

بررسی شکل ۴-۱ نشان می‌دهد که در حالت آرمانی (نمودار الف)، توزیع زمان‌های پاسخ کاملاً فشرده و پیش از موعدهای بحرانی (۸ و ۱۲ دقیقه) متمرکز است. اما با ورود ترافیک (نمودار ب)، چولگی توزیع به سمت راست^۱ متمایل شده و دم نمودار^۲ به دلیل گیر افتادن آمبولانس‌ها در گره‌های ترافیکی، تا زمان‌های بسیار بالاتر نیز امتداد یافته است.

دلیل اصلی این تأخیرها، ایجاد حفره‌های امنیتی در سطح شهر به دلیل عدم توانایی سیستم در جایگزینی سریع آمبولانس‌های اعزام‌شده است. شکل ۴-۲ وضعیت محله‌های بی‌دفاع را در طول ۲۴ ساعت (برای یک روز نماینده) نشان می‌دهد.



شکل ۴-۲: مقایسه محله‌های فاقد پوشش در طول ۲۴ ساعت؛ (الف): شرایط آرمانی، (ب): تأثیر ترافیک پویا بر ایجاد خلأهای پوششی.

^۱ Right-skewed

^۲ Tail

چنانچه در شکل ۴-۲ (ب) مشهود است، همزمان با ساعات اوج ترافیک صبحگاهی (دقیقه ۰ تا ۱۸۰ شبیه‌سازی معادل ۶ الی ۹ صبح) و اوج عصرگاهی (دقیقه ۶۰۰ تا ۸۴۰ معادل ۱۶ الی ۲۰)، تعداد گره‌های خارج از پوشش ۸ دقیقه‌ای به صورت انفجاری افزایش یافته و به بیش از ۵۰ محله می‌رسد. اگرچه الگوریتم خط مبنا تلاش می‌کند تا با جابه‌جایی پیوسته و واکنشی آمبولانس‌های آزاد، این حفره‌های ایجادشده را پر کند، اما به دلیل عدم درک الگوهای آینده‌ی ترافیک، این جابه‌جایی‌ها در ساعات پیک ناکارآمد بوده و ناوگان در گره‌های ترافیکی گرفتار می‌شود. در نتیجه، سیستم توانایی پایداری خود را از دست داده و مناطق وسیعی از شهر عملاً بی‌دفاع باقی می‌مانند.

تحلیل این رفتار اثبات می‌کند که پیچیدگی‌های دینامیک کلان‌شهرها، نیازمند رویکردی فراتر از تصمیم‌گیری واکنشی است. برای جبران افت ۲۴ درصدی عملکرد و حفظ پوشش استراتژیک در ساعات پیک ترافیک، استفاده از یک عامل هوشمند پیش‌بین که قادر به یادگیری الگوهای شهری و صدور فرامین استقرار مجدد پیشگیرانه باشد، الزامی است. در بخش آتی، تأثیر پیاده‌سازی این عامل هوشمند مبتنی بر یادگیری تقویتی بر بهبود شاخص‌های فوق مورد ارزیابی قرار می‌گیرد.

۴-۴- ارزیابی عملکرد عامل هوشمند در شرایط تقاضای استاندارد (روز)

کاری)

همان‌گونه که در بخش پیشین اثبات گردید، پیچیدگی‌های ناشی از ترافیک پویا و استهلاک ناوگان باعث افت شدید عملکرد در سیستم‌های مبتنی بر اعزام واکنشی صرف^۱ می‌گردد. در این بخش، عملکرد معماری هیبریدی پیشنهادی، که در آن اعزام به صورت مکاشفه‌ای و استقرار مجدد به صورت پیشگیرانه توسط عامل یادگیری تقویتی مدیریت می‌شود، در همان شرایط واقع‌گرایانه (روز کاری استاندارد) ارزیابی می‌شود. هدف این بخش، بررسی میزان موفقیت عامل هوشمند در جبران افت عملکرد و بهبود شاخص‌های حیاتی سیستم است.

^۱ Reactive Dispatch

۴-۴-۱- بهبود زمان پاسخ‌گویی و نرخ موفقیت

نخستین و مهم‌ترین معیار برای سنجش کارایی سیستم اورژانس، توانایی آن در رسیدن به بالین بیمار در محدوده زمان طلایی است. پس از آموزش شبکه عصبی PPO طی ۱,۵ میلیون گام، مدل نهایی بر روی محیط شبیه‌سازی اجرا گردید. نتایج حاصل از ۳۰ بار اجرای مستقل در جدول ۳-۴ خلاصه شده است.


جدول ۳-۴: عملکرد عامل هوشمند (RL) در محیط واقع‌گرایانه در روز کاری استاندارد (حاصل ۳۰ بار اجرای مستقل)

شاخص	تعداد کل مأموریت‌ها	مأموریت‌های موفق (به‌موقع)	مأموریت‌های ناموفق (تأخیر)	نرخ پاسخ‌گویی به‌موقع	میانگین زمان پاسخ (دقیقه)	میانگین زمان خدمت‌رسانی (دقیقه)
مقدار	۴۰۱	۳۴۷	۵۴	۸۶/۶٪	۴/۹۶	۳۱/۸۶

قیاس دستاوردهای عامل هوشمند (جدول ۳-۴) با سیستم خط مبنا (جدول ۲-۴)، نشان‌دهنده یک جهش قابل‌توجه در کیفیت خدمات‌رسانی است. نرخ پاسخ‌گویی به‌موقع با ارتقای حدوداً ۱۱ درصدی، از ۷۵/۷٪ به ۸۶/۶٪ افزایش یافته است. به موازات این بهبود، میانگین زمان پاسخ‌گویی کل شبکه نیز از ۷/۵ دقیقه به ۴/۹۶ دقیقه تقلیل یافته است؛ کاهشی نزدیک به ۲/۵ دقیقه که در مقیاس عملیات اورژانس پیش‌بیمارستانی، دستاوردی حیاتی برای نجات جان بیماران ترومایی و قلبی محسوب می‌گردد.

به منظور درک بهتر نحوه توزیع این زمان‌ها، هیستوگرام زمان‌های پاسخ برای هر دو سیستم (برای یک


روز نماینده) در شکل ۳-۴ مقایسه شده است.



شکل ۳-۴: مقایسه توزیع زمان‌های پاسخ‌گویی در شرایط ترافیک پویا؛ (الف): خط مبنا (بدون هوش مصنوعی)، (ب): سیستم مدیریت‌شده توسط عامل هوشمند (RL).

بررسی شکل ۳-۴ به وضوح نشان می‌دهد که عامل هوشمند توانسته است رفتار دُمدار نمودار را که ناشی از گیر افتادن آمبولانس‌ها در ترافیک‌های سنگین بود، مهار کند. در نمودار (ب)، چولگی به شدت کاهش یافته و تراکم اصلی داده‌ها^۱ با موفقیت به سمت چپ خط بحرانی ۸ دقیقه شیف‌ت پیدا کرده است. این امر نشان می‌دهد که پیش‌بینی محل وقوع حوادث و استقرار پیش‌دستانه ناوگان، توانسته است تأخیرهای افراطی را از سیستم حذف نماید.

برای اثبات این ادعا که برتری عامل هوشمند دقیقاً در شرایط بحرانی و گره‌های ترافیکی رقم می‌خورد، عملکرد هر دو سیستم پس از ۳۰ بار اجرای مستقل به تفکیک ساعات ترافیک روان و ساعات اوج ترافیک تجزیه و تحلیل شده است (شکل ۴-۴ و جدول ۴-۴).



شکل ۴-۴: مقایسه عملکرد عامل هوشمند و خط مبنای پویا به تفکیک ترافیک روان (روز) و پیک ترافیک (شبانه) در روز کاری استاندارد.

^۱ Mass of Distribution

جدول ۴-۴: مقایسه آماری نرخ موفقیت در شرایط مختلف ترافیکی (حاصل ۳۰ بار اجرای مستقل)

شرایط ترافیکی	خط مبنا (میانگین $\pm$ انحراف معیار)	عامل هوشمند (میانگین $\pm$ انحراف معیار)	مقدار سطح معناداری
ساعات ترافیک روان	$1/99 \pm 96/08\%$	$1/43 \pm 96/90\%$	$0/29$
ساعات اوج ترافیک	$7/11 \pm 55/35\%$	$6/36 \pm 70/47\%$	$<0/001$

شکل و جدول فوق (۴-۴) یکی از مهم‌ترین یافته‌های این پژوهش را با قطعیت آماری به تصویر می‌کشند. در ساعات ترافیک روان (نظیر نیمه‌شب)، اگرچه عامل هوشمند با ثبت نرخ $96/90\%$ در برابر $96/08\%$ برتری داشته است، اما تفاوت مطلق میان دو روش چندان چشمگیر نیست؛ زیرا معابر خلوت بوده و اعزام مستقیم از پایگاه به تنهایی پاسخگو است. با این وجود، مقدار سطح معناداری برابر با $0/29$ ($p < 0.005$) ثابت می‌کند که همین بهبود جزئی نیز تصادفی نبوده و از نظر آماری کاملاً معنادار است.

اما ارزش افزوده اصلی و نقطه قوت عامل هوشمند در ساعات اوج ترافیک نمایان می‌شود. در حالی که ترافیک سنگین باعث می‌شود سیستم سنتی دچار فروپاشی شده و نرخ موفقیت آن به $55/35\%$ سقوط کند، عامل هوشمند با بهره‌گیری از منطق جابه‌جایی پیشگیرانه، این نرخ را در سطح قابل قبول $70/47\%$ حفظ می‌نماید. علاوه بر این ارتقا، بررسی مقادیر انحراف معیار نشان‌دهنده‌ی برتری پایداری عامل هوشمند است؛ سیستم PPO توانسته است نوسانات عملکرد شبکه را در سخت‌ترین شرایط کاهش دهد (انحراف معیار $6/36\%$ در برابر $7/11\%$ خط مبنا).


در نهایت، مقدار سطح معناداری بسیار کوچک در این حالت ($p < 0.001$) به طور قطعی و ریاضی اثبات می‌کند که این دستاورد بی‌نظیر، تصادفی نبوده و سیاست‌های تولیدشده توسط RL، با پیش‌بینی الگوهای ترافیکی، ناوگان را پیش از قفل شدن خیابان‌ها در مناطق استراتژیک مستقر نموده‌اند.

۴-۴-۲- تحلیل پوشش استراتژیک مکانی

علاوه بر زمان پاسخ‌گویی، یکی دیگر از اهداف حیاتی در مدیریت ناوگان اورژانس، حفظ پوشش امنیتی در تمامی نقاط شهر است. یک سیستم کارآمد باید بتواند توزیع مکانی ناوگان را به گونه‌ای مدیریت کند که حتی در زمان درگیری بخشی از آمبولانس‌ها در مأموریت، سایر مناطق شهر بی‌دفاع نمانند.

به منظور ارزیابی این شاخص، میانگین تعداد گره‌های خارج از شعاع پوشش ۸ دقیقه‌ای در طول ۲۴ ساعت شبیه‌سازی اندازه‌گیری شد. بر اساس خروجی‌ها، در سیستم خط مبنا (بدون هوش مصنوعی)، به طور متوسط ۱۰/۱۶ محله در هر لحظه فاقد پوشش بوده‌اند. با اعمال سیاست‌های استقرار مجدد توسط عامل یادگیری تقویتی، این رقم با بهبود چشمگیری به ۹/۲۴ محله کاهش یافته است.

برای درک بهتر رفتار سیستم در طول شبانه‌روز، نمودار نوسانات محله‌های بی‌دفاع در یک روز نماینده در شکل ۴-۵ ترسیم شده است.



شکل ۴-۵: مقایسه تعداد محله‌های فاقد پوشش در طول ۲۴ ساعت؛ (الف): خط مبنا و واکنشی (بدون هوش مصنوعی)، (ب): سیستم مدیریت‌شده توسط عامل هوشمند (RL).

بررسی شکل ۴-۵ نشان می‌دهد که عامل RL توانسته است نوسانات شدید^۱ را به نحو مؤثری مهار کند. در سیستم سنتی (نمودار الف)، در ساعات اوج ترافیک تعداد مناطق بی‌دفاع به صورت متراکم و پیوسته در مرز ۵۰ گره قرار دارد. اما در سیستم هوشمند (نمودار ب)، اگرچه قله‌هایی در ساعات پیک دیده می‌شود، اما ضخامت این قله‌ها بسیار کمتر بوده و سیستم با سرعت بسیار بالاتری توانسته است با جابه‌جایی ناوگان آزاد، این خلأها را پر کرده و گراف را به حالت پایدار (نزدیک به صفر) بازگرداند. این رفتار، مزیت رویکرد پیشگیرانه بر رویکرد واکنشی را به اثبات می‌رساند.

^۱ Spikes

۴-۴-۳- تحلیل کارایی عملیاتی، توزیع بار کاری و کاهش استهلاك

یکی از چالش‌های پنهان در سیستم‌های استقرار مجدد، پدیده‌ای به نام سرگردانی ناوگان است. در این حالت، سیستم با مشاهده کوچکترین خلأ پوششی، آمبولانس‌ها را مکرراً در سطح شهر جابه‌جا می‌کند که منجر به افزایش شدید هزینه‌های سوخت، استهلاك خودروها و خستگی پرسنل می‌گردد. در این بخش، کارایی عملیاتی عامل هوشمند در قیاس با خط مبنا مورد ارزیابی قرار گرفته است.

جدول ۴-۵: مقایسه شاخص‌های عملیاتی و بار کاری در روز کاری استاندارد (حاصل ۳۰ بار اجرای مستقل)

روش شبیه‌سازی	میانگین تعداد گره‌های بی‌دفاع	میانگین زمان بی‌دفاع ماندن (دقیقه)	مجموع زمان جابه‌جایی ناوگان (دقیقه)	انحراف معیار بار کاری (مأموریت)	حداکثر بار کاری یک آمبولانس (مأموریت)
خط مبنا (بدون هوش مصنوعی)	۱۰/۱۶	۲۰/۴۱	۵۸۷۵	۰/۹۵	۱۲
عامل هوشمند	۹/۲۴	۲۶/۱۶	۱۴۹۳	۱/۳۳	۱۲

مهم‌ترین و برجسته‌ترین دستاورد عملیاتی عامل RL که در جدول ۴-۵ خودنمایی می‌کند، کاهش خیره‌کننده‌ی مجموع زمان جابه‌جایی ناوگان است. در سیستم خط مبنا (مبتنی بر قوانین مکاشفه‌ای)، ناوگان اورژانس مجموعاً ۵۸۷۵ دقیقه در طول شبانه‌روز در حال گشت‌زنی و جابه‌جایی برای پر کردن خلأها بوده‌اند که نشان‌دهنده وقوع شدید پدیده سرگردانی است. اما عامل هوشمند، با درک هزینه و جریمه‌ی جابه‌جایی (از طریق تابع پاداش MDP)، این زمان را به تنها ۱۴۹۳ دقیقه (نزدیک به ۷۵ درصد کاهش) تقلیل داده است. عامل RL آموخته است که هر خلأ پوششی نیازمند واکنش فیزیکی نیست و تنها زمانی دستور جابه‌جایی صادر می‌کند که ارزش استراتژیک آن (کاهش زمان پاسخ‌گویی آینده) از هزینه استهلاك و درگیر شدن در ترافیک بیشتر باشد.

کمی افزایش در میانگین زمان بی‌دفاع ماندن (از ۲۰/۴۱ به ۲۶/۱۶ دقیقه) در مدل RL نیز دقیقاً ناشی از همین هوشمندی است؛ عامل ترجیح داده است مناطق پیرامونی و کم‌خطر را برای مدت بیشتری بی‌دفاع بگذارد تا آمبولانس‌ها در هسته مرکزی و پرخطر شهر پایدار بمانند.

بررسی شاخص‌های بار کاری نشان می‌دهد که انحراف معیار مأموریت‌ها در مدل هوشمند (۱/۳۳) نسبت به خط مبنا (۰/۹۵) اندکی افزایش یافته است؛ به این معنا که برخی آمبولانس‌ها (حداکثر ۱۲ مأموریت)

بیشتر از سایرین درگیر عملیات بوده‌اند. از منظر مهندسی سیستم، این امر نه تنها یک نقطه ضعف نیست، بلکه ویژگی ذاتی یک سیستم مبتنی بر تقاضای نامتقارن است. از آنجایی که عامل RL به صورت هوشمندانه آمبولانس‌ها را در مجاورت نقاط پرخطر مستقر می‌کند، بدیهی است که کدهای مستقر در این مناطق حیاتی، بار کاری بیشتری نسبت به کدهای مستقر در مناطق حاشیه‌ای با تقاضای کم دریافت کنند. این فداکاری آگاهانه در برابری مطلق بار کاری، همان عاملی است که منجر به افزایش نرخ موفقیت کل سیستم به ۸۶/۶٪ (جدول ۴-۳) گردیده است.

۴-۴-۴- جمع‌بندی دستاوردهای عامل هوشمند در شرایط استاندارد

بررسی جامع شاخص‌های کلیدی عملکرد در سناریوی روز کاری اثبات می‌کند که پیاده‌سازی معماری هیبریدی پیشنهادی، با موفقیت توانسته است بر چالش‌های بنیادین ناشی از ترافیک پویا غلبه نماید. عامل یادگیری تقویتی با گذار از رویکرد واکنش‌گرا به رویکرد پیش‌بین، نه تنها نرخ پاسخ‌گویی به موقع را حدود ۱۱ درصد ارتقا داده و به مرز ۸۶/۶٪ رساند، بلکه این دستاورد را با کاهش ۷۵ درصدی در مجموع زمان جابه‌جایی ناوگان محقق ساخت. این تقلیل چشمگیر در استهلاک، به وضوح نشان می‌دهد که سیاست‌های اتخاذشده توسط شبکه عصبی PPO کاملاً استراتژیک، هدفمند و به دور از پدیده مخرب سرگردانی بوده‌اند.

با اثبات کارایی، بهره‌وری و هوشمندی این عامل در شرایط تقاضای استاندارد شهری، پرسش مهم بعدی آن است که آیا این مدل آموزش‌دیده قادر است تاب‌آوری^۱ و تطبیق‌پذیری خود را در برابر ناهنجاری‌های شبکه، نظیر تغییرات ناگهانی الگوی ترافیک در روزهای تعطیل و یا شوک‌های تقاضا در شرایط بحرانی، نیز حفظ نماید؟ در بخش‌های آتی، عملکرد سیستم در این سناریوهای چالش‌برانگیز ارزیابی و تحلیل خواهد شد.

۴-۵- ارزیابی تطبیق‌پذیری مدل در الگوهای متغیر (سناریوی روز تعطیل)

همان‌طور که در بخش‌های پیشین مشاهده شد، عامل هوشمند آموزش‌دیده در محیط روز کاری عملکردی خیره‌کننده در مهار ترافیک پیوسته داشت. اما یکی از معیارهای اصلی ارزیابی سیستم‌های پشتیبان

^۱ Resilience

تصمیم مبتنی بر یادگیری ماشین، قابلیت تعمیم‌پذیری و توانایی تطبیق با شرایطی است که مدل پیش از آن ندیده است.

در روزهای تعطیل، رژیم شهر کاملاً دگرگون می‌شود؛ ترافیک صبحگاهی حذف شده و پیک ترافیک به ساعات عصر و شب منتقل می‌گردد. همچنین، به دلیل خلوتی معابر در طول روز، درصد وقوع حوادث شدید با جهشی قابل توجه همراه است. هدف از این بخش، اجرای یک ارزیابی متقاطع^۱ است؛ بدین معنا که مدل PPO آموزش‌دیده در روز کاری، بدون هیچ‌گونه آموزش مجدد، مستقیماً بر روی محیط روز تعطیل آزمایش می‌شود تا قدرت درک و واکنش در لحظه‌ی آن سنجیده شود.

۴-۵-۱- تحلیل شاخص‌های کلان و عملکرد در پیک‌های ترافیکی شبانه

در گام نخست، خروجی‌های کلان سیستم خط مبنا (مبتنی بر منطق واکنشی پیشرفته) و سیستم مدیریت‌شده توسط عامل هوشمند در روز تعطیل (با حجم تقاضای حدود ۳۰۰ حادثه) پس از ۳۰ بار اجرای مستقل، استخراج و در جدول ۴-۶ جمع‌گردد.

جدول ۴-۶: مقایسه عملکرد کلی سیستم خط مبنای پویا و عامل هوشمند در سناریو روز تعطیل (حاصل ۳۰ بار اجرای مستقل)


شاخص	تعداد کل مأموریت‌ها	مأموریت‌های موفق (به‌موقع)	مأموریت‌های ناموفق (تأخیر)	نرخ پاسخ‌گویی به‌موقع	میانگین زمان پاسخ (دقیقه)
خط مبنای پویا	۳۰۸	۲۷۷	۳۱	۹۰/۱۰٪	۴/۰۸
عامل هوشمند	۳۰۸	۲۸۴	۲۴	۹۲/۳۴٪	۳/۵۹

برخلاف انتظار اولیه مبنی بر افت عملکرد عامل در محیطی متفاوت از محیط آموزش (روز کاری)، جدول ۴-۶ نشان می‌دهد که در مجموع ۲۴ ساعت، عامل هوشمند توانسته است با موفقیت نرخ پاسخ‌گویی کل شبکه را از ۹۰/۱۰٪ در سیستم خط مبنا به ۹۲/۳۴٪ ارتقا دهد. هم‌راستا با این بهبود، میانگین زمان پاسخ نیز با کاهشی مشهود، از ۴/۰۸ دقیقه به ۳/۵۹ دقیقه تقلیل یافته است.

با این وجود، برای درک عمیق‌تر پویایی سیستم، بررسی عملکرد به تفکیک رژیم‌های ترافیکی الزامی است. از منظر تئوری ترافیک شهری، در روزهای تعطیل شهر در بیشتر ساعات روز خلوت بوده و تنها در

^۱ Cross-Evaluation

ساعات عصر و شب با پیک‌های سنگین غیرمعمول مواجه می‌شویم. به منظور اثبات قدرت تعمیم‌پذیری عامل RL در این شرایط جدید، عملکرد هر دو سیستم بر اساس ۳۰ اجرای متوالی در ساعات ترافیک روان و ساعات اوج ترافیک شبانه تجزیه و تحلیل شده است (شکل ۴-۶ و جدول ۴-۷).



شکل ۴-۶: مقایسه عملکرد عامل هوشمند و خط مبنای پویا به تفکیک ترافیک روان (روز) و پیک ترافیک (شبانه) در روز تعطیل.

جدول ۴-۷: مقایسه آماری نرخ موفقیت در شرایط مختلف ترافیکی روز تعطیل (حاصل ۳۰ بار اجرای مستقل)

مقدار سطح معناداری	عامل هوشمند (میانگین $\pm$ انحراف معیار)	خط مبنای (میانگین $\pm$ انحراف معیار)	شرایط ترافیکی
< 0.001	$98.1\% \pm 0.97$	$98.6\% \pm 0.79$	ساعات ترافیک روان
< 0.001	$76.7\% \pm 1.07$	$67.0\% \pm 0.64$	ساعات اوج ترافیک

تحلیل جدول ۴-۷ و شکل ۴-۶ زوایای پنهان و بسیار مهمی از رفتار استراتژیک شبکه عصبی را آشکار می‌سازد. در ساعات ترافیک روان روز تعطیل، سیستم خط مبنای عملکردی نزدیک به حد بهینه داشته و با ثبت نرخ موفقیت 98.6% ، اندکی بهتر از عامل هوشمند (98.1%) عمل کرده است. اگرچه این تفاوت نیم درصدی بسیار ناچیز است، اما آزمون آماری ($p < 0.001$) معنادار بودن آن را تأیید می‌کند. دلیل این پدیده از منظر مهندسی سیستم‌ها کاملاً منطقی است. عامل RL بر اساس سیاست‌های بهینه‌سازی‌شده‌اش، همواره در حال

پیش‌بینی و جابه‌جایی ناوگان برای پوشش خلأها است؛ این تحرکات پیشگیرانه در یک گراف کاملاً خلوت ممکن است باعث دوری موضعی آمبولانس از محل حادثه شده و تأخیرهای چند ثانیه‌ای ایجاد کند که به این افت آماری اندک منجر می‌شود.

اما ارزش واقعی و قدرت تعمیم‌پذیری شگرف عامل هوشمند، در لحظات بحرانی و اوج ترافیک شبانه به اثبات می‌رسد. با فرا رسیدن ساعات عصر و شب که ویژگی بارز و غیرقابل‌پیش‌بینی روزهای تعطیل است، سیستم سنتی غافلگیر شده و نرخ موفقیت آن با ریزشی شدید و نوسانات بالا به ۶۷/۰۱٪ سقوط می‌کند. در مقابل، عامل هوشمند به محض تشخیص ایجاد گره‌های ترافیکی در شبکه، الگوی رفتاری خود را تطبیق داده و با استقرار پیش‌دستانه ناوگان در نقاط کلیدی، موفق می‌شود نرخ پاسخ‌گویی را در دل ترافیک سنگین شبانه در عدد بسیار مطلوب ۷۶/۶۷٪ حفظ کند.

این ارتقای نزدیک به ۱۰ درصدی در موفقیت مطلق، با سطح معناداری ریاضی بسیار بالا ($p < 0.001$) به ثبت رسیده است که هرگونه احتمال تصادفی بودن این برتری را رد می‌کند. علاوه بر این، بررسی مقادیر انحراف معیار نشان می‌دهد که عامل هوشمند توانسته است پایداری شبکه را در شرایط بحرانی افزایش دهد (کاهش انحراف معیار از ۱۰/۰۷٪ در خط مبنا به ۸/۶۴٪ در مدل RL).

در یک جمع‌بندی تحلیلی، این دستاورد ثابت می‌کند که شبکه عصبی PPO به یک تعادل هوشمندانه دست یافته است؛ به گونه‌ای که درصد بسیار ناچیزی از کارایی در زمان‌های خلوت را فدا کرده تا در لحظات بحرانی شب، که سیستم‌های واکنشی دچار فروپاشی شده و جان بیماران در خطر جدی قرار می‌گیرد، تاب‌آوری، ثبات و برتری استراتژیک خود را به اثبات برساند.

۴-۵-۲- کارایی عملیاتی و کنترل پدیده هرج‌ومرج ناوگان

برای درک عمیق‌تر رفتار عامل RL در روز تعطیل، باید شاخص‌های عملیاتی و استهلاک ناوگان را بررسی نمود.

جدول ۴-۸: مقایسه شاخص‌های عملیاتی و بار کاری در ارزیابی متقاطع روز تعطیل (حاصل ۳۰ بار اجرای مستقل)

روش شبیه‌سازی	میانگین تعداد گره‌های بی‌دفاع	میانگین زمان بی‌دفاع ماندن (دقیقه)	مجموع زمان جابه‌جایی ناوگان (دقیقه)	انحراف معیار بار کاری (مأموریت)	حداکثر بار کاری یک آمبولانس (مأموریت)
خط مبنا (بدون هوش مصنوعی)	۴/۶۸	۱۸/۸	۳۵۷۶	۱/۵۳	۱۰
عامل هوشمند	۳/۹۷	۲۲/۹۸	۷۰۰	۱/۵۸	۱۰

بررسی داده‌های جدول ۴-۸، هوشمندی شبکه عصبی در مدیریت کلان منابع را به رخ می‌کشد. با وجود منطق سخت‌گیرانه در الگوریتم خط مبنا، این سیستم به دلیل ماهیت واکنشی و کوتاه‌بینانه خود، به محض ایجاد کوچک‌ترین خلأ پوششی در شبکه، اقدام به جابه‌جایی ناوگان می‌کند. این واکنش سریع و پیوسته به حفره‌های موقتی، منجر به بروز پدیده سرگردانی ناوگان شده و مجموع زمان جابه‌جایی را به ۳۵۷۶ دقیقه رسانده است.

در مقابل، عامل هوشمند توانسته است با کاهش چشمگیر زمان جابه‌جایی به تنها ۷۰۰ دقیقه (حدود ۸۰ درصد کاهش)، استهلاک و هدررفت انرژی سیستم را به حداقل ممکن برساند و در عین حال، میانگین گره‌های بی‌دفاع را نیز در سطح ۳/۹۷ محله (اندکی بهتر از خط مبنا با ۴/۶۸ محله) حفظ نماید. دلیل این دستاورد استراتژیک آن است که شبکه عصبی PPO، توانایی انجام تحلیل هزینه-فایده بلندمدت را آموخته است. در روزهای تعطیل که معابر در طول روز خلوت‌تر هستند، عامل RL با اعمال خویشتن‌داری استراتژیک، از واکنش شتاب‌زده به هر خلأ جزئی پرهیز می‌کند؛ چرا که می‌داند در شرایط ترافیک روان، آمبولانس‌های مجاور می‌توانند به سرعت وارد عمل شوند.

افزایش میانگین زمان بی‌دفاع ماندن (از ۱۸/۸ به ۲۲/۹۸ دقیقه) در مدل RL نیز ناشی از همین هوشمندی است؛ عامل ترجیح می‌دهد گره‌های کم‌اهمیت‌تر را برای مدتی رها کند، اما در عوض، آمبولانس‌ها را در هسته‌های بحرانی شهر ثابت و آماده نگه می‌دارد تا بتواند بر پیک سنگین ترافیک شبانه، که در شکل ۴-۶ برتری خود را نشان داد، غلبه نماید. این نتایج نشان می‌دهد که عامل هوشمند قادر است توازن دینامیک میان حفظ پوشش استراتژیک و کاهش شدید استهلاک ناوگان برقرار کند.

۴-۶- تحلیل حساسیت و تست تاب‌آوری سیستم (شرایط بحران و تقاضای

بالا)

در بخش‌های پیشین، کارایی عامل یادگیری تقویتی در شرایط استاندارد (روز کاری) و قابلیت انطباق آن در روزهای تعطیل به اثبات رسید. با این وجود، یکی از مهم‌ترین چالش‌ها در ارزیابی سیستم‌های پشتیبان تصمیم مبتنی بر هوش مصنوعی، بررسی میزان تعمیم‌پذیری صفر-شات^۱ آن‌هاست؛ بدین معنا که آیا مدلی که منحصراً برای شرایط عادی آموزش دیده است، قادر به حفظ منطق تصمیم‌گیری خود در مواجهه با شوک‌های پیش‌بینی‌نشده و تقاضای بحرانی هست یا خیر؟

به منظور پاسخ به این پرسش، یک تست استرس^۲ طراحی گردید. در این سناریو، بدون تغییر در ظرفیت فیزیکی ناوگان (۳۹ دستگاه آمبولانس)، حجم تقاضا به صورت مصنوعی به حدود ۷۰۰ حادثه در روز افزایش یافت. در این فاز، مدل PPO آموزش‌دیده در محیط روز کاری، مستقیماً و بدون هیچ‌گونه آموزش مجدد با ۳۰ بار اجرای متوالی بر روی محیط بحرانی آزمایش گردید.

۴-۶-۱- تحلیل فروپاشی سیستم و محدودیت‌های فیزیکی شبکه

افزایش بار کاری به حدود ۷۰۰ حادثه در ساده‌شده کلان‌شهر تهران، سیستم را وارد فاز اشباع منابع^۳ می‌کند. خروجی‌های کلان شبیه‌سازی برای هر دو رویکرد خط مبنای پویا و عامل هوشمند در جدول ۴-۹ تجمیع شده است.

جدول ۴-۹: مقایسه عملکرد کلی خط مبنای پویا و عامل هوشمند در شرایط تست استرس (حاصل ۳۰ بار اجرای مستقل)

شاخص	تعداد کل مأموریت‌ها	مأموریت‌های موفق (به‌موقع)	مأموریت‌های ناموفق (تأخیر)	نرخ پاسخ‌گویی به‌موقع	میانگین زمان پاسخ (دقیقه)
خط مبنای پویا	۷۰۸	۲۲۸	۴۸۰	٪۳۲/۲۳	۳۵/۳۶
عامل هوشمند	۷۰۸	۲۳۰	۴۷۸	٪۳۲/۴۶	۳۷/۷۱

^۱ Zero-Shot Generalization


^۲ Stress Test

^۳ Resource Saturation

نگاهی به نتایج جدول ۴-۹ نشان‌دهنده افت شدید عملکرد در کل سیستم است. سقوط نرخ پاسخ‌گویی به محدوده ۳۰ درصد، گواهی بر این واقعیت است که هیچ الگوریتم تصمیم‌گیری قادر به دور زدن محدودیت‌های فیزیکی ناوگان نیست. همانطور که مشاهده می‌شود نرخ موفقیت عامل هوشمند و خط مبنای پویا بسیار مشابه یکدیگر هستند.

۴-۶-۲- تحلیل تاب‌آوری در ساعات اوج بحران^۱

اما ارزش واقعی تصمیمات عامل هوشمند زمانی آشکار می‌شود که سیستم را به تفکیک بار ترافیکی و در بدترین شرایط ممکن (ترکیب تقاضای بالا و ترافیک سنگین) پس از ۳۰ بار اجرای مستقل ارزیابی کنیم (شکل ۴-۷ و جدول ۴-۱۰).



شکل ۴-۷: مقایسه تاب‌آوری خط مبنای پویا و عامل هوشمند در شرایط بحران به تفکیک ترافیک روان و ترافیک اوج

^۱ Peak Traffic Resilience

جدول ۴-۱۰: مقایسه آماری نرخ موفقیت در شرایط بحران تقاضا (حاصل ۳۰ بار اجرای مستقل)

شرایط ترافیکی	خط مبنا (میانگین $\pm$ انحراف معیار)	عامل هوشمند (میانگین $\pm$ انحراف معیار)	مقدار سطح معناداری
ساعات ترافیک روان	$0.5/0.7 \pm 0.46/0.88$	$0.6/0.52 \pm 0.44/0.11$	۰/۰۰۸
ساعات اوج ترافیک	$0.3/0.32 \pm 0.14/0.71$	$0.4/0.27 \pm 0.18/0.53$	<۰/۰۰۱

پیش از تحلیل شکل ۴-۷ و ارقام جدول ۴-۱۰، باید بر این واقعیت تلخ مهندسی تأکید نمود که در تقاضای هجومی و مفرط، کل سیستم اورژانس دچار اشباع و فروپاشی شده است و هیچ‌یک از دو روش نتوانسته‌اند عملکردی قابل قبول (از منظر استانداردهای طلایی سلامت) ارائه دهند. با این حال، تفاوت حیاتی در نحوه مدیریت این فروپاشی است. در ساعات ترافیک روان (که بحران صرفاً ناشی از تعدد حوادث است و مسیرها باز هستند)، سیستم خط مبنا با ثبت نرخ پاسخ‌گویی $0.46/0.88$ به شکلی جزئی از عامل هوشمند با نرخ $0.44/0.11$ پیشی گرفته است. آزمون آماری با $p = 0.008$ نشان می‌دهد که این افت نزدیک به ۳ درصدی در عامل هوشمند معنادار است. اما از منظر تئوری تصمیم‌گیری، این پدیده یک نقطه ضعف نیست؛ بلکه نشان‌دهنده‌ی یک فداکاری و خویشتن‌داری استراتژیک است. عامل RL با پیش‌بینی هجوم عظیم حوادث در ساعات پیش رو، ناوگان خود را در نقاط استراتژیک نگه داشته و از اعزام‌های دوربرد و تخلیه پایگاه‌های مرکزی خودداری می‌کند که این امر موجب افت محدود پاسخ‌گویی در ساعات خلوت می‌شود.


دست‌آورد این خویشتن‌داری و فاجعه‌ی اصلی سیستم‌های سنتی در ساعات پیک ترافیک رخ می‌دهد؛ جایی که بحران تقاضا با بحران ترافیک سنگین تلاقی می‌کند. در این تقاطع بحرانی، سیستم واکنشی خط مبنا کاملاً فلج شده و نرخ موفقیت آن به عدد ناچیز $0.14/0.71$ سقوط می‌کند. در همین شرایط، عامل هوشمند با اتکا به استقرار پیشگیرانه‌ای که از پیش اتخاذ کرده بود، شریان‌های امدادسانی را تا حدودی حفظ کرده و موفق می‌شود این نرخ را به $0.18/0.53$ ارتقا دهد.

اگرچه عدد $0.18/0.53$ به خودی خود نشان‌دهنده شرایطی وخیم در اوج بحران است، اما از منظر تحلیل داده، ارتقای عملکرد از $0.14/0.71$ به $0.18/0.53$ به معنای یک بهبود نسبی حدوداً ۲۶ درصدی است. به عبارت دیگر، عامل هوشمند توانسته است در بدترین شرایط ممکن، ۲۶ درصد بیمار بیشتر را نسبت به ظرفیت سیستم سنتی در همان ساعات، به‌موقع پوشش دهد. آزمون آماری با ثبت مقدار $p < 0.001$ به صورت قطعی

اثبات می‌کند که این جهش و تاب‌آوری در دل بحران، مطلقاً تصادفی نبوده است. مقادیر انحراف معیار نیز نشان می‌دهند که در زمان فروپاشی ترافیکی، نوسانات در هر دو سیستم وجود دارد (۳/۳۲٪ برای خط مبنا و ۴/۲۷٪ برای عامل هوشمند) که بازتاب‌دهنده‌ی آشوب ذاتی در شرایط بحران است؛ اما این دستاورد در نهایت نشان می‌دهد که هوش مصنوعی در نقش یک فرمانده بحران با اجرای مکانیزم تریاژ مکانی، منابع به‌شدت محدود را بسیار هوشمندانه‌تر و بهینه‌تر از رویکردهای مکاشفه‌ای تخصیص می‌دهد.

۴-۶-۳- کارایی عملیاتی و جلوگیری از سرگردانی مطلق ناوگان

در شرایطی که تقاضا از عرضه پیشی می‌گیرد، سیستم‌های مبتنی بر قوانین صلب معمولاً دچار هرج‌ومرج و فروپاشی منطقی می‌شوند. این پدیده را می‌توان در نمودار تعداد محله‌های بی‌دفاع (شکل ۴-۸) و شاخص‌های عملیاتی (جدول ۴-۱۱) مشاهده کرد.



شکل ۴-۸: روند تغییرات مناطق بی‌دفاع در شرایط بحران (مدل RL). پرش‌های نمودار به سمت مرز ۵۵ محله، نشان‌دهنده اشباع کامل ناوگان است.

چنانچه در شکل ۴-۸ مشاهده می‌شود، حتی با مدیریت هوش مصنوعی، تعداد گره‌های خارج از پوشش در ساعات بحرانی به بیش از ۵۰ محله می‌رسد که نشان‌دهنده کمبود مطلق منابع است. اما تفاوت دو سیستم در نحوه برخورد با این کمبودهاست.

جدول ۴-۱۱: مقایسه شاخص‌های عملیاتی و استهلاک در شرایط تست استرس (حاصل ۳۰ بار اجرای مستقل)

روش شبیه‌سازی	میانگین تعداد گره‌های بی‌دفاع	میانگین زمان بی‌دفاع ماندن (دقیقه)	مجموع زمان جابه‌جایی ناوگان (دقیقه)	انحراف معیار بار کاری (مأموریت)	حداکثر بار کاری یک آمبولانس (مأموریت)
خط مبنا (بدون هوش مصنوعی)	۳۰/۵	۱۶/۱۱	۵۴۴۹	۱/۰۵	۲۰
عامل هوشمند	۲۹/۹۸	۱۵/۶۱	۴۶۳۸	۰/۸۲	۱۹

با بررسی جدول ۴-۱۱ متوجه می‌شویم که الگوریتم خط مبنای پویا، با مشاهده ده‌ها محله بی‌دفاع، دچار پدیده سرگردانی ناوگان شده و آمبولانس‌های محدود آزاد را پیوسته جابه‌جا کرده است تا رکوردی مخرب معادل ۵۴۴۹ دقیقه زمان جابه‌جایی را ثبت کند.

در مقابل، شبکه عصبی PPO با درک وضعیت اشباع، از جابه‌جایی‌های هیجانی پرهیز کرده و مجموع زمان جابه‌جایی را در عدد ۴۶۳۸ دقیقه (حدود ۱۵ درصد کمتر) کنترل نموده است. هوش مصنوعی با وجود این کاهش در جابه‌جایی، به لطف انتخاب‌های هوشمندانه‌تر، توانسته است میانگین گره‌های بی‌دفاع را نیز نسبت به سیستم سنتی مقداری کاهش دهد.

تست حساسیت و شرایط بحران به وضوح نشان داد که شبکه عصبی آموزش‌دیده، از پایداری و قدرت تعمیم بسیار بالایی برخوردار است. در یک محیط بحرانی که سیستم‌های سنتی دچار فروپاشی منطقی و سرگردانی می‌شوند، عامل RL با اعمال خویشتن‌داری استراتژیک، توزیع بهینه منابع، و تریاژ مکانی در ساعات اوج ترافیک، توانست مفهوم افت برانزده را به بهترین شکل ممکن پیاده‌سازی نماید.

۴-۷- شناسایی گلوگاه‌های عملیاتی و تحلیل آسیب‌پذیری^۱

یکی از اهداف غایی توسعه سیستم‌های پشتیبان تصمیم مبتنی بر هوش مصنوعی، فراتر رفتن از اتوماسیون صرف و دستیابی به دانش عملیاتی^۲ است. اگرچه در بخش‌های پیشین برتری شبکه عصبی PPO در مدیریت ناوگان و تریاژ بیماران اثبات گردید، اما هیچ سیستمی با منابع محدود، عاری از شکست نیست.


^۱ Defense Analytics

^۲ Actionable Intelligence

صرف بیان تعداد مأموریت‌های ناموفق برای مدیران شهری کافی نیست؛ بلکه تحلیل ریشه‌ای این تأخیرها و بررسی تقاطع آن‌ها با نقشه پوشش شهر، نشان می‌دهد که آیا سیستم به دلیل کمبود ایستگاه شکست خورده است، یا به دلیل ترافیک و اشباع تقاضا. در این بخش، رفتار سیستم در هر سه سناریو، بر اساس داده‌های تجمیع‌شده از ۳۰ اجرای مستقل، از منظر زمانی و مکانی زیر ذره‌بین قرار گرفته است.

۴-۷-۱- تحلیل توزیع زمانی آسیب‌پذیری

به منظور درک عمیق‌تر از رفتار سیستم در طول شبانه‌روز، میانگین توزیع ساعتی مأموریت‌های ناموفق (تأخیردار) در هر روز استخراج گردید. بررسی این توزیع همراه با نسبت‌سنجی آن با کل شکست‌های روزانه، نشان می‌دهد که شبکه عصبی در چه بازه‌هایی و به چه دلایلی، با وجود تمام تلاش‌های پیشگیرانه، تسلیم جبر فیزیکی شبکه ترافیک و حجم تقاضا می‌شود.



شکل ۴-۹: توزیع ساعتی مأموریت‌های ناموفق (تأخیردار؛ الف) روز کاری، (ب) روز تعطیل، (ج) بحران.

تحلیل مقایسه‌ای، درصدی و علت‌وشلولی شکل ۴-۹ حقایق کلیدی زیر را نمایان می‌سازد.

در روز کاری استاندارد (نمودار الف)، الگوی شکست به شدت دوقطبی است. در ساعات میانی روز (از ساعت ۹ صبح تا ۱۵ عصر)، سیستم تحت هدایت RL به طور میانگین کمتر از ۱ خطای محاسباتی یا تأخیر در هر ساعت دارد. این امر ثابت می‌کند که هوش مصنوعی در شرایطی که گراف شهری کاملاً قفل نیست، عملکردی بی‌نقص دارد. اما اوج آسیب‌پذیری دقیقاً در ساعات پیک ترافیک رخ می‌دهد؛ به طوری که در پیک صبحگاهی (ساعات ۷ و ۸)، از مجموع ۵۴ مأموریت ناموفق، به طور میانگین، در طول ۲۴ ساعت، به طور متوسط حدود ۱۵ شکست (حدود ۰.۲۷٪)، و در پیک عصرگاهی (ساعات ۱۷ الی ۱۹) به طور میانگین بیش از ۲۶ شکست (حدود ۰.۴۸٪) متمرکز در روز ثبت می‌شود. این یعنی در پیک‌های رفت‌وآمد کاری، سرعت متوسط

ناوگان در خیابان‌ها به قدری افت می‌کند که حتی با بهترین استقرار از پیش تعیین‌شده نیز، زمان رسیدن به بالین بیمار از مرز ۸ دقیقه فراتر می‌رود.


در روز تعطیل (نمودار ب)، الگوی آسیب‌پذیری کاملاً منطبق با تغییرات زیستی شهروندان به ساعات عصر و شب منتقل شده است. از آنجایی که در روز تعطیل سفرهای صبحگاهی حذف می‌شوند، از نیمه‌شب تا ساعت ۱۱ صبح تقریباً هیچ شکست معناداری ثبت نشده است. اما از ساعت ۱۸ الی ۲۱، یک قله‌ی هجومی و متراکم در نمودار شکل می‌گیرد؛ به گونه‌ای که ساعت ۱۹ به تنهایی با ثبت میانگین بیش از ۶ مأموریت ناموفق (۲۵ درصد کل)، مرگبارترین ساعت روز تعطیل محسوب می‌شود. این بازه‌ی زمانی مصادف با اوج ترافیک تفریحی، بازگشت شهروندان از مراکز خرید و تفرجگاه‌ها، و افزایش تصادفات شدید در سطح معابر است.

در شرایط بحران با ۷۰۰ تقاضا (نمودار ج)، از مجموع ۴۷۸ تأخیر، به طور میانگین، توزیع شکست‌ها به شکل وحشتناکی در کل روز پراکنده شده و از حالت قله‌های نقطه‌ای خارج شده است. در ساعات پیک ۷ الی ۸ صبح و ۱۷ الی ۱۹ عصر، آمار تأخیرها از مرز ۴۰ الی ۴۶ مأموریت از دست رفته در یک ساعت (حدود ۱۰ درصد از کل شکست‌های روز در یک ساعت) عبور می‌کند.

نکته‌ی بسیار حیاتی در این نمودار، پدیده سرریز صف است؛ به این معنا که وقتی در پیک صبحگاهی حجم تقاضا به شدت بالا می‌رود، ظرفیت ناوگان اشباع شده و صفی از بیماران منتظر تشکیل می‌شود. این صف انباشته‌شده به ساعات بعدی منتقل می‌شود؛ به همین دلیل مشاهده می‌کنیم که برخلاف روز عادی، در ساعات خلوت‌تر روز (مثل ساعات ۱۰ الی ۱۱ یا ساعات پایانی شب ۲۰ الی ۲۳) نیز سیستم به طور متوسط در هر ساعت ۲۰ الی ۳۶ مأموریت ناموفق انباشته‌شده دارد. این نمودار از منظر تحلیل سیستم‌ها ثابت می‌کند که در شرایط بحران، گلوگاه شبکه صرفاً ترافیک محلی نیست، بلکه اتمام مطلق ظرفیت سرویس‌دهی ناوگان در کل شبانه‌روز است.

۴-۷-۲- تحلیل عمیق مکانی: تقاطع پوشش‌دهی و نرخ شکست

مهم‌ترین و پیچیده‌ترین خروجی تحلیلی برای برنامه‌ریزان شهری، درک تفاوت میان در معرض خطر بودن و وقوع شکست است. برای این منظور، دو شاخص بیشترین زمان فاقد پوشش بودن^۱ و بیشترین تعداد شکست عملیاتی^۲ در گره‌های شهری بر اساس میانگین ۳۰ روز شبیه‌سازی استخراج گردید.



شکل ۴-۱۰: مقایسه مناطق دارای بیشترین آسیب‌پذیری تئوریک (بالا - زمان عدم پوشش) در تقاطع با مناطق دارای بیشترین شکست عملیاتی (پایین - تعداد مأموریت تأخیردار).

با بررسی تطبیقی نمودارهای بالا و پایین در شکل ۴-۱۰، در هر سه سناریو، یک توزیع سه‌گانه‌ی بسیار معنادار در رفتار شبکه و تصمیمات عامل RL کشف می‌شود. گره‌های شهری از منظر آسیب‌پذیری به سه دسته کاملاً مجزا تقسیم می‌شوند:

گروه اول که مناطق فداشده‌ی استراتژیک هستند. گره‌هایی مانند حکیمیه، ازگل، فرمانیه و مهرآباد در صدر لیست طولانی‌ترین زمان‌های بی‌دفاع بودن قرار دارند. به عنوان مثال، حکیمیه در روز کاری به طور میانگین حدود ۴۸۰ دقیقه از شبانه‌روز خارج از پوشش ۸ دقیقه‌ای رها شده است. اما نام این محله‌ها در لیست بیشترین مأموریت‌های شکست‌خورده دیده نمی‌شود. این پدیده تبلور یادگیری ماشین در اجرای تریاژ مکانی است. هوش مصنوعی آموخته است که این محله‌ها غالباً حاشیه‌ای بوده و نرخ تراکم تقاضا در آن‌ها پایین است؛

¹ Vulnerability

² Actual Fails

³ Sacrificed Nodes

لذا به صورت آگاهانه آن‌ها را ساعت‌ها بی‌دفاع می‌گذارد تا ناوگان را در مرکز شهر حفظ کند، زیرا محاسبه کرده است که ریسک عدم پوشش آن‌ها، کمتر منجر به وقوع تأخیر در واقعیت می‌شود.

گروه دوم که نقاط داغ اشباع‌شده^۱ هستند. در مقابل گروه اول، محله‌هایی مانند بازار، مرزداران، بهارستان و انقلاب (به‌ویژه در سناریوی بحران با ۷۰۰ تقاضا)، بیشترین آمار تأخیر و شکست واقعی را ثبت کرده‌اند (به عنوان مثال ثبت میانگین ۱۴ الی ۱۵ شکست روزانه در مرزداران و بازار در شرایط بحران). نکته قابل تأمل این است که این محله‌ها اصلاً در لیست مناطق فاقد پوشش حضور ندارند.

علت این امر، مبحث تراکم تقاضا و کمبود ظرفیت مازاد^۲ است. هوش مصنوعی این گره‌های متراکم تجاری و مرکزی را همواره تحت پوشش نگه داشته است؛ اما گاهی ۲ الی ۳ حادثه با فاصله زمانی بسیار کوتاه در آن‌ها رخ می‌دهد. در نتیجه، آمبولانس مستقر در محل به حادثه اول اعزام می‌شود، اما برای حوادث همزمان بعدی، سیستم مجبور است آمبولانسی از فاصله‌ای دورتر و از میان ترافیک سنگین اعزام کند که منجر به ثبت شکست می‌گردد. در این محله‌ها، مشکل نبود پوشش پایه نیست، بلکه اتمام فیزیکی ناوگان در لحظات شوک تقاضاست.

گروه سوم که نقاط کور هستند. مهم‌ترین کشف در میانگین‌گیری ۳۰ روزه، گره‌هایی نظیر شهرک استقلال، چیتگر و یافت‌آباد هستند که در هر سه سناریو، هم در لیست بی‌دفاع‌ترین مناطق و هم در لیست پرشکست‌ترین مأموریت‌ها به صورت مشترک حضور دارند. به عنوان نمونه، شهرک استقلال در تقاضای ۷۰۰ حادثه، بیش از ۱۲۰۰ دقیقه از شبانه‌روز بی‌دفاع است و در روز تعطیل نیز رکورددار بالاترین نرخ شکست است.

حضور مشترک این گره‌ها در هر دو لیست نشان می‌دهد که عامل هوشمند تمام تلاش خود را برای جابه‌جایی ناوگان به کار بسته است، اما به دلیل ایزوله بودن این مناطق در گراف ترافیکی، مسافت بسیار دور آن‌ها از هسته مرکزی و فقدان پایگاه فیزیکی در آن حوالی، توانایی حفظ پوشش پایدار در آن‌ها را ندارد.

^۱ Overwhelmed Hotspots


^۲ Lack of Surge Capacity

آمار تأخیرها و شکست‌های به تصویر کشیده شده در شکل ۴-۱۰، نشان‌دهنده‌ی ضعف مدل نیستند؛ بلکه این خروجی‌ها نمایانگر بهینه‌ترین حالت ممکن ریاضی^۱ برای یک ناوگان محدود متشکل از ۳۹ آمبولانس در یک کلان‌شهر هستند. بدون حضور عامل هوشمند PPO و فقدان سیاست‌های بازاستقرار پیشگیرانه، سیستم دچار فروپاشی زودهنگام می‌شد و آمار تلفات در هسته‌ی مرکزی شهر به مراتب فاجعه‌بارتر از شرایط فعلی بود. عامل هوشمند با توزیع هوشمندانه و تریاژ این کمبودهای اجتناب‌ناپذیر، آسیب‌ها را کمینه کرده است. ارائه راهکارهای اجرایی جهت رفع این محدودیت‌های فیزیکی، در فصل پنجم مورد بحث قرار خواهد گرفت.

۴-۸- تحلیل پاداش تجمعی شبکه عصبی در سناریوهای سه‌گانه

در ارزیابی الگوریتم‌های یادگیری تقویتی، بررسی شاخص‌های عملیاتی نظیر درصد موفقیت، تنها نیمی از رفتار سیستم را تشریح می‌کند. برای اثبات اینکه شبکه عصبی PPO واقعاً پویایی‌های محیط را درک کرده و تصمیماتش تصادفی نیست، باید نشان داد که عامل توانسته است تابع هدف^۲ را درک کرده و پاداش تجمعی^۳ خود را مدیریت کند.

از آنجایی که در این پژوهش، یک مدل واحد (آموزش‌دیده در محیط روز کاری) برای ارزیابی هر سه سناریو مورد استفاده قرار گرفته است، مقایسه‌ی روند انباشت پاداش‌ها در این سه محیط، درک استراتژیک بسیار عمیقی از نحوه واکنش هوش مصنوعی به تغییرات توزیع داده‌ها ارائه می‌دهد.



شکل ۴-۱۱: روند میانگین پاداش تجمعی عامل هوشمند PPO در طول یک شبانه‌روز (حاصل ۳۰ بار اجرا؛ الف) روز کاری، ب) روز تعطیل، ج) بحران.

با تحلیل دقیق و تطبیقی شکل ۴-۱۱، هوشمندی و منطق رفتاری شبکه عصبی به وضوح اثبات می‌گردد. روند هر نمودار حاوی پیام‌های مهندسی متمایزی است.

^۱ Mathematical Optimum

^۲ Objective Function

^۳ Cumulative Reward

نمودار الف (روز کاری)، مهار خسارت و کمینه‌سازی هزینه‌ها را نشان می‌دهد. این نمودار، محیط بومی عامل RL را در مقیاس ۳۰ روزه نشان می‌دهد. برخلاف تصور اولیه مبنی بر صعود خطی پاداش‌ها، مشاهده می‌شود که میانگین پاداش تجمعی در محدوده‌ی منفی (تا حدود ۶۵,۰۰۰-) نوسان می‌کند. از منظر تئوری کنترل، این نمودار یک دستاورد عالی است؛ زیرا تابع پاداش سیستم به گونه‌ای طراحی شده که تأخیرها و بیماران در صف‌مانده جرایم سنگینی به همراه دارند. در میانگین‌گیری ۳۰ روزه، گرفتار شدن تعدادی از آمبولانس‌ها در پیک ترافیک صبحگاهی (دقیقه ۱۰۰ تا ۲۰۰) و پیک عصرگاهی (دقیقه ۷۰۰ تا ۹۰۰) اجتناب‌ناپذیر است که منجر به افت نمودار در این دو مقطع می‌شود. اما هنر عامل هوشمند این است که پس از هر شوک ترافیکی، شیب سقوط را متوقف کرده و در ساعات آرام‌تر، با جابه‌جایی‌های استراتژیک روند نمودار را تثبیت و حتی رو به بالا هدایت می‌کند. این رفتار ثابت می‌کند که عامل به جای جستجوی پاداش‌های غیرواقعی، در نقش یک سیستم کمینه‌ساز هزینه عمل کرده و پایداری شبکه را حفظ می‌نماید.


نمودار ب (روز تعطیل)، فرصت‌طلبی و انطباق سریع در محیطی جدید با پویایی متفاوت را نشان می‌دهد. این نمودار یکی از شگفت‌انگیزترین رفتارهای عامل RL را در ارزیابی متقاطع به تصویر می‌کشد. در ساعات اولیه روز (به دلیل خلوتی ممتد معابر در روزهای تعطیل)، عامل با فرصت‌طلبی، مأموریت‌ها را با موفقیت و پیش از موعد انجام داده و پاداش‌های مثبت متوالی کسب می‌کند (صعود تا مرز ۶۰,۰۰۰). اما در حوالی دقیقه ۸۰۰ الی ۱۰۰۰ (اوج ترافیک تفریحی و حوادث شدید شامگاهی روز تعطیل)، عامل ناگهان با یک الگوی غیربومی غافلگیر شده و نمودار دچار یک افت مقطعی ۳۰ هزار واحدی می‌شود. نکته‌ی کلیدی در قدرت انطباق مدل نهفته است؛ شبکه پس از این شوک، فروپاشی را متوقف کرده و مجدداً با استقرارهای پیش‌دستانه، پاداش را رو به بالا هدایت کرده و روز را با پاداش مثبت بیش از ۷۰,۰۰۰ به پایان می‌رساند. این نمودار ثابت می‌کند که عامل هوشمند قادر به اصلاح در لحظه‌ی استراتژی‌های خود است.

نمودار ج (حالت بحران)، انعکاس ریاضی فروپاشی فیزیکی در محیط اشباع و تست استرس را نشان می‌دهد. در این نمودار شاهد یک سقوط آزاد مطلق به قعر ناحیه قرمز رنگ (تا مرز منفی ۹۰۰,۰۰۰ واحد) هستیم. اگرچه عامل RL در این سناریو توانست از نظر نرخ پاسخ‌گویی عملکردی به مراتب بهتر از روش سنتی

ثبت کند، اما نمودار پاداش به شدت منفی است. از منظر مهندسی سیستم‌ها، این خروجی بزرگ‌ترین اثبات برای صحت معماری تابع پاداش در این پژوهش است.

تابع پاداش به گونه‌ای طراحی شده است که جان انسان‌ها در اولویت باشد. در تقاضای ۷۰۰ حادثه، صف‌های انتظار به سمت بی‌نهایت میل می‌کنند و جریمه‌های تصاعدی ناشی از بیماران منتظر، به قدری سنگین می‌شود که بر تمام پاداش‌های موفقیت‌آمیز غلبه می‌کند. این سقوط ریاضی، انعکاس دقیق پدیده ناپایداری در تئوری صف است و ثابت می‌کند که هوش مصنوعی نمی‌تواند معجزه‌ای برای دور زدن کمبود فیزیکی منابع خلق کند، بلکه تنها می‌تواند این جریمه‌های میلیونی را نسبت به رویکردهای مکاشفه‌ای مینیمم نماید.

برای اثبات قطعی این موضوع که منفی شدن نمودار پاداش در روز کاری به معنای شکست مدل نیست، بلکه نشان‌دهنده محدودیت‌های فیزیکی سیستم است، پاداش‌های تجمعی سیستم خط مبنا (بدون هوش مصنوعی) دقیقاً با همان تابع جرایم محاسبه گردید. نمودار مقایسه‌ای زیر (شکل ۴-۱۲)، میانگین پاداش هر دو مدل را پس از ۳۰ روز شبیه‌سازی مستقل به تصویر می‌کشد.



شکل ۴-۱۲: اثبات کمینه‌سازی هزینه‌ها؛ مقایسه پاداش تجمعی عامل هوشمند در برابر خط مبنا.

بررسی شکل ۴-۱۲ ارزش واقعی و ریاضی عامل هوشمند را در محیط اورژانس اثبات می‌کند. در این نمودار، خط قرمز (سیستم واکنشی خط مبنا) با شروع پیک‌های ترافیکی به دلیل از دست دادن زمان‌های طلایی و انباشت بیماران منتظر، دچار سقوطی فاجعه‌بار شده و پاداش آن تا مرز منفی ۱۴۰،۰۰۰ واحد افت می‌کند. در مقابل، خط سبز (عامل هوشمند) نشان می‌دهد که شبکه عصبی چگونه با استقرار پیشگیرانه ناوگان، موفق شده است شیب این سقوط را مهار کند.

ناحیه‌ی سایه‌خورده‌ی سبز رنگ محصور بین دو نمودار، تجسم فیزیکی جرایم و خساراتی است که هوش مصنوعی از وقوع آن‌ها جلوگیری کرده است. این فاصله معنادار به روشنی نشان می‌دهد که اگرچه سیستم به دلیل ترافیک شهری ناگزیر به دریافت جریمه است، اما عامل PPO توانسته است ده‌ها هزار واحد جریمه‌ی ناشی از تأخیر را نسبت به الگوریتم‌های سنتی دفع کند.

تحلیل پاداش‌های تجمعی نشان داد که عامل هوشمند PPO در این پژوهش، از یک منطق کور پیروی نمی‌کند؛ بلکه به عنوان یک تحلیل‌گر هزینه-فایده^۱ عمل می‌کند که قادر است در محیط‌های استاندارد خسارات ترافیکی را کمینه کند، در محیط‌های متغیر (روز تعطیل) به سرعت خود را تطبیق دهد، و در محیط‌های بحرانی، واقعیت‌های فیزیکی کمبود منابع را به صورت ریاضی بازتاب دهد.

^۱ Cost-Benefit Analyzer

فصل ۵- نتیجه‌گیری و پیشنهادات

مدیریت و تخصیص بهینه منابع در سیستم‌های اورژانس پیش‌بیمارستانی، یکی از پیچیده‌ترین مسائل در حوزه تحقیق در عملیات و کنترل سیستم‌های تصادفی است. در کلان‌شهرهای پرتراکم نظیر تهران، نوسانات شدید ترافیکی، توزیع نامتقارن زمانی و مکانی تقاضا، و محدودیت فیزیکی ناوگان امدادی، کارایی روش‌های سنتی تخصیص منابع را به شدت کاهش می‌دهد. همان‌طور که در فصول پیشین مورد بررسی قرار گرفت، رویکردهای مکاشفه‌ای مبتنی بر رویکرد واکنشی و اعزام نزدیک‌ترین آمبولانس، به دلیل فقدان نگاه پیش‌بینانه و ناتوانی در ارزیابی وضعیت آینده‌ی شبکه، در ساعات اوج تقاضا دچار پدیده سرگردانی ناوگان و از دست رفتن زمان‌های طلایی امدادسانی می‌شوند.

به منظور غلبه بر این چالش بنیادین، رساله‌ی حاضر با هدف طراحی، شبیه‌سازی و پیاده‌سازی یک سیستم پشتیبان تصمیم هوشمند مبتنی بر یادگیری تقویتی عمیق تدوین گردید. در این راستا، با بهره‌گیری از معماری شبکه عصبی PPO و مدل‌سازی تقریبی گراف ترافیکی شهر تهران، همراه با لحاظ نمودن پارامترهای واقع‌گرایانه‌ای نظیر استهلاک، خرابی تصادفی و تفاوت اهمیت بالینی حوادث، یک عامل تصمیم‌گیر مرکزی توسعه یافت. این عامل هوشمند آموزش دید تا به جای واکنش صرف به حوادث رخ داده، با درک الگوهای پنهان شهری، فرامین بازاستقرار پیشگیرانه و خویشتن‌داری استراتژیک را با هدف بیشینه‌سازی پاداش تجمعی صادر نماید.

در فصل حاضر، به عنوان ایستگاه پایانی این پژوهش، تلاش می‌شود تا تصویری جامع و یکپارچه از دستاوردها و خروجی‌های شبیه‌سازی ارائه گردد. بر این اساس، ابتدا نتایج کلیدی به‌دست‌آمده از تقابل عامل هوشمند با الگوریتم خط مبنا در سناریوهای سه‌گانه (روز کاری استاندارد، ارزیابی متقاطع در روز تعطیل و

تست استرس در شرایط بحران) که با اتکا بر میانگین‌گیری‌های ۳۰ روزه و آزمون‌های معناداری آماری به اثبات قطعی رسیده‌اند، جمع‌بندی می‌گردد. سپس، با ترجمه‌ی این دستاوردهای الگوریتمی به دانش عملیاتی، پیشنهادات کاربردی و ملموسی برای مدیران و سیاست‌گذاران اورژانس شهری ارائه خواهد شد. در پایان نیز، با بیانی شفاف از محدودیت‌های ذاتی مدل‌سازی در این پژوهش، مسیرهای روشن و نوآورانه‌ای برای توسعه‌ی تحقیقات آتی در این حوزه ترسیم می‌گردد.

۵-۱- دستاوردها و نتایج اصلی پژوهش

بررسی و تحلیل خروجی‌های شبیه‌سازی در فصول پیشین، کارایی و برتری سیستم پشتیبان تصمیم توسعه‌یافته در این پژوهش را نسبت به الگوریتم‌های سنتی و مکاشفه‌ای رایج به اثبات رساند. این سیستم که در قالب یک عامل هوشمند هیبریدی، متشکل از ترکیب الگوریتم‌های اعزام شرطی و شبکه عصبی یادگیری تقویتی عمیق (PPO) برای بازاستقرار پیشگیرانه، طراحی شده است، دستاوردهای کلیدی متعددی را در پنج محور اصلی به همراه داشته است که در ادامه تبیین می‌گردند.

نخستین دستاورد این پژوهش، اثبات برتری رویکرد پیش‌بینانه بر رویکرد واکنشی در مهار ترافیک پیوسته در سناریوی روز کاری استاندارد است. عامل هوشمند هیبریدی با درک الگوهای ترافیکی، توانست از طریق بازاستقرار استراتژیک، میانگین نرخ موفقیت کل شبکه را با بهبودی بالغ بر ۱۱ درصد، به مرز ۸۶/۶ درصد ارتقا دهد. این برتری به ویژه در ساعات اوج ترافیک با ثبت نرخ پاسخ‌گویی ۷۰/۴۷ درصد در برابر ۵۵/۳۵ درصد خط مبنا (با سطح معناداری آماری $p < 0.001$) به اوج خود رسید. دستاورد شگرف‌تر در این بخش، دستیابی به این سطح از ارتقای عملکرد همراه با کاهش چشمگیر (نزدیک به ۷۴ درصدی) در مجموع زمان جابه‌جایی ناوگان نسبت به روش سنتی بود؛ امری که نشان‌دهنده توقف کامل پدیده سرگردانی ناوگان و مدیریت بی‌نظیر استهلاک فیزیکی در شرایط عادی است. همچنین، هوش مصنوعی توانست میانگین محله‌های بی‌دفاع شهر را در طول شبانه‌روز به طور مؤثری از ۱۰/۱۶ به ۹/۲۴ محله کاهش دهد.

دومین دستاورد برجسته‌ی این شبکه عصبی، اثبات توانایی تعمیم‌پذیری و تطبیق با شرایط آموزش‌ندیده در ارزیابی متقاطع روز تعطیل بود. در این سناریو که دارای رژیم ترافیکی کاملاً متفاوتی است، عامل هیبریدی با اعمال هوشمندانه‌ی خویشتن‌داری استراتژیک، متوجه روان بودن ترافیک در ساعات ابتدایی و میانی روز گردید و مجموع زمان جابه‌جایی را با کاهشی ۸۰ درصدی به ۷۰۰ دقیقه رساند. این استراتژی باعث شد تا ناوگان امدادی برای پیک ترافیک سنگین و غیرمنتظره‌ی شامگاهی (ساعات ۱۸ الی ۲۲) تازه‌نفس و در دسترس باقی بماند. در نتیجه‌ی این سیاست، در اوج ترافیک شب تعطیل، هوش مصنوعی با موفقیت ۷۶/۶۷ درصد بر سیستم سنتی (با موفقیت ۶۷/۰۱ درصد) غلبه کرد و نشان داد که می‌تواند درصد ناچیزی از کارایی در زمان‌های خلوت را فدا کند تا در لحظات بحرانی برتری خود را حفظ نماید.

سومین دستاورد، پیاده‌سازی مفهوم افت برازنده و حفظ تاب‌آوری در مرز فروپاشی شبکه (تست استرس با حدود ۷۰۰ حادثه) است. محدودیت‌های فیزیکی ناوگان در این حجم از تقاضا، لاجرم باعث افت عملکرد کل سیستم می‌شود؛ با این وجود، هنر هوش مصنوعی در نحوه مدیریت این فروپاشی نمایان گردید. در حالی که سیستم سنتی در ساعات پیک بحران کاملاً فلج شده و نرخ موفقیت آن به ۱۴/۷۱ درصد سقوط کرد، عامل هوشمند توانست با حفظ جریان‌های امدادی در نقاط استراتژیک، این نرخ را در عدد ۱۸/۵۳ درصد تثبیت کند. این ارتقا که با قطعیت ریاضی همراه بود، نشان‌دهنده یک بهبود نسبی ۲۶ درصدی نسبت به خط مبنا، دقیقاً در سخت‌ترین و حیاتی‌ترین تقاطع بحران ترافیک و تقاضاست. هوش مصنوعی با درک اشباع سیستم، به جای واکنش‌های منفعلانه، ظرفیت به‌شدت محدود ناوگان را بسیار بهینه‌تر از رویکردهای مکاشفه‌ای تخصیص داد.

چهارمین دستاورد، کشف استراتژی تریاژ مکانی و شناسایی گلوگاه‌های ساختاری از طریق تحلیل‌های دفاعی در میانگین ۳۰ اجرای متوالی است. تحلیل ریشه‌ای خلأهای پوششی و شکست‌های عملیاتی منجر به دسته‌بندی گره‌های شهری به سه گروه متمایز گردید. بررسی‌ها نشان داد که عامل RL برای حفظ پوشش مناطق پرتراکم مرکزی (نقاط داغ اشباع‌شده نظیر بازار و مرزداران)، به صورت آگاهانه مناطق حاشیه‌ای (نقاط فداشده‌ی استراتژیک نظیر حکیمیه و ازگل) را ساعت‌ها فاقد پوشش می‌گذارد تا از فروپاشی کل شبکه

جلوگیری کند. همچنین، شناسایی نقاط کور ساختاری (نظیر شهرک استقلال و چیتگر) که در هر سه سناریو رکورددار بیشترین تأخیر و عدم پوشش بودند، ثابت نمود که شکست‌های رخ داده در هسته مرکزی و نواحی حاشیه‌ای معلول ضعف الگوریتم نیست، بلکه ناشی از محدودیت فیزیکی، ایزوله بودن گراف ترافیکی و کمبود ظرفیت پاسخگویی به شوک‌های تقاضا در زمان وقوع حوادث همزمان است.

در نهایت، پنجمین دستاورد این پژوهش، اثبات همگرایی ریاضی و انعطاف‌پذیری تابع پاداش در بستر فرآیند تصمیم‌گیری مارکوف بود. بررسی روند پاداش‌های تجمعی نشان داد که شبکه عصبی به جای جستجوی پاداش‌های مثبت و غیرواقعی، در نقش یک کمینه‌ساز هزینه ظاهر شده است. در روز کاری، عامل با متوقف کردن شیب سقوط جرایم در ساعات پیک، توانست ده‌ها هزار واحد جریمه‌ی ناشی از تأخیر را نسبت به الگوریتم خط مبنا مهار کند. در روز تعطیل، بازیابی سریع نمودار پس از یک شوک ترافیکی مقطعی، قدرت انطباق در لحظه‌ی مدل را ثابت کرد. مهم‌تر از همه، سقوط آزاد و به‌شدت منفی پاداش در شرایط بحران (تست استرس)، مهر تأییدی بر واقع‌گرایی و منطق انسانی این الگوریتم بود؛ چرا که ثابت نمود تابع هدف به‌شدت پیرو تئوری صف و اولویت جان بیماران است و در زمان فروپاشی فیزیکی ناوگان، سیستم تنها تلاش می‌کند جرایم و خسارات جانی را نسبت به سایر الگوریتم‌های سنتی کمینه نماید.

۵-۲- پیشنهادات کاربردی و مدیریتی

توسعه‌ی سیستم‌های پشتیبان تصمیم مبتنی بر هوش مصنوعی، علاوه بر خودکارسازی فرآیندها، رسالت تولید دانش عملیاتی برای سیاست‌گذاران را بر عهده دارد. در وهله‌ی اول، ضروری است تأکید گردد که آمار تأخیرها و شکست‌های ثبت‌شده در سناریوهای بحرانی این پژوهش، نشان‌دهنده‌ی ضعف مدل نیستند؛ بلکه این خروجی‌ها نمایانگر بهینه‌ترین حالت ممکن ریاضی برای یک ناوگان محدود متشکل از ۳۹ آمبولانس در کلان‌شهر تهران هستند.

بدون حضور عامل هوشمند PPO و فقدان سیاست‌های بازاستقرار پیشگیرانه، سیستم دچار فروپاشی زودهنگام می‌شد و آمار تلفات و شکست‌ها در هسته‌ی مرکزی شهر به مراتب فاجعه‌بارتر از شرایط فعلی بود.

در واقع، عامل هوشمند با اجرای تریاژ مکانی و توزیع استراتژیک این کمبودهای اجتناب‌ناپذیر، آسیب‌های کلان را به حداقل رسانده است. اکنون با توجه به اینکه هوش مصنوعی توان بهره‌وری از ظرفیت موجود را به سقف ریاضی خود رسانده است، عبور از این گلوگاه‌ها نیازمند مداخلات فیزیکی، زیرساختی و مدیریتی است. بر اساس الگوهای مکانی و زمانی کشف‌شده توسط شبکه عصبی در میانگین ۳۰ اجرای متوالی، پیشنهادات اجرایی زیر به مدیران شهری و سازمان اورژانس ارائه می‌گردد.

نخستین پیشنهاد راهبردی، توسعه ناوگان پیشرو (موتورلانس)^۱ در هسته مرکزی و تجاری شهر است. تحلیل‌های مکانی در این پژوهش اثبات نمودند که ساخت پایگاه آمبولانس جدید در نقاط داغ و اشباع‌شده نظیر بازار یا مرزداران گره‌گشا نخواهد بود؛ چرا که مشکل اصلی این مناطق کمبود پوشش اولیه نیست، بلکه وقوع حوادث با فاصله زمانی کم و گرفتار شدن آمبولانس اعزامی دوم در ترافیک سنگین این شریان‌هاست. راهکار اقتصادی و علمی برای عبور از این گلوگاه، استقرار ناوگان موتورلانس در این نقاط است تا با دور زدن گره‌های ترافیکی، زمان واکنش اولیه را به حداقل رسانده و تثبیت بالینی بیماران را تا رسیدن آمبولانس اصلی تضمین نمایند.

دومین پیشنهاد زیرساختی، احداث پایگاه‌های فیزیکی جدید در نقاط کور و گلوگاه‌های ساختاری است. برخلاف هسته مرکزی، تحلیل‌ها نشان داد که مناطقی نظیر شهرک استقلال، چیتگر و یافت‌آباد به دلیل مسافت دور و ایزوله بودن در گراف ترافیکی، همواره در تمامی سناریوها به عنوان مناطق فاقد پوشش و دارای بالاترین نرخ شکست شناسایی می‌شوند. از آنجایی که عامل هوشمند به صورت ریاضی قادر به حفظ پوشش پایدار در این نواحی نیست و اعزام ناوگان متحرک به این نقاط باعث فروپاشی کل شبکه می‌گردد، استقرار یک پایگاه فیزیکی ثابت در این محله‌ها امری حیاتی است. این اقدام نه تنها پوشش عادلانه مناطق حاشیه‌ای را تضمین می‌کند، بلکه بار سنگین امداد رسانی دوربرد را از دوش ناوگان متحرک مرکز شهر برمی‌دارد.

سومین مداخله مدیریتی، اعمال سیاست مدیریت پویای شیفته‌ها و تزریق ناوگان کمکی صرفاً بر اساس پنجره‌های بحران است. تحلیل توزیع زمانی تأخیرها نشان داد که گلوگاه‌های سیستم در تمام طول شبانه‌روز

^۱ Motorlance

پخش نشده‌اند، بلکه تابع رژیم ترافیکی خاص هر روز هستند. از این رو، به جای افزایش ثابت و پرهزینه‌ی ناوگان در تمام طول ۲۴ ساعت، پیشنهاد می‌شود از سیاست تزریق ظرفیت متغیر استفاده گردد. در روزهای کاری استاندارد، شیفت‌های تقویتی و استقرار ناوگان پشتیبان باید منحصراً در دو پنجره‌ی زمانی بحرانی، یعنی پیک صبحگاهی (۷ الی ۸ صبح) و پیک عصرگاهی (۱۷ الی ۱۹) برنامه‌ریزی شوند و سیستم در سایر ساعات روز قادر است با همان ظرفیت پایه، تقاضا را مدیریت نماید. در مقابل، در روزهای تعطیل با توجه به تغییر الگوی زیستی شهر، منابع پشتیبان صبحگاهی باید کاملاً حذف شده و ظرفیت مازاد ناوگان به ساعات عصر و شب (به ویژه پنجره زمانی ۱۸ الی ۲۲) منتقل گردد تا با کمترین هزینه استهلاک، بالاترین سطح آمادگی در برابر حوادث شدید و تفریحی شبانه‌ای ایجاد شود.

چهارمین و آخرین پیشنهاد کاربردی، مشارکت با بخش خصوصی^۱ جهت تأمین ناوگان شناور در ساعات اشباع تقاضاست. با توجه به ماهیت به‌شدت نوسانی تقاضا (به‌ویژه در سناریوی بحران با پدیده سرریز صف)، خرید و نگهداری آمبولانس‌های جدید توسط سازمان اورژانس دولتی صرفاً برای پوشش دادن چند ساعت پیک در روز، فاقد توجیه اقتصادی است. پیشنهاد می‌گردد مدیران سیستم بهداشت و درمان از طریق ایجاد پلتفرم‌های یکپارچه، از ناوگان اورژانس‌های خصوصی به عنوان یک ظرفیت پشتیبان استفاده نمایند. با پیاده‌سازی این معماری، عامل هوشمند می‌تواند در ساعات بحرانی نظیر پیک ترافیک عصرگاهی یا هنگام بروز شوک‌های تقاضا، مأموریت‌های با اولویت پایین‌تر (بیماران غیربحال) را به صورت خودکار به بخش خصوصی برون‌سپاری نموده و ظرفیت استراتژیک ناوگان دولتی را منحصراً برای پاسخ‌گویی به حوادث فوق‌اورژانسی حفظ کند.

۵-۳- نوآوری‌های پژوهش

با مرور ادبیات موضوع در حوزه تخصیص ناوگان امدادی، مشخص می‌گردد که بسیاری از مطالعات پیشین مبتنی بر مفروضات ساده‌سازی شده (نظیر سرعت ثابت، گراف‌های ایستا و عدم لحاظ استهلاک ناوگان)

^۱ Public-Private Partnership

بوده‌اند. رساله‌ی حاضر با عبور از این محدودیت‌ها، به جای تمرکز صرف بر توسعه‌ی تئوریک الگوریتم‌ها، تلاش نموده است تا جنبه‌های نوآورانه‌ای را در تقاطع مدل‌سازی واقع‌گرایانه و تفسیرپذیری هوش مصنوعی ارائه نماید که مهم‌ترین آن‌ها در سه محور زیر تبیین می‌گردند.

نخستین جنبه‌ی نوآورانه این پژوهش، توسعه‌ی یک بستر شبیه‌سازی واقع‌گرایانه و مدل‌سازی جامع محدودیت‌های تصادفی در کلان‌شهرهاست. در بسیاری از پژوهش‌های پیشین، تخصیص ناوگان در محیط‌های ایده‌آل ارزیابی می‌شود؛ اما در این تحقیق، با تعریف دقیق فرآیند تصمیم‌گیری مارکوف و اعمال جریمه‌های استراتژیک در تابع پاداش، بر چالش پنهان سرگردانی ناوگان غلبه شد. علاوه بر این، با تزریق نویزهای تصادفی نظیر خروج آمبولانس‌ها از شبکه (به دلیل نقص فنی یا خستگی پرسنل) و اعمال ترافیک‌های پویای وابسته به زمان، محیط شبیه‌سازی از یک مدل انتزاعی به یک بستر آزمایشگاهی نزدیک به واقعیت برای سیستم اورژانس ارتقا یافت. رقابت عامل هوشمند با یک خط مبنای پویا و پیشرفته (به جای مقایسه با روش‌های ضعیف و ابتدایی) در این بستر پرچالش، اعتبار علمی و مهندسی نتایج را به شدت مستحکم نموده است.

دومین رویکرد متمایز در این رساله، ارزیابی متقاطع مدل و سنجش تاب‌آوری سیستم در شرایط آموزش‌ندیده است. در ادبیات یادگیری ماشین، مدل‌ها غالباً منحصراً در همان توزیع داده‌ای که آموزش دیده‌اند ارزیابی می‌شوند. با این وجود، در این تحقیق از طریق اجرای ۳۰ روزه‌ی متوالی در رژیم‌های ترافیکی متفاوت، یک مدل واحد (آموزش‌دیده در روز کاری) به صورت مستقیم در محیط‌های کاملاً جدید نظیر روز تعطیل و تست استرس (بحران با ۷۰۰ تقاضا) مورد سنجش قرار گرفت. این سبک از ارزیابی ثابت نمود که شبکه عصبی PPO صرفاً الگوها را حفظ نکرده است، بلکه قابلیت انطباق در لحظه با تغییرات شهری و پیاده‌سازی مفهوم افت برانزده در مرز فروپاشی شبکه را داراست.

در نهایت، سومین و شاید مهم‌ترین دستاورد تحلیلی این پژوهش، تلاش برای تفسیرپذیری تصمیمات شبکه عصبی و عبور از ماهیت جعبه سیاه^۱ در هوش مصنوعی است. با ابداع رویکرد تحلیل آسیب‌پذیری و استخراج شاخص‌های مکانی، منطق پنهان عامل هوشمند در این رساله تفسیر گردید. کشف این پدیده که

^۱ Black Box

عامل هوشمند به صورت خودکار و ریاضی اقدام به اجرای استراتژی تریاژ مکانی نموده و گره‌های حاشیه‌ای و ایزوله را جهت حفظ ظرفیت مازاد در هسته مرکزی شهر فدا می‌کند، گامی نوآورانه در جهت ترجمه‌ی خروجی شبکه‌های عصبی عمیق به دانش عملیاتی و مدیریتی برای برنامه‌ریزان شهری محسوب می‌گردد.

۵-۴- محدودیت‌های پژوهش و فرضیات ساده‌ساز

هر پژوهش علمی، به ویژه مدل‌سازی و شبیه‌سازی سیستم‌های پیچیده شهری، نیازمند اعمال فرضیات ساده‌ساز جهت امکان‌پذیر نمودن محاسبات ریاضی و آموزش شبکه‌های عصبی است. اگرچه تلاش گردید تا محیط شبیه‌سازی در این رساله بالاترین تطابق را با واقعیت‌های عملیاتی کلان‌شهر تهران داشته باشد و با اجرای میانگین‌گیری‌های متوالی ۳۰ روزه اعتبار نتایج تضمین گردد، اما این پژوهش نیز از محدودیت‌های زیر مستثنی نبوده است که توجه به آن‌ها در تحلیل و بسط نتایج ضروری است.

نخستین محدودیت مدل‌سازی در این تحقیق، عدم مدل‌سازی تفکیکی ظرفیت بیمارستان‌ها و فرآیند انتقال بیماران است. در این پژوهش، مأموریت آمبولانس‌ها به صورت استقرار در گره محل حادثه تا اتمام زمان سرویس مدل‌سازی شده است. در واقع، زمان انتقال بیمار به بیمارستان و فرآیند تحویل وی در بخش اورژانس، که در دنیای واقعی می‌تواند به دلیل شلوغی تریاژ بیمارستان ساعت‌ها به طول انجامد، در قالب یک متغیر تصادفی و کلی به نام مدت زمان خدمت‌رسانی تجمیع شده است. در صورت الزام آمبولانس به ترک محله برای انتقال بیمار به یک بیمارستان خاص، پویایی‌های ناوگان به مراتب پیچیده‌تر شده و بدون شک نرخ تأخیر در شرایط بحرانی فراتر از ارقام فعلی خواهد بود.

دومین فرض ساده‌ساز، استفاده از مدل‌سازی کلان ترافیک^۱ به جای استفاده از داده‌های لحظه‌ای است. به دلیل عدم دسترسی پیوسته به رابط‌های برنامه‌نویسی^۲ ترافیک لحظه‌ای نظیر نشان یا نقشه‌های گوگل^۳ و همچنین چالش‌های سنگین پردازشی آن در فرآیند آموزش میلیون‌ها اپیزود شبکه عصبی، ترافیک در این

^۱ Macro-Traffic

^۲ API

^۳ Google Maps

شبیه‌سازی به صورت ضرایب کلان زمانی^۱ مدل‌سازی شد. به عبارت دیگر، فرض بر این بود که سرعت پایه در معابر ثابت است و این سرعت صرفاً بر اساس ساعات مختلف شبانه‌روز (ساعات پیک و غیرپیک) دستخوش افت می‌شود؛ در حالی که ترافیک خرد در دنیای واقعی شامل توقف‌ها، شتاب‌گیری‌های لحظه‌ای در تقاطع‌ها و گره‌های محلی غیرقابل‌پیش‌بینی است.

محدودیت سوم، عدم اعمال رویدادهای انسداد کامل و فیزیکی در مسیرهاست. گراف طراحی‌شده برای شبکه ارتباطی محله‌ها در این پژوهش، همواره متصل در نظر گرفته شده است؛ بدین معنا که ترافیک سنگین تنها باعث ایجاد تأخیر در سفر می‌شود. این در حالی است که در محیط فیزیکی شهر، رخدادهایی نظیر تصادفات شدید خیابانی، بلایای طبیعی، عملیات عمرانی یا آب‌گرفتگی می‌تواند منجر به انسداد کامل و تصادفی یک شریان اصلی گردد. چنین شرایطی، الگوریتم‌های مسیریابی را مجبور به یافتن مسیرهای جایگزین و طولانی‌تر در لحظه می‌نماید که این سطح از اختلال و قطع ارتباط یال‌ها در گراف مدل فعلی لحاظ نشده است. چهارمین فرض، در نظر گرفتن همگنی کامل در ناوگان امدادی است. در محیط شبیه‌سازی توسعه‌یافته، تمامی ۳۹ وسیله‌ی نقلیه به عنوان آمبولانس‌های استاندارد و کاملاً مشابه (با قابلیت‌های یکسان) در نظر گرفته شدند. با این وجود، در ساختار واقعی و عملیاتی اورژانس، ناوگان شامل ترکیبی متنوع از موتورلانس‌ها، آمبولانس‌های پایه^۲ و آمبولانس‌های مراقبت ویژه^۳ است. بدیهی است که در یک سیستم کاملاً منطبق با واقعیت، اعزام هر یک از این وسایل نیازمند تطبیق دقیق با نوع، شدت و شرایط بالینی حادثه می‌باشد.

پنجمین محدودیت کلیدی در این مدل‌سازی، فرض تقارن ترافیکی و استفاده از یال‌های دوطرفه با وزن‌های یکسان در گراف شهری است. در این شبیه‌سازی، زمان سفر بین هر دو گره متصل، در هر دو مسیر رفت و برگشت برابر و دارای ضریب ترافیک یکسانی در نظر گرفته شده است. این در حالی است که در شبکه‌های حمل‌ونقل دنیای واقعی، جریان ترافیک کلان‌شهرها در ساعات مختلف شبانه‌روز کاملاً جهت‌دار و نامتقارن است. به عنوان نمونه، در ساعات اوج ترافیک صبحگاهی، مسیرهای حومه‌ای به سمت مرکز شهر و

^۱ Multipliers

^۲ Type A

^۳ MICU / Type B

مناطق تجاری دارای بار ترافیکی بسیار سنگینی هستند، در حالی که در همان زمان، لاین‌های خروجی و مسیرهای برگشت ترافیک به مراتب روان‌تری را تجربه می‌کنند. عدم استفاده از گراف‌های جهت‌دار با وزن‌های مستقل برای باندهای رفت و برگشت، اگرچه پیچیدگی محاسباتی و فضای حالت مسئله را برای آموزش شبکه عصبی به شدت کاهش داده است، اما موجب می‌شود تا عامل هوشمند نتواند از این عدم تقارن‌های ترافیکی برای یافتن مسیرهای سریع‌تر و بهینه‌سازی بازگشت ناوگان بهره‌برداری نماید.

در نهایت، محدودیت‌های ذاتی در معماری تک‌عاملی^۱، یکی دیگر از چالش‌های توسعه این سیستم به شمار می‌رود. کنترل تمامی ناوگان توسط یک عامل هوشمند مرکزی در سیستم‌هایی با ابعاد متوسط نظیر شبکه ۳۹ آمبولانسی فعلی، عملکردی یکپارچه و عالی از خود نشان می‌دهد. اما با گسترش مقیاس مسئله به کلان‌شهرهای بزرگتر با صدها پایگاه و آمبولانس، فضای حالت و فضای عمل به شدت بزرگ شده و سیستم دچار پدیده نفرین ابعاد می‌گردد. در چنین مقیاسی، آموزش عامل مرکزی به شدت کند و با چالش‌های محاسباتی روبه‌رو خواهد شد.

۵-۵- پیشنهادات برای تحقیقات آتی

با توجه به دستاوردهای این پژوهش و همچنین محدودیت‌های احصاشده در مسیر مدل‌سازی، محورهای زیر به عنوان مسیرهای تحقیقاتی ارزشمند برای توسعه و ارتقای پژوهش‌های آتی در حوزه تخصیص هوشمند ناوگان اورژانس پیشنهاد می‌گردد.

نخستین پیشنهاد برای مطالعات آینده، یکپارچه‌سازی سیستم با رابط‌های برنامه‌نویسی ترافیک و پیاده‌سازی مسیریابی دینامیک لحظه‌ای است. پیشنهاد می‌شود به جای استفاده از ضرایب کلان ترافیکی، محیط شبیه‌سازی از طریق وب‌سرویس‌ها به داده‌های لحظه‌ای ارائه‌دهندگان نقشه (نظیر نشان، بلد یا نقشه‌های گوگل) متصل گردد. با این ارتقای زیرساختی، می‌توان یک مازول مسیریابی دینامیک به سیستم افزود تا در صورت بروز انسدادهای ناگهانی یا تصادفات خیابانی در حین انجام مأموریت، آمبولانس مجبور به طی کردن

^۱ Single-Agent PPO

مسیر از پیش تعیین شده نباشد؛ بلکه بتواند مسیر حرکت خود را به صورت برخط تغییر داده و بهینه‌ترین مسیر جایگزین را برای فرار از گره‌های ترافیکی انتخاب نماید.

همسو با ارتقای مدل‌سازی شبکه معابر، توسعه‌ی گراف‌های جهت‌دار به منظور شبیه‌سازی ترافیک نامتقارن دومین مسیر تحقیقاتی حائز اهمیت است. در این رساله از یال‌های دوطرفه با وزن ترافیکی یکسان استفاده شد، در حالی که در دنیای واقعی ترافیک مسیرهای رفت و برگشت در ساعات پیک کاملاً متفاوت است. آموزش و بهینه‌سازی عامل هوشمند بر بستر گراف‌های جهت‌دار، امکان ارزیابی دقیق‌تر استراتژی‌های بازگشت به پایگاه و مسیریابی‌های نامتقارن را در کلان‌شهرها فراهم می‌آورد.

سومین محور پیشنهادی، گسترش مرزهای مدل‌سازی به سوی فرآیند تحویل بیمار و انتخاب پویای بیمارستان است. توسعه‌ی تابع پاداش به گونه‌ای که عامل RL علاوه بر بهینه‌سازی سرعت رسیدن به محل حادثه، فاز انتقال بیمار به مناسب‌ترین مرکز درمانی را نیز در بر گیرد، گامی حیاتی در تکمیل این سیستم پشتیبان تصمیم خواهد بود. این مدل‌سازی می‌تواند شامل در نظر گرفتن ظرفیت لحظه‌ای تخت‌های اورژانس در بیمارستان‌های مختلف، زمان تحویل بیمار و ترافیک مسیرهای منتهی به مراکز درمانی باشد.

چهارمین مسیر توسعه، گذار از معماری تک‌عاملی و پیاده‌سازی یادگیری تقویتی چندعاملی^۱ است. به منظور غلبه بر محدودیت‌های پردازشی و محاسباتی ناشی از کنترل متمرکز در کلان‌شهرهایی با صدها پایگاه و آمبولانس، استفاده از الگوریتم‌های پیشرفته‌ای نظیر MAPPO پیشنهاد می‌شود. در این معماری غیرمتمرکز، هر آمبولانس یا گروهی از پایگاه‌های یک منطقه به عنوان یک عامل هوشمند مستقل عمل کرده و برای پوشش گره‌های شهری و توزیع بار کاری، با سایر عوامل وارد فرآیند مذاکره و همکاری می‌شوند که این امر پدیده‌ی نفرین ابعاد را به شدت کنترل می‌کند.

در نهایت، مدیریت یک ناوگان امدادی ناهمگن افق دیگری برای تحقیقات آینده است. گسترش فضای عمل شبکه عصبی به نحوی که عامل تصمیم‌گیرنده بتواند نوع وسیله‌ی نقلیه اعزامی (موتورلانس، آمبولانس پایه یا آمبولانس مراقبت‌های ویژه) را بر اساس شدت بالینی حادثه و وضعیت ترافیکی گره هدف به صورت

^۱ MARL

کاملاً پویا و هوشمند انتخاب نماید، می‌تواند بهره‌وری و انعطاف‌پذیری منابع محدود اورژانس را در سناریوهای بحرانی به شکل چشمگیری افزایش دهد.

مراجع

- [1] P. T. Pons, J. S. Haukoos, W. Bludworth, T. Cribley, K. A. Pons, V. J. Markovchick, "Paramedic response time: does it affect patient survival in an observational study?", *Academic Emergency Medicine*, Vol. 12, pp. 594-600, 2005.
- [2] L. Brotcorne, G. Laporte, F. Semet, "Ambulance location and relocation models", *European Journal of Operational Research*, Vol. 147, pp. 451-463, 2003.
- [3] R. S. Sutton, A. G. Barto, *Reinforcement Learning: An Introduction*, MIT Press, 2018.
- [4] M. Gendreau, G. Laporte, F. Semet, "A dynamic model and parallel tabu search heuristic for real-time ambulance relocation", *Parallel Computing*, Vol. 27, pp. 1641-1653, 2001.
- [5] M. S. Maxwell, M. Restrepo, S. G. Henderson, H. Topaloglu, "Approximate dynamic programming for ambulance redeployment", *INFORMS Journal on Computing*, Vol. 22, pp. 266-281, 2010.
- [6] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, O. Klimov, "Proximal policy optimization algorithms", *arXiv preprint arXiv:1707.06347*, 2017.
- [7] V. Bélanger, A. Ruiz, P. Soriano, "Recent advances in emergency medical services management", *European Journal of Operational Research*, Vol. 272, pp. 1-23, 2019.
- [8] J. P. Pell, J. M. Sirel, A. K. Marsden, I. Ford, S. M. Cobbe, "Effect of reducing, pp. 1385-1388, 2001.
- [9] V. Schmid, "Solving the dynamic ambulance relocation and dispatching problem using approximate dynamic programming", *European Journal of Operational Research*, Vol. 219, pp. 611-621, 2012.
- [10] K. Liu, X. Li, H. Huang, C. C. Zou, Y. Fu, "Ambulance dispatch via deep reinforcement learning", *Proceedings of the 28th International Conference on Advances in Geographic Information Systems*, pp. 1-4, 2020.
- [11] R. Church, C. ReVelle, "The maximal covering location problem", *Papers of the Regional Science Association*, Vol. 32, pp. 101-118, 1974.
- [12] M. Gendreau, G. Laporte, F. Semet, "The maximal expected coverage relocation problem for emergency vehicles", *Journal of the Operational Research Society*, Vol. 57, pp. 22-28, 2006.
- [13] M. L. Puterman, *Markov Decision Processes: Discrete Stochastic Dynamic Programming*, John Wiley & Sons, 2014.
- [14] W. B. Powell, *Approximate Dynamic Programming: Solving the Curses of Dimensionality*, John Wiley & Sons, 2007.

- [15] M. S. Maxwell, S. G. Henderson, H. Topaloglu, "Tuning approximate dynamic programming policies for ambulance redeployment via direct search", *Stochastic Systems*, Vol. 3, pp. 1-40, 2013.
- [16] V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, et al., "Human-level control through deep reinforcement learning", *Nature*, Vol. 518, pp. 529-533, 2015.
- [17] A. Tampuu, T. Matiisen, D. Kodelja, I. Kuzovkin, K. Korjus, J. Aru, et al., "Multiagent cooperation and competition with deep reinforcement learning", *PLoS ONE*, Vol. 12, e0172395, 2017.
- [18] E. W. Dijkstra, "A note on two problems in connexion with graphs", *Numerische Mathematik*, Vol. 1, pp. 269-271, 1959.
- [19] L. Aboueljineane, E. Sahin, Z. Jemai, "A review on simulation models applied to emergency medical service operations", *Computers & Industrial Engineering*, Vol. 66, pp. 734-750, 2013.
- [20] Y. J. Bell, M. C. Cassandras, "Dynamic vehicle routing and dispatching for emergency services", *IEEE Transactions on Intelligent Transportation Systems*, Vol. 16, pp. 2487-2498, 2015.
- [21] H. K. Rajagopalan, C. Saydam, J. Xiao, "A multiperiod set covering location model for dynamic redeployment of ambulances", *European Journal of Operational Research*, Vol. 186, pp. 652-666, 2008.
- [22] V. Schmid, K. F. Doerner, "Ambulance location and relocation problems with time-dependent travel times", *European Journal of Operational Research*, Vol. 207, pp. 1293-1303, 2010.
- [23] N. Channouf, P. L'Ecuyer, A. Ingolfsson, A. N. Avramidis, "The application of forecasting techniques to modeling emergency medical system calls in Calgary, Alberta", *Health Care Management Science*, Vol. 10, pp. 25-45, 2007.
- [24] Z. Zhou, A. B. M. Shaw, "Spatial and temporal analysis of emergency medical services (EMS) calls", *Applied Geography*, Vol. 124, 102313, 2020.
- [25] J. Bandara, M. E. Mayorga, L. W. McLay, "Priority dispatching strategies for EMS systems," *Journal of the Operational Research Society*, Vol. 65, pp. 572-587, 2014.
- [26] M. E. Mayorga, L. W. McLay, D. J. Morrice, "A markov decision process model for the dynamic dispatch of emergency medical vehicles," *European Journal of Operational Research*, Vol. 227, pp. 555-566, 2013.
- [27] S. G. Henderson, A. J. Mason, "Ambulance service planning: simulation and data analysis," in *Operations Research and Health Care*, Springer, pp. 95-121, 2004.
- [28] A. Ingolfsson, "EMS planning and management," in *Operations Research and Health Care*, Springer, pp. 105-128, 2013.
- [29] L. A. McLay, M. E. Mayorga, "A model for dispatching emergency medical vehicles to prioritized patients," *IIE Transactions*, Vol. 45, pp. 1171-1188, 2013.
- [30] T. Andersson, P. Värbrand, "Decision support for ambulance dispatch and relocation," *Journal of the Operational Research Society*, Vol. 58, pp. 195-201, 2007.

- [31] L. Li, T. J. Walsh, M. L. Littman, "Towards a unified theory of state abstraction for MDPs," ISAIM, pp. 531-539, 2006.
- [32] A. Jagtenberg, S. Bhulai, R. van der Mei, "An evaluation of ambulance dispatch policies," European Journal of Operational Research, Vol. 258, pp. 240-254, 2017.
- [33] A. Y. Ng, D. Harada, S. Russell, "Policy invariance under reward transformations: Theory and application to reward shaping," ICML, Vol. 99, pp. 278-287, 1999.
- [34] A. Raffin, A. Hill, A. Gleave, A. Kanervisto, M. Ernestus, N. Dormann, "Stable-Baselines3: Reliable Reinforcement Learning Implementations," Journal of Machine Learning Research, Vol. 22, pp. 1-8, 2021.
- [35] D. S. Matteson, M. W. McLean, D. B. Woodard, S. G. Henderson, "Forecasting emergency medical services call arrival rates," The Annals of Applied Statistics, Vol. 5, pp. 1379-1406, 2011.
- [36] D. Gross, J. F. Shortle, J. M. Thompson, C. M. Harris, Fundamentals of Queueing Theory, John Wiley & Sons, 2008.
- [37] A. M. Law, Simulation Modeling and Analysis, McGraw-Hill Education, 5th Edition, 2015.
- [38] L. Moore, A. Lavoie, A. Abdous, S. Le Sage, C. D. Liberman, E. Goulet, "Key performance indicators in prehospital emergency care," Prehospital Emergency Care, Vol. 19, pp. 218-232, 2015.
- [39] P. D. Patterson, M. D. Weaver, D. Frank, C. W. Karashin, P. R. P. Raja, L. R. Vena, et al., "Fatigue-related risk in emergency medical services," Prehospital Emergency Care, Vol. 16, pp. 509-516, 2012.

Abstract

Optimal management of pre-hospital Emergency Medical Services (EMS) fleets in densely populated metropolises is a complex challenge due to traffic fluctuations and the stochastic distribution of incidents. Traditional reactive approaches, lacking a predictive perspective, often lead to coverage gaps and fleet wandering. To overcome this challenge, the present study designs a hybrid decision support system and simulates its performance on a simplified traffic graph of the Tehran metropolis. In this architecture, dispatching is executed based on the shortest dynamic travel time, while proactive relocation is guided by an intelligent agent utilizing Deep Reinforcement Learning (DRL) and the Proximal Policy Optimization (PPO) algorithm. This simulation model, incorporating realistic constraints such as depreciation, fleet breakdowns, and dynamic traffic, was rigorously evaluated based on the statistical average of 30 consecutive runs. The extracted results across three operational scenarios demonstrate the significant superiority of the hybrid agent. On a standard workday, the success rate of arriving within the golden time improved by over 11%, reaching 86%. In the cross-evaluation (holiday scenario), by adopting a strategic restraint policy, the model reduced fleet wandering time by nearly 74%. Furthermore, during stress testing under crisis conditions (700 demands), the neural network accurately perceived system saturation and executed spatial triage logic, enhancing fleet resilience at the most severe intersection of traffic and crisis with a 26% relative improvement compared to the baseline.

Keywords: EMS Fleet Management, Proactive Relocation, Hybrid Decision System, Deep Reinforcement Learning, PPO Algorithm, Spatial Triage, Discrete-Event Simulation.



K. N. Toosi University of Technology
Faculty of Electrical Engineering

**A Thesis Submitted in Partial Fulfillment of the Requirements for
the Degree of Bachelor of Science (B.Sc.)
in Electrical Engineering - Control**

Design and Simulation of an Intelligent Decision-Making Agent for Ambulance
Dispatch and Relocation in Densely Populated Urban Environments

By:

Niloofar Molla

Supervisor:

Dr. Mehdi Delrobaei

Summer 2026